人工智能中的数学讲义

方聪

北京大学

摘要

本讲义收录了人工智能中的数学课程中的主要概念与课程习题。概率与统计讲义内容摘录于陈家鼎、郑忠国《概率与统计》教材与复熹和张原概率与统计课程课件。图论内容摘录于耿素云、屈婉玲、王捍贫《离散数学教程》。本讲义版权归上述作者，不会出版。讲义仅供于上该课程的同学们学习参考，讲义的错误会不断修正。感谢张乙沐、张海涵对讲义整理的帮助。

1.1 随机事件及其运算

1.1.1 随机事件

样本空间和样本点: 随机实验 E 中所有可能结果组成的集合称为 E 的**样本空间**，记为 Ω。样本空间中的元素称为样本点，记为 ω

- E_1：抛掷硬币，观察正面 H，反面 T 出现的情况。

$$\Omega_1 = \{H, T\}.$$

- E_2：抛掷一枚硬币 3 次，观察正面 H，反面 T 出现的情况。

$$\Omega_2 = \{HHH, HHT, HTH, THH\ HTT, THT, TTH, TTT\}.$$

- E_3：抛掷一枚硬币 3 次，观察正面出现的次数。

$$\Omega_3 = \{0, 1, 2, 3\}.$$

随机现象的某些样本点组成的集合称为**随机事件**，简称为事件，常用 $A, B, C, \cdots$ 表示

例如, E 为抛掷一枚骰子, 事件 $A=$"出现奇数点", 即 $A = \{1, 3, 5\}$, 是样本空间 $\Omega = \{1, 2, 3, 4, 5, 6\}$ 的一个子集

事件的频率：设 μ 是 n 次实验中事件 A 发生的次数，则事件 A 发生的频率 $\frac{\mu}{n}$，随着实验次数 n 增大，频率会在某一数值 p 附近摆动，称为该事件的**概率**，记为 $P(A) = p$

由于频率 $\frac{\mu}{n}$ 总在 $0, 1$ 之间，我们有：

$$0 \leqslant P(A) \leqslant 1$$

例如投一枚硬币 n 次，出现 μ 次正面，则 $\frac{\mu}{n} \overset{n\to\infty}{\to} p$。其中，主观概率 p 为事件的置信度，概率是可能性大小的度量。大概率事情易发生，小概率事情不易发生。

1.1.1.1 事件的交和并

定义 2.1 设有事件 A 和事件 B，如果 A 发生，则 B 必发生，那么称事件 B 包含事件 A（或称事件 A 在 B 中），并记为

$$A \subset B \ (\text{或 } B \supset A)$$

定义 2.2 如果事件 A 包含事件 B，同时事件 B 包含事件 A，则事件 A 和事件 B 相等，并记为

$$A = B$$

定义 2.3 设 A 和 B 都是事件，则 "A 或 B" 表示这样的事件 C：C 发生当且仅当 A 或 B 中至少有一个发生，该事件 C 叫做 A 与 B 的并，记为 $A \cup B$。

例 2.1 （对应郑书例 2.1）在桌面上，投掷两枚匀称的硬币，A 表示 "恰好一枚国旗朝上"，B 表示 "两枚国旗朝上"，C 表示 "至少一枚国旗朝上"，则 $C = A \cup B$.

对于并运算，有以下性质，我们恒记必然事件为 U，不可能事件为 V：

$$A \cup B = B \cup A$$
$$A \cup U = U，A \cup V = V$$

定义 2.4 设 A 和 B 都是事件，则 "A 且 B" 表示这样的事件 C：C 发生当且仅当 A 和 B 都发生，该事件 C 叫做 A 与 B 的交，记为 $A \cap B$，也简记为 AB。

在例 2.1 中，$A \cap C = A$，$B \cap C = C$，$A \cap B = A$

对于交运算，有以下性质：

$$A \cap B = B \cap A$$
$$A \cap U = A，A \cap V = V$$

1.1.1.2 事件的余和差

定义 2.5 设 A 是事件，称 "非 A" 是 A 的对立事件（或称余是事件），其含义为，"非 A" 发生当且仅当 A 不发生，常常用 $\overline{A}$ 表示 "非 A"，也用 A^c 表示 "非 A"。

由定义知 $\overline{(\overline{A})} = A$，$\overline{U} = V$，$\overline{V} = U$

定义 2.6 设 A 和 B 都是事件，则两个事件的差 "A 减去 B" 表示这样的事件 C：C 发生当且仅当 A 发生而 B 不发生，该事件 C 记为 $A - B$（或 $A \backslash B$）

由定义知，$A - B = A \cap \bar{B}$

画图法确定关系。

1.1.1.3 事件运算的性质

事件的基本运算还有以下性质:

- $A \cup (B \cup C) = (A \cup B) \cup C$ “并”的结合律
- $A \cap (B \cap C) = (A \cap B) \cap C$ “交”的结合律
- $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$ 分配律
- $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$ 分配律
- $A \cup A = A$，$A \cap A = A$
- $\overline{A \cup B} = \overline{A} \cap \overline{B}$ 对偶律
- $\overline{A \cap B} = \overline{A} \cup \overline{B}$ 对偶律

多个事件的交和并:
设 $A_1, A_2, \cdots, A_n$ 是 n 个事件，则“$A_1, A_2, \cdots, A_n$”的并是指这样的事件：它发生当且仅当 $A_1, A_2, \cdots, A_n$ 中至少一个发生，常常用 $\bigcup\limits_{i=1}^{n} A_i$ 表示 $A_1, A_2, \cdots, A_n$ 的并
设 $A_1, A_2, \cdots, A_n$ 是 n 个事件，则“$A_1, A_2, \cdots, A_n$”的交是指这样的事件：它发生当且仅当 $A_1, A_2, \cdots, A_n$ 这 n 个事件都发生，常常用 $\bigcap\limits_{i=1}^{n} A_i$ 表示 $A_1, A_2, \cdots, A_n$ 的交，也用 $A_1 A_2 \cdots A_n$ 表示这个“交”

实际应用中，还需定义无穷多事件的并与交
设 $A_1, A_2, \cdots, A_i, \cdots$ 是一列事件，则 B 是指这样的事件：B 发生当且仅当这些 $A_i (i = 1, 2, \cdots)$ 中至少一个发生，这个 B 叫做诸 A_i 的并，记为 $\bigcup\limits_{i=1}^{\infty} A_i$，有时也写为 $A_1 \cup A_2 \cup \cdots$
设 $A_1, A_2, \cdots, A_i, \cdots$ 是一列事件，则 C 是指这样的事件：C 发生当且仅当这些 $A_i (i = 1, 2, \cdots)$ 都发生，这个 C 叫做诸 A_i 的交，记为 $\bigcap\limits_{i=1}^{\infty} A_i$，有时也写为 $A_1 A_2 \cdots$

例: 取 $X \in \mathbb{R}$, 事件 A_i 为 $X \in [\frac{1}{i+1}, \frac{1}{i}]$, 事件 B_i 为 $X \in [0\ \frac{1}{i}]$。则事件 $\bigcup\limits_{i=1}^{n} A_i$ 发生等价于 $X \in [\frac{1}{n+1}, 1]$，事件 $\bigcap\limits_{i=1}^{n} B_i$ 发生等价于 $X \in [0, \frac{1}{n}]$。进而当 $n \to \infty$ 时事件 $\bigcup\limits_{i=1}^{\infty} A_i$ 发生等价于 $X \in (0, 1]$，事件 $\bigcap\limits_{i=1}^{\infty} B_i$ 发生等价于 $X = 0$。

并的更一般定义是，设 $\{A_a, a \in \Gamma\}$ 是一族事件（其中 Γ 是任何非空集，每个 $a \in \Gamma$ 对应一个事件 A_a），这些事件 A_a 的“并”是指这样的事件 B：B 发生当且仅当至少一个 A_a 发生，这个 B 常常记为 $\bigcup\limits_{a \in \Gamma} A_a$，类似可以定义一族事件的交 $\bigcap\limits_{a \in \Gamma} A_a$

例 2.3:（对应郑书例 2.3）一射手向一个目标连续射击，设 $A_1 =$ “第一次射击，命中”，$A_i =$ “前 $i-1$ 次射击都未命中，第 i 次射击命中”（$i = 2, 3, \cdots$），$B =$ “终于命中”，则 $B = \bigcup\limits_{i=1}^{\infty} A_i$

例 2.4:（对应郑书例 2.4）一射手向一个目标连续射击，设 $A_i =$ “第 i 次射击，未命中目标”（$i = 2, 3, \cdots$）则 $\bigcap\limits_{i=1}^{\infty} A_i =$ “每次均未命中目标”

不难验证，对可列个事件的并和交有以下规律：

- $A \cup (\bigcap\limits_{i=1}^{\infty} B_i) = \bigcap\limits_{i=1}^{\infty} (A \cup B_i)$ 分配律
- $A \cap (\bigcup\limits_{i=1}^{\infty} B_i) = \bigcup\limits_{i=1}^{\infty} (A \cap B_i)$ 分配律
- $\overline{(\bigcup\limits_{i=1}^{\infty} A_i)} = \bigcap\limits_{i=1}^{\infty} \overline{A_i}$ 对偶律
- $\overline{(\bigcap\limits_{i=1}^{\infty} A_i)} = \bigcup\limits_{i=1}^{\infty} \overline{A_i}$ 对偶律

1.1.1.4 互斥事件

互不相容的事件

如果事件 A 和事件 B 不能都发生，即 $A \cap B = V$，则称 A 和 B 是互不相容的事件（也称互斥的事件）

称事件 $A_1, \cdots A_n$ 互不相容，若对任何 $i \neq j (i, j = 1, \cdots n)$，$A_i$ 与 A_j 互不相容

例如，抛掷两枚硬币，事件“恰好一枚国徽朝上”和事件“两枚都是国徽朝上”是互不相容的。不难看出，对任何事件 A，A 和 $\overline{A}$ 是互不相容的

- 加法公式：$A_1, A_2, \ldots$ 互不相容，则：

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

- $P(A \bigcup B) = P(A) + P(B) - P(AB)$

1.2 概率的公理化定义

概率空间子类: 设 Ω 为样本空间, $\mathscr{F}$ 为 Ω 的一些子集构成的集类。若 $\mathscr{F}$ 满足以下三个条件:(1) $\Omega \in \mathscr{F}$,(2) $A \in \mathscr{F} \Rightarrow A^c \in \mathscr{F}$,(3) $\{A_n\}_{n\in\mathbb{N}} \subsetneqq \mathscr{F} \Rightarrow \bigcup\limits_{n=1}^{\infty} A_n \in \mathscr{F}$, 则称 $\mathscr{F}$ 为概率空间子类

例:

- $\mathscr{F} = \{\emptyset, \Omega\}$ 平凡概率空间子类
- $\mathscr{F} = \{\emptyset, \Omega, A, \overline{A}\}$ 包含 A 的最小概率空间子类
- $\mathscr{F} = \{A | A \subset \Omega\}$ Ω 上的最大概率空间子类
- $\Omega = \{\omega_1, \cdots, \omega_n\}$, 则 Ω 所有子集构成的概率空间子类共有 2^n 个元素

定义: 设 $\mathscr{F}$ 是满足上述条件的概率空间子集类。概率 $P = P(\cdot)$ 是 $\mathscr{F}$ 上面定义的实值函数, 满足:

- 非负性: $P(A) \geqslant 0$ 对于一切 $A \in \mathscr{F}$
- 规范性: $P(\Omega) = 1$
- 可列可加性: 若 $A_n \in \mathscr{F} (n = 1, 2, \cdots)$ 两两不相交, 则

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

$(\Omega, \mathscr{F}, P)$ 为概率空间

例 1: 假定 $\Omega = \{\omega_1, \cdots, \omega_n\}$, $\mathscr{F}$ 为全体子集构成的概率空间子类。
设 $p_1, \cdots, p_n$ 为 n 个非负实数, 且满足 $\sum\limits_{i=1}^{n} p_i = 1$。令

$$\mathbb{P}(\emptyset) = 0, \quad \mathbb{P}(A) = \sum_{j=1}^{k} p_{i_j}, \quad A = \{\omega_{i_1}, \cdots, \omega_{i_k}\}, k = 1, \cdots, n$$

则 $\mathbb{P}$ 为 $(\Omega, \mathscr{F})$ 上概率。
概率 P 有以下性质:
(1) $P(\emptyset) = 0$;
(2) 若 $A \in \mathscr{F}$, 则 $P(A^c) = 1 - P(A)$;
(3) 若 $A_1, \cdots, A_n$ 都属于 $\mathscr{F}$ 且两两不相交, 则

$$P(\bigcup_{i=1}^{n} A_i) = \sum_{i=1}^{n} P(A_i) \tag{1.2.1}$$

(4) 若 $A \subset B$，$A \in \mathscr{F}$，$B \in \mathscr{F}$，则 $P(A) \leqslant P(B)$，且

$$P(B-A) = P(B) - P(A) \tag{1.2.2}$$

(5) 若 $A_n \subset A_{n+1}$，$A_n \in \mathscr{F}(n=1,2,\cdots)$，则

$$P(\bigcup_{n=1}^{\infty} A_n) = \lim_{n\to\infty} P(A_n) \tag{1.2.3}$$

(6) 若 $A_n \supset A_{n+1}$，$A_n \in \mathscr{F}(n=1,2,\cdots)$，则

$$P(\bigcap_{n=1}^{\infty} A_n) = \lim_{n\to\infty} P(A_n) \tag{1.2.4}$$

(7) 若 $A_n \in \mathscr{F}(n=1,2,\cdots)$，则

$$P(\bigcup_{n=1}^{\infty} A_n) \leqslant \sum_{n=1}^{\infty} P(A_n) \tag{1.2.5}$$

2.1 古典概型

模型定义：若随机现象有如下两个特征：
(1) 在实验中它的全部可能性只有有限个；
(2) 基本事件发生或出现是等可能的；
则称其对应的数学模型为古典概型

取

$$\Omega = \{\omega_1, \omega_2, \cdots, \omega_n\}, \quad \mathscr{F} = \{A | A \subset \Omega\}$$

令 P 为 $(\Omega, \mathscr{F})$ 上的概率测度，满足

$$P(\{w_1\}) = \cdots = P(\{w_n\})$$

则 $(\Omega, \mathscr{F}\ P)$ 为古典概型对应的概率空间。
计算公式：对 $A = \{\omega_{i_1}, \cdots, \omega_{i_k}\} \in \mathscr{F}$，利用概率的有限可加性可知：

$$P(A) = \sum_{j=1}^{k} P(\{\omega_{i_j}\}) = \frac{k}{n} = \frac{|A|}{|\Omega|}$$

排列：从含有 n 个不同元素的总体中抽取 r 个进行排列
(1) 放回情形：共有 n^r 种排列方式
(2) 不放回情形：共有 $A_n^r := n(n-1)\cdots(n-r+1)$ 种排列方式
当 $r = n$ 时，为全排列，此时 $A_n^n = n!$。
组合：(1) 从 n 个不同元素中取出 r 个而不考虑其顺序，称为组合，其总数为 $C_n^r = \frac{n!}{r!(n-r)!} = \frac{A_n^r}{r!}$
(2) 把 n 个不同元素分成 k 个部分，且第 i 个部分有 r 个元素，$1 \leqslant i \leqslant k$，且 $r_1 + r_2 + \cdots + r_k = n$，则有 $\frac{n!}{r_1! r_2! \cdots r_k!}$ 种方法
(3) 把 n 个元素全部带有标注，其中 n_1 个带标注 1，n_2 个带标注 2，$\cdots$，n_k 个带标注 k。现在从此 n 个元素中取出 r 个，使得带有标注 i 的元素有 r_i 个，其中 $1 \leqslant i \leqslant k$ 且 $r_1 + r_2 + \cdots + r_k = r$。则不同取法的总数为 $C_{n_1}^{r_1} C_{n_2}^{r_2} \cdots C_{n_k}^{r_k}$。
(4) 从 n 个不同元素中有重复的取出 r 个，不计顺序，则不同的取法有 C_{n+r-1}^{r}（有重复组合数）
组合公式：对一切正整数 a, b，

$$\sum_{i=0}^{n} C_a^i C_b^{n-i} = C_{a+b}^n$$

约定当 $k > n$ 时，$C_n^k = 0$。特别地，

$$\sum_{i=0}^{n}(C_n^i)^2 = C_{2n}^n$$

例 1：（对应郑书例 3.1）某人同时抛掷两枚骰子，问：得到 7 点（两颗骰子的点数之和的概率是多少?）

解：我们用甲乙分别表示这两颗骰子，每颗骰子共有 6 种可能的点数：1,2,3,4,5,6，两颗骰子共有 6×6=36 种可能结果：$(i,j)(i=1,\cdots,6)(j=1,\cdots,6)$，这里 i 表示骰子甲的点数，j 表示骰子乙的点数，显然这些结果出现的机会是相等的，它们构成了等概完备事件组，事件“得到 7 点”由 6 种结果（基本事件）组成：$(1,6),(2,5),(3,4),(4,3),(5,2),(6,1)$，故事件“得到 7 点”的概率为 $\frac{6}{36}=\frac{1}{6}$ □

例 2：甲口袋有 5 个白球，3 个黑球，乙口袋中有 4 个白球，6 个黑球，从两个口袋中各任取一球，求取到的两个球颜色相同的概率。

解：从两个口袋中各取一球，共有 $C_8^1C_1^10$ 种等可能取法。两球颜色相同可能情况为：从甲乙口袋均取出白球，从甲乙口袋均取出黑球，共有 $C_5^1C_4^1+C_3^1C_6^1$ 种取法，于是

$$P(\text{取到的两个球颜色相同}) = \frac{C_5^1C_4^1+C_3^1C_6^1}{C_8^1C_{10}^1} = \frac{19}{40}$$

□

例 3：（巴拿赫问题）某数学家有两盒火柴，每盒有 n 根，每次使用时，他任取一盒并从中抽出一根，问他发现一盒空而同时另一盒还有 $r(0 \leqslant r \leqslant n)$ 的概率为多少 (发现为空表示最后一次抽到空盒)?

解：设两盒火柴分别为 A，B，由对称性，所求概率为事件 $E=$“发现 A 盒空而 B 盒还有 r 根”的概率的 2 倍。

先计算样本空间中的样本点个数，由于共取了 $2n-r+1$ 次，故有 2^{2n-r+1} 个样本点。

考察事件 E，等效为前 $2n-r$ 次 A 盒恰好取 n 次，次序不论，最后一次必定取到 A 盒，此种样本点共有 C_{2n-r}^n 个，因此

$$P(E) = \frac{C_{2n-r}^n}{2^{2n-r+1}}.$$

所求概率为 $\frac{C_{2n-r}^n}{2^{2n-r}}$.

2.2 条件概率与独立性

2.2.1 条件概率

条件概率： 设 $(\Omega, \mathscr{F}\ P)$ 为概率空间，$B \in \mathscr{F}$ 满足 $P(B) > 0$。称

$$P(A|B) = \frac{P(AB)}{P(B)}, A \in \mathscr{F}$$

为 B 发生条件下 A 发生的条件概率。

条件概率 $P(\cdot|B)$ 为 $\mathscr{F}$ 上的概率，即满足：

- $P(A|B) \geqslant 0, \quad \forall A \in \mathscr{F}$
- $P(\Omega|B) = 1$
- $\forall \{A_n\} \subset \mathscr{F}, A_n \cap A_m = \emptyset, \forall n \neq m,$

$$P(\sum_{n=1}^{\infty} A_n|B) = \sum_{n=1}^{\infty} P(A_n|B)$$

容易得到，$P(B|\Omega) = P(B)$。

乘法公式： $P(AB) = P(B \mid A)P(A)$

乘法公式的推广： $P(A_1A_2\cdots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1A_2)\cdots P(A_n|A_1A_2\cdots A_{n-1})$，其中 $P(A_1A_2\cdots A_{n-1} > 0$。

例 1： 将 52 张扑克牌（不含大王、小王）随机地分为 4 堆，每堆 13 张，问：各堆都含有 A 牌（即 1 点）的概率是多少？

解： 将 4 堆扑克牌编号：第 1 堆，第 2 堆，第 3 堆，第 4 堆，用 A_1, A_2, A_3, A_4 依次表示 4 个 A 牌，设 i_1, i_2, i_3, i_4 是 1,2,3,4 的一个排列，令 $E_{i_1i_2i_3i_4} =$ “第 i_1 堆有 A_1 但没有 A_2, A_3, A_4，第 i_2 堆有 A_2 但没有 A_1, A_3, A_4，第 i_3 堆有 A_3 但没有 A_1, A_2, A_4，第 i_4 堆有 A_4 但没有 A_1, A_2, A_3”，$E =$ “各堆都含有 A”，则

$$E = \bigcup_{i_1i_2i_3i_4} E_{i_1i_2i_3i_4}$$

这些事件两两不相容，易知 $P(E) = 4!P(E_{1234})$，令 $E_k = \{$ 第 k 堆含有 A_k 但不含有其他的 $A_j (j \neq k)\} \quad (k = 1, 2, 3, 4)$，则

$$P(E_{1234}) = P(E_1)P(E_2|E_1)P(E_3|E_1E_2)P(E_4|E_1E_2E_3)$$

易知

$$P(E_1) = C_{48}^{12}/C_{52}^{13}, \quad P(E_2|E_1) = C_{36}^{12}/C_{39}^{13},$$

$$P(E_3|E_1E_2) = C_{24}^{12}/C_{26}^{13}, \quad P(E_4|E_1E_2E_3) = 1,$$

于是

$$P(E_{1234}) = \frac{C_{48}^{12}C_{36}^{12}C_{24}^{12}}{C_{52}^{13}C_{39}^{13}C_{26}^{13}} = \frac{13^4}{52\times51\times50\times49},$$

$$P(E) = 4!P(E_{1234}) \approx 0.105$$

□

例 2：（罐子模型）设罐中有 b 个黑球，r 个红球，每次随机取出一个球，取出后将原球放回，还加进 c 个同色球和 d 个异色球，记 B_i 为“第 i 次取出的是黑球”，R_j 为“第 j 次取出的是红球”。若连续从罐中取出三个球，其中有两个红球，一个黑球，则由乘法公式我们可得

$$P(B_1R_2R_3) = P(B_1)P(R_2|B_1)P(R_3|B_1R_2) = \frac{b}{b+r}\cdot\frac{r+d}{b+r+c+d}\cdot\frac{r+d+c}{b+r+2c+2d},$$

$$P(R_1B_2R_3) = P(R_1)P(B_2|R_1)P(R_3|R_1B_2) = \frac{r}{b+r}\cdot\frac{b+d}{b+r+c+d}\cdot\frac{r+d+c}{b+r+2c+2d},$$

$$P(R_1R_2B_3) = P(R_1)P(R_2|R_1)P(B_3|R_1R_2) = \frac{r}{b+r}\cdot\frac{r+c}{b+r+c+d}\cdot\frac{b+2d}{b+r+2c+2d},$$

以上概率与黑球在第几次被抽出有关。罐子模型也称波利亚（Polya）模型，这个模型的各种变化如下：

（1）当 $c=-1$，$d=0$ 时，为不返回抽样，此时前次抽取结果会影响后次抽取结果，但只要抽取的黑球和红球个数确定，则概率不依赖其抽出球的次序，有

$$P(B_1R_2R_3) = P(R_1B_2R_3) = P(R_1R_2B_3) = \frac{br(r-1)}{(b+r)(b+r-1)(b+r-2)}$$

（2）当 $c=0$，$d=0$ 时，为返回抽样，此时前次抽取结果不会影响后次抽取结果，上述三种概率相等，有

$$P(B_1R_2R_3) = P(R_1B_2R_3) = P(R_1R_2B_3) = \frac{br^2}{(b+r)^3}$$

（3）当 $c>0$，$d=0$ 时，为传染病模型，此时每次取出球后会增加下一次取到同色球的概率，或者说，每发现一个传染病患者，以后都会增加再传染的概率。同样的，上述三种概率相等，且都等于

$$P(B_1R_2R_3) = P(R_1B_2R_3) = P(R_1R_2B_3) = \frac{br(r+c)}{(b+r)(b+r+c)(b+r+2c)}$$

可以看出，当 $d=0$ 时，只要取出的黑球和红球个数确定，则概率不依赖于其抽出球的顺序。

（4）当 $c=0$，$d>0$ 时，为安全模型，可以解释为，每当事故发生，会抓紧安全工作，从而下一次发生事故的概率会减少，而当事故未发生时，安全工作会松懈，下一次发生事故的概率会增大，上述三种概率分别为：

$$P(B_1R_2R_3) = \frac{b}{(b+r)}\cdot\frac{r+d}{b+r+d}\cdot\frac{r+d}{b+r+2d},$$

$$P(R_1B_2R_3)=\frac{r}{(b+r)}\cdot\frac{b+d}{b+r+d}\cdot\frac{r+d}{b+r+2d},$$
$$P(R_1R_2B_3)=\frac{r}{(b+r)}\cdot\frac{r}{b+r+d}\cdot\frac{b+2d}{b+r+2d}$$

例： 设 n 件产品中有 m 件不合格品，从中任取两件，已知两件中有一件是合格品，求另一件也是合格品的概率。

解： 记事件 A "有一件是合格品"，B "另一件也是合格品"。则

$P(A)=P$（取出一件合格品，一件不合格品）$+P$（取出两件都是合格品）

$=\frac{C_m^1C_{n-m}^1}{C_n^2}+\frac{C_{n-m}^2}{C_n^2}=\frac{2m(n-m)+(n-m)(n-m-1)}{n(n-1)}$

$=\frac{(n-m)(n+m-1)}{n(n-1)}$

$P(AB)=P$（取出两件都是合格品）$=\frac{C_{n-m}^2}{C_n^2}=\frac{(n-m)(n-m-1)}{n(n-1)}$

于是所求概率为

$P(B\mid A)=\frac{P(AB)}{P(A)}=\frac{\frac{(n-m)(n-m-1)}{n(n-1)}}{\frac{(n-m)(n+m-1)}{n(n-1)}}=\frac{n-m-1}{n+m-1}$ □

2.2.2 事件的独立性

事件的独立性： 设 $(\Omega,\mathscr{F}\ P)$ 为概率空间，称 $A,B\in\mathscr{F}$ 相互独立（独立），若

$$P(AB)=P(A)P(B)$$

性质：（1）若 A,B 独立，且 $P(B)>0$，则

$$P(A|B)=\frac{P(AB)}{P(B)}=\frac{P(A)P(B)}{P(B)}=P(A).$$

即条件概率等于无条件概率。

（2）若 A,B 独立，则 A 与 $\overline{B}$，$\overline{A}$ 与 B，$\overline{A}$ 与 $\overline{B}$ 亦独立。

$$P(A\overline{B})=P(A)-P(AB)=P(A)-P(A)P(B)=P(A)P(\overline{B})$$

（3）零概率事件及其对立的事件与任意的事件都独立。

例： 袋中有 a 只黑球和 b 只白球，令 A："第一次摸到黑球"，B："第二次摸到黑球"。讨论 A 和 B 的独立性。

（1）放回情形。因为

$$P(A)=\frac{a}{a+b},P(AB)=\frac{a^2}{(a+b)^2},P(\overline{A}B)=\frac{ab}{(a+b)^2},$$

所以

$$P(B)=P(AB)+P(\overline{A}B)=\frac{a^2+ab}{(a+b)^2}=\frac{a}{a+b}$$

故

$$P(A)P(B)=P(AB)$$

（2）不放回情形。易知

$$P(A)=P(B)=\frac{a}{a+b},P(\overline{A}B)=\frac{ab}{(a+b)(a+b-1)},$$

故

$$P(A)P(B)\neq P(AB)$$

定义： 设 $\{A_k\}_{k\leqslant n}\subset\mathscr{F}$。称 $A_1,A_2,\cdots,A_n$ 相互独立，若

$$P(\bigcap_{j=1}^{k}A_{i_j})=\prod_{j=1}^{k}P(A_{i_j}),\quad 1\leqslant i_1<i_2<\cdots<i_k\leqslant n,k\leqslant n$$

注意：独立 $\Rightarrow$ 两两独立，但是反之不对：
伯恩斯坦反列：一个均匀的正四面体，其第一、二、三面分别涂上红、黄、蓝三种颜色第四面同时涂上以上三种颜色。以 A,B,C 分别表示投一次四面体出现红、黄、蓝颜色朝下的事件，则

$$P(A)=P(B)=P(C)=\frac{1}{2},\quad P(AB)=P(BC)=P(AC)=\frac{1}{4}$$

从而 A,B,C 两两独立，但是，

$$P(ABC)=\frac{1}{4}\neq P(A)P(B)P(C)$$

独立性与概率计算： 设 $A_1,A_2,\cdots,A_n$ 相互独立，则

$$P(A_1\cup A_2\cup\cdots\cup A_n)=1-\prod_{i=1}^{n}P(\overline{A_i})$$

例： 设有某型号的高射炮，每门炮（发射一发）击中敌机的概率为 0.6，现在若干门炮同时发射（每炮射一发），问：若要以 99% 的把握击中来犯的一架敌机，至少需要配置几门高射炮？
解： 设 n 是需要配置的高射炮的门数，记 $A_i=$“第 i 门炮击中敌机”$(i=1,\cdots,n)$，$A=$“敌机被击中”。由于 $A=\bigcup\limits_{i=1}^{n}A_i$，于是要找到 n，使得

$$P(A)=P(\bigcup_{i=1}^{n}A_i)\geqslant 0.99$$

由于 $P(A)=1-P(\overline{A})=1-P(\bigcup\limits_{i=1}^{n}\overline{A_i})$，且 $\overline{A_1},\cdots,\overline{A_n}$ 相互独立，故

$$P(A)=1-P(\overline{A_1})\cdots P(\overline{A_n})=1-0.4^n$$

为使不等式成立，必须且只需 $1-0.4^n\geqslant 0.99$。由此得

$$n\geqslant \lg 0.01/\lg 0.4=5.026$$

故至少需配置 6 门高射炮方能以 99% 的把握击中敌机。

例： 设 A，B，C 三事件相互独立，证明 $A-B$ 与 C 独立。

解： 因为

$$\begin{aligned}P((A-B)C)&=P(AC-BC)=P(AC)-P(ABC)\\&=P(A)P(C)-P(A)P(B)P(C)\\&=(P(A)-P(A)P(B))P(C)\\&=(P(A)-P(AB))P(C)=P(A-B)P(C).\end{aligned}$$

所以 $A-B$ 与 C 独立。 □

2.3 全概率公式和贝叶斯公式

2.3.1 全概率公式

完备事件组： 若 $\{B_n\}_{n\geqslant 1}\subset\mathscr{F}$ 满足两两互斥且 $\sum\limits_{n=1}^{\infty}B_n=\Omega$，则称 $\{B_n\}_{n\geqslant 1}$ 为完备事件组。

全概率公式： 假定 $\{B_n\}_{n\geqslant 1}$ 为完备事件组，则

$$P(A)=\sum_{n=1}^{\infty}P(B_n)P(A|B_n),\forall A\in\mathscr{F}$$

注意：在上式中，若 $P(B_n)=0$，则规定 $P(B_n)P(A|B_n)=0$。

例： 一保险公司相信人群可以分为 2 类：一类是容易出事故的；另一类是不容易出事故的。已知前者在一年内出事故的概率为 0.4，后者在一年内出事故的概率为 0.2。前者约占人群的 30%。今有一人前来投保，他在一年内出事故的可能性有多大?

解： 设 $A=$ “他在一年内出事故”，$B=$ “他是容易出事故的”，则 $B,\overline{B}$ 构成完备事件组，有

$$P(A)=P(B)P(A|B)+P(\overline{B})P(A|\overline{B})$$

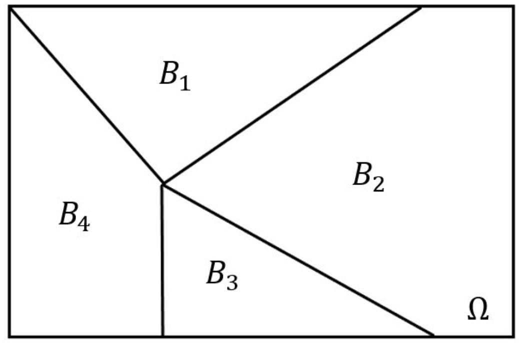

图 2.1: 完备事件组

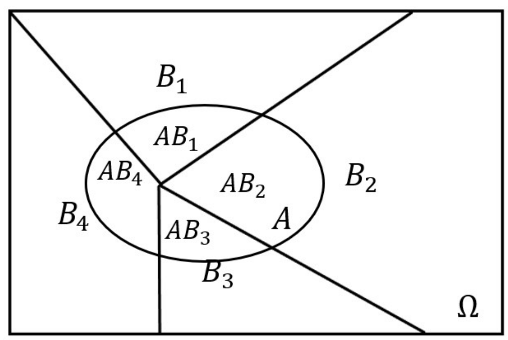

图 2.2: 全概率公式

由于 $P(B) = 0.3, P(A|B) = 0.4, P(\overline{B}) = 0.7, P(A|\overline{B}) = 0.2$，于是

$$P(A) = 0.3 \times 0.4 + 0.7 \times 0.2 = 0.26$$

□

例： 甲口袋有 1 个黑球，2 个白球，乙口袋有 3 个白球，每次从两口袋中任取一球，交换后放入另一口袋中，求交换 n 次之后，黑球仍然在甲口袋的概率。

设事件 A_i 为“第 i 次交换后黑球仍然在甲口袋中”，记 $p_i = P(A), i = 0, 1, 2, \cdots$，则有 $p_0 = 1$，且

$$P(A_{i+1} \mid A_i) = \frac{2}{3}, \quad P(A_{i+1} \mid A_i^c) = \frac{1}{3}$$

由全概率公式得

$$p_n = \frac{2}{3}p_{n-1} + \frac{1}{3}(1 - p_{n-1}) = \frac{1}{3}p_{n-1} + \frac{1}{3}, \quad n \geqslant 1$$

得到递推公式

$$p_n - \frac{1}{2} = \left(\frac{1}{3}\right)\left(p_{n-1} - \frac{1}{2}\right), \quad n \geqslant 1$$

将 $p_0=1$ 代入上式可得

$$p_n-\frac{1}{2}=\left(\frac{1}{3}\right)^n\left(\frac{1}{2}\right)$$

因此

$$p_n=\frac{1}{2}\left[1+\left(\frac{1}{3}\right)^n\right]$$

□

2.3.2 贝叶斯公式

贝叶斯公式： 假定 $\{B_n\}_{n\geqslant 1}$ 为完备事件组，$A\in\mathscr{F}$ 满足 $P(A)>0$，则

$$P(B_n|A)=\frac{P(B_n)P(A|B_n)}{\sum\limits_{n=1}^{\infty}P(B_n)P(A|B_n)}$$

例： 一项血液化验有 95% 的把握诊断某种疾病，但这项化验用于健康人也会有 1% 的“假阳性”结果（即如果一个健康人接受这项化验，化验结果误诊此病人患该疾病的概率为 1%）。假定该疾病的患者事实上只占总人口的 0.5%。若某人化验结果为阳性，则此人确实患有该疾病的概率是多少?

解： 令 A 表示“此人确实患该疾病”，B 表示“其化验结果为阳性”，则所求概率为

$$\begin{aligned}P(A|B)&=\frac{P(A)P(B|A)}{P(A)P(B|A)+P(\overline{A})P(B|\overline{A})}\\&=\frac{0.95\times 0.005}{0.95\times 0.005+0.01\times 0.995}\\&=\frac{95}{294}\approx 0.323\end{aligned}$$

□ **例：** 一架飞机失踪了，推测它等可能的坠落在 3 个区域。令 $\alpha_i(i=1,2,3)$ 表示飞机在第 i 个区域坠落但没有被发现的概率。已知对区域 1 的搜索没有发现飞机，求在此条件下，飞机坠落在第 $i(i=1,2,3)$ 个区域的条件概率。

解： 令 B_i 表示“飞机坠毁在第 i 个区域”，$i=1,2,3$，A 表示“在第 1 个区域没有搜索到飞机”，则

$$P(B_1|A)=\frac{P(B_1)P(A|B_1)}{\sum\limits_{i=1}^{3}P(B_i)P(A|B_i)}=\frac{\frac{\alpha_1}{3}}{\frac{\alpha_1}{3}+1\times\frac{1}{3}+1\times\frac{1}{3}}=\frac{\alpha_1}{\alpha_1+2}$$

对 $j=2,3$,

$$P(B_j|A)=\frac{P(B_j)P(A|B_j)}{\sum\limits_{i=1}^{3}P(B_i)P(A|B_i)}=\frac{\frac{1}{3}}{\frac{\alpha_1}{3}+1\times\frac{1}{3}+1\times\frac{1}{3}}=\frac{1}{\alpha_1+2}$$

□ □

随机游走： 考虑数轴上一质点，假定它只在整数点上运动。当前时刻它处于位置 a（整数），下一时刻（单位间隔时间）以概率 p 向正向，概率 $1-p$ 向负向运动一个单位，称这样的质点运动为随机游动，当 $p=q=\frac{1}{2}$ 时，称为对称随机游走。

（1）无限制随机游走：对随机游走，以 S_n 表示 n 时刻质点的位置，假定 $S_0=0$。我们计算经过 n 次运动后到达位置 k 的概率。

由于质点在 n 时刻位于 k，在 n 次游动中，质点向右移动次数 x 比向左运动 y 多 k 次：

$$x-y=k, \quad x+y=n$$

$$x=\frac{n+k}{2}, \quad y=\frac{n-k}{2}$$

为使 x 为整数，k 和 n 的奇偶性需要相同，即

$$P(S_n=k)=\begin{cases} C_n^{\frac{n+k}{2}} p^{\frac{n+k}{2}}(1-p)^{\frac{n-k}{2}}, & n,k\text{奇偶性相同} \\ 0, & n,k\text{奇偶性不同} \end{cases}$$

（2）两端带有吸收壁的随机游走：设 a，b 为正整数。假定质点初始位置为 a，在位置 0 和 $a+b$ 均有一个吸收壁，求质点被吸收的概率。

记 q_n 为质点初始位置是 n 而最终在 $a+b$ 被吸收的概率，显然，

$$q_0=0, \quad q_{a+b}=1$$

若质点某时刻位于 n，$n=1,\cdots,a+b-1$。则其在位置 $a+b$ 被吸收有两种可能：（1）运动到 $n-1$ 位置被 $a+b$ 吸收，（2）运动到 $n+1$ 位置被 $a+b$ 吸收，由全概率公式得

$$q_n=q_{n-1}q+q_{n+1}p, \quad n=1,\cdots,a+b-1$$

由于 $p+q=1$，上式可以写为

$$p(q_{n+1}-q_n)=q(q_n-q_{n-1}), \quad n=1,\cdots,a+b-1$$

记 $r=\frac{q}{p}$，则

$$q_{n+1}-q_n=r(q_n-q_{n-1}), \quad n=1,\cdots,a+b-1$$

可以分两种情况讨论：(i) 若 $r=1$，即 $p=q=\frac{1}{2}$。则

$$q_{n+1}-q_n=q_n-q_{n-1}=\cdots=q_1-q_0$$

$$q_{n+1}=q_0+(n+1)(q_1-q_0), \quad n=1,\cdots a+b-1$$

结合边值条件，有

$$q_n = \frac{n}{a+b}, n = 1, \cdots, a+b-1$$

(ii) 若 $r \neq 1$，即 $p \neq q$：

$$q_{n+1} - q_n = r(q_n - q_{n-1}) = \cdots = r^n(q_1 - q_0)$$

即

$$q_n - q_0 = \sum_{i=0}^{n-1}(q_{i+1} - q_i) = \sum_{i=0}^{n-1} r^i(q_1 - q_0) = \frac{1-r^n}{1-r}(q_1 - q_0), \quad n = 1, \cdots, a+b-1$$

结合边值条件，得

$$q_1 = \frac{1-r}{1-r^{a+b}}$$

则

$$q_n = \frac{1-r^n}{1-r^{a+b}}$$

3.1 随机变量

为了进一步研究随机现象，我们需要引入随机变量的概念。

定义：（随机变量的直观描述）如果条件 S 下的结果可以用某个变量 X 来描述，X 的值不能预先确定，而随着条件 S 的不同可能变化，但是对任何实数 c，事件 “X 取值不超过 c” 是有概率的，将这样一种变量 X 称为随机变量。

定义：（随机变量的数学描述）如果条件 S 下的所有可能结果组成了集合 $\Omega = \{\omega\}$，$X = X(\omega)$ 是在 Ω 上有定义的实值函数，而且对任何实数 c，事件 “$\{\omega : X(\omega) \leqslant c\}$” 是有概率的，将 X 称为随机变量。

例：（对应郑书例 1.2）盒中有 5 个球, 其中有 2 个白球, 3 个黑球. 从中任取 3 个球, 将其中所含的白球的数目记为 X.

建模: 将球编号, $1 \sim 3$ 表示黑球, 4,5 表示白球.

记摸到球的编号为 $\omega = (i, j, k)$, 其中 $1 \leqslant i < j < k \leqslant 5 . |\Omega| = C_5^3 = 10$.

其中满足 $X = 0$ 的 ω 有 $C_2^0 C_3^3 = 1$ 个;　满足 $X = 1$ 的 ω 有 $C_2^1 C_3^2 = 6$ 个;　满足 $X = 2$ 的 ω 有 $C_2^2 C_3^1 = 3$ 个.

设事件: $\{X = 1\} = \{\omega : X(\omega) = 1\}, \quad \{X \leqslant 1\} = \{\omega : X(\omega) \leqslant 1\}$.

将 $P(\{X = 1\})$ 简记为 $P(X = 1)$.

$$P(X = 1) = \frac{6}{10},\ P(X \leqslant 1) = \frac{7}{10}.$$

例：（对应郑书例 1.6）某公共汽车站每隔 10 min 会有一两某路公交车到达. 某乘客随机在任意时刻到达车站.

显然，他的候车时间 X (单位: min) 为随机变量. X 的取值范围 $0 \leqslant X \leqslant 10$。事件 $\{X \leqslant c\}$ 是有概率的，这是一种几何概型，我们会在后面给出计算过程，例如:

$$P(X \leqslant 3) = \frac{3}{10}, \quad P(2 \leqslant X \leqslant 6) = \frac{4}{10}.$$

3.2 离散型随机变量

定义： X 是离散型随机变量指: X 取有限个值 $x_1,\cdots,x_n$, 或可列无穷个值 $x_1,x_2,\cdots.X$ 的概率分布 (列) 指:

$$p_k = P\left(X = x_k\right), \quad k = 1,\cdots,n \text{ 或} k = 1,2,\cdots.$$

将 X 的可能值以及相应的概率列为表3.1。表3.1称为 X 的**概率分布表**，它能够清楚完整的表示 X

X	x_1	x_2	$\cdots$	x_k	$\cdots$
p	p_1	p_2	$\cdots$	p_k	$\cdots$

表 3.1: 概率分布表

的取值以及概率的分布情况。

定义： 设 X 的可能取值是 $x_1,x_2,\cdots$（有限个或者可列无穷个），则称

$$p_k = P(X = x_k) \quad (k = 1,2,\cdots)$$

为 X 的**概率分布**，这时也称为 X 的**概率函数**或者**概率分布律**

关于 $\{p_k\}$，有以下性质:

（1）$p_k \geqslant 0\ (k = 1,2,\cdots)$ （2）$\sum\limits_k p_k = 1$

回忆本讲例 1 的 X（抽到的白球数）它的概率分布表如表3.2所示:

X	0	1	2
p	0.1	0.6	0.3

表 3.2: X 的概率分布表

对离散型随机变量，有以下几种常见的概率分布:

3.2.1 两点分布（伯努利分布）

定义随机变量 X 的可能值是 0 和 1 且概率分布为:

$$P(X=1)=p, \quad P(X=0)=1-p.$$

称 X 服从**两点分布**（也称伯努利分布），记为 $X\sim B(1,p)$ (参数 $0\leqslant p\leqslant 1$)

我们定义示性函数 1_A：事件 A 发生则取 1; A 不发生则取 0 .

例:（对应郑书例 2.1）100 件产品中有 3 件次品. 从中任取一件.

设事件 $A=$ “取到合格品”，，随机变量 $X=1_A$，X 的可能取值为 0 和 1。取到每件产品的概率均等，概率分布为

$$P(X=1)=\frac{97}{100}, P(X=0)=\frac{3}{100}$$

X 服从参数 $p=0.97$ 的两点分布。

3.2.2 二项分布

设随机变量所有可能值为 $0,1,\cdots,n$，且

$$P(X=k)=C_n^k p^k(1-p)^{n-k}, k=0,1,\cdots,n$$

称 X 服从参数为 n,p 的二项分布，记作 $X\sim B(n,p)$(参数 $n\geqslant 1, 0\leqslant p\leqslant 1$)

二项分布有明显的实际背景，例如在单次实验中事件 A 发生的概率是 p，进行独立重复实验 n 次，记事件 A 发生的次数为 X，则 $X\sim B(n,p)$。

定理 2.1: 对于二项分布，分布列 $P(X=k)$ 的最大值点 k_0 如下:

若 $(n+1)p\notin\mathbb{Z}$, 则 $k_0=[(n+1)p]$;

若 $(n+1)p\in\mathbb{Z}$, 则 $k_0=(n+1)p$ 或 $(n+1)p-1$.

证明：显然

$$\frac{p_n(k+1)}{p_n(k)}=\frac{n-k}{k+1}\cdot\frac{p}{1-p}$$

由于 $\frac{n-k}{k+1}\cdot\frac{p}{1-p}>1$ 等价于 $k<(n+1)p-1$，于是有:

(a) 当 $k<(n+1)p-1$ 时，$p_n(k+1)>p_n(k)$

(b) 当 $k>(n+1)p-1$ 时，$p_n(k+1)<p_n(k)$

(c) 当 $k=(n+1)p-1$ 时，$p_n(k+1)=p_n(k)$

(i) 若 $(n+1)p \notin \mathbb{Z}$，设 $k_0 = [(n+1)p] < (n+1)p < k_0+1$，当 $k < m$ 时，$k \leqslant k_0 - 1 < (n+1)p - 1$，因此 $p_n(k) < p_n(k+1)$；当 $k \geqslant k_0$ 时，$k > (n+1)p - 1$，因此 $p_n(k) > p_n(k+1)$，所以 k_0 为最大值。

(ii) 若 $(n+1)p \in \mathbb{Z}$，设 $k_0 = (n+1)p$，有 $p_n(k_0) = p_n(k_0+1)$，进而利用性质（a）和性质（b）知 k_0 为最大值。 □

3.2.3 泊松分布

定义： 设随机变量 X 的所有可能取值是全体非负整数，且

$$P(X=k) = \frac{\lambda^k}{k!}e^{-\lambda}, \quad k = 0, 1, 2, \cdots.$$

则称 X 服从参数为 λ 的泊松分布，记为 $X \sim \mathscr{P}(\lambda)$(参数: $\lambda > 0$) 。

泊松分布常见于生物学，物理学，工业的应用中，例如电话交换台收到的电话呼唤次数，放射性物质在一定时间内放出的粒子数。

定理： 泊松分布的分布列最大值点 $k_0 = [\lambda]$。

证明：注意到 $p_{k+1} = \frac{\lambda}{k+1}p_k$，故由分布函数知

若 $k+1 \leqslant \lambda$，则 $p_{k+1} \geqslant p_k$

若 $k+1 \geqslant \lambda$，则 $p_{k+1} \leqslant p_k$

因此当 $k_0 = [\lambda]$ 时，分布列取最大值。 □

例： 已知某商场一天来的顾客服从参数为 λ 的泊松分布，而每个来商场的顾客购物概率为 p，证明此商场一天内购物的顾客数服从参数为 λp 的泊松分布。

解： 用 Y 表示商场内一天购物的顾客数，则由全概率公式知，对任意正整数 k 有

$$P(Y=k) = \sum_{i=k}^{\infty} P(X=i)P(Y=k \mid X=i) = \sum_{i=k}^{\infty} \frac{\lambda^i e^{-\lambda}}{i!} C_i^k p^k (1-p)^{i-k}$$

$$= \frac{(\lambda p)^k}{k!} e^{-\lambda} \sum_{i=k}^{\infty} \frac{[\lambda(1-p)]^{i-k}}{(i-k)!} = \frac{(\lambda p)^k}{k!} e^{-\lambda} e^{\lambda(1-p)} = \frac{(\lambda p)^k}{k!} e^{-\lambda p}$$

□

3.2.4 超几何分布

定义： 若随机变量 X 的概率分布满足:

$$P(X=k)=\frac{C_D^k C_{N-D}^{n-k}}{C_N^n},\quad k=0,1,\cdots,n.$$

则称 X 服从超几何分布，记为 $X\sim H(N,D,n)$ （参数 N,D,n 满足 $N\geqslant D\geqslant 0$）

设一批产品有 N 个产品, D 个次品, 任取 n 个, 抽到的次品数为 X。如果进行放回抽样则 X 服从二项分布，如果进行不放回抽样则 X 服从超几何分布。

定理 2.3： 给定 n. 当 $N\to\infty,\frac{D}{N}\to p$ 时,

$$\lim_{N\to\infty}\frac{C_D^k C_{N-D}^{n-k}}{C_N^n}=C_n^k p^k(1-p)^{n-k},\quad k\geqslant 0$$

证明：由于 $0<p<1$，当 N 充分大时，$n<D<N$，且 n 是固定的，易知

$$\begin{aligned}\frac{C_D^k C_{N-D}^{n-k}}{C_N^n}&=\frac{D!}{k!(D-k)!}\cdot\frac{(N-D)!}{(n-k)!(N-D-n+k)!}\cdot\frac{n!(N-n)!}{N!}\\&=\frac{n!}{k!(n-k)!}\cdot\frac{D(D-1)\cdots(D-k+1)}{N^k}\\&\quad\cdot\frac{(N-D)(N-D-1)\cdots(N-D-n+k+1)}{N^{n-k}}\\&\quad\cdot\frac{N^n}{N(N-1)\cdots(N-n+1)}\\&=C_n^k\Big(\prod_{i=1}^{k}\frac{D-i+1}{N}\Big)\Big(\prod_{i=1}^{n-k}\frac{N-D-i+1}{N}\Big)\Big(\prod_{i=1}^{n}\frac{N}{N-i+1}\Big)\\&\to C_n^k p^k(1-p)^{n-k}\quad(N\to\infty)\end{aligned}$$

□

该定理的直观解释是，如果一批产品的总量 N 很大，其中次品占比为 p，则从整批产品随机抽取 n 个，抽到次品的个数 k 近似服从参数为 p，n 的二项分布。

3.2.5 几何分布

定义： 若随机变量 X 的所有可能值是全体整数，且概率分布满足:

$$P(X=k)=(1-p)^{k-1}p,\quad k=1,2,\cdots.$$

则称 X 服从几何分布，记为 $X\sim G(p)$, 参数 $0<p<1$ 。

例如，某个射手向目标连续射击，如果他单次射中目标的概率为 p，则他首次射中目标所需要的射击次数 X 是一个随机变量，且满足几何分布。

几何分布具备无记忆性: $P(X-n=k \mid X>n)=P(X=k)$.

例： 设 X 是只取自然数的离散随机变量，若 X 的分布具有无记忆性，证明 X 的分布一定为几何分布。

证明： 由无记忆性知

$$P(X>n+m|X>m)=\frac{P(X>n+m)}{P(X>m)}=P(X>n),$$

将 n 换为 $n-1$ 仍有

$$P(X>n+m-1)=P(X>n-1)P(X>m).$$

两式相减有

$$P(X=n+m)=P(X=n)P(X>m).$$

设 $P(X=1)=p$，若取 $n=m=1$ 有

$$P(X=2)=p(1-p).$$

若取 $n=2$，$m=1$ 则有

$$P(X=3)=P(X=2)P(X>1)=p(1-p)^2.$$

若令 $P(X=k)=p(1-p)^{k-1}$，则用数学归纳法得

$$P(X=k+1)=P(X=k)P(X>1)=p(1-p)^k, \quad k=0,1,\cdots.$$

这表明 X 的分布为几何分布。 $\square$

3.2.6 离散均匀分布

定义： 若随机变量 X 的概率分布满足:

$$P(X=k)=\frac{1}{N}, \quad k=1,\cdots,N.$$

则称 X 服从离散均匀分布。

3.3 连续随机变量

定义: 连续型随机变量指: 存在 $p(x)$ 使得

$$P(a \leqslant X \leqslant b) = \int_a^b p(x)dx, \quad \forall a < b.$$

称 $p(\cdot)$ 为 X 的概率密度 (函数), 也记为 $p_X(\cdot)$.

连续随机变量有以下性质:

(1) 非负: $p(x) \geqslant 0$

(2) 规范: $\int_{-\infty}^{\infty} p(x)dx = 1$

(3) $P(X = x) = 0$ 在任意一点选中的概率都为 0.

(4) $p(\cdot)$ 在 x 连续, 即 $P(X \in [x, x + \Delta x]) = p(x)\Delta x + o(\Delta x)$,

以下是常见的连续随机变量:

3.3.1 均匀分布

定义: 如果随机变量 X 的分布密度为:

$$p(x) = \begin{cases} \frac{1}{b-a}; & \text{若} a \leqslant x \leqslant b; \\ 0, & \text{其他}. \end{cases}$$

则称 X 服从区间 $[a, b]$ (或 (a, b)) 上的均匀分布, 记为 $X \sim U(a, b)$ (参数 $a < b$) :

均匀分布的分布函数也可以写为 $p(x) = \frac{1}{b-a} 1_{\{a \leqslant x \leqslant b\}}$.

例如, 某公共汽车站每隔 10 分钟会有一班公交车到达, 一位搭乘该车的乘客在任意时刻到达车站是等可能的, 则他的候车时间 X 是一个随机变量, 且满足 $[0, 10]$ 上的均匀分布。

3.3.2 指数分布

定义: 如果随机变量 X 的分布密度为:

$$p(x) = \lambda e^{-\lambda x}, \quad x > 0.$$

则称 X 服从参数为 λ 的指数分布, 记为 $X \sim \mathrm{Exp}(\lambda)$(参数 $\lambda > 0$)

若 X 服从参数为 λ 的指数分布，则对任何 $0 \leqslant a < b$ 有：

$$P(a < X < b) = \lambda \int_a^b e^{-\lambda x} dx = e^{-\lambda a} - e^{-\lambda b}$$

$$P(X > a) = e^{-\lambda a}$$

定理： (无记忆性): $P(X - s > t \mid X > s) = e^{-\lambda t}, \forall t, s \geqslant 0.$

不难看出，$P(X - s > t \mid X > s) = \frac{P(X-s>t)}{P(X>s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda t}} = e^{-\lambda t} = P(X > t)$

注意到，无记忆性是指数分布独有的，即设 X 是非负的随机变量，$P(X - s > t \mid X > s) = P(X > s)$ 对 $\forall t, s \geqslant 0$ 恒成立的充分必要条件是 X 服从指数分布。

证明：之前已经证明了充分性，现只需证明必要性：设 X 是非负随机变量满足 $P(X - s > t \mid X > s) = e^{-\lambda t}$，则

$$P(X > s) > 0, \quad P(X > s + t) = P(X > s)P(X > t)$$

令 $f(u) = P(X > u)$，则 $f(s + t) = f(s)f(t)$

于是 $f(1) = f(\frac{1}{n} \times n) = (f(\frac{1}{n}))^n$

从而 $f(\frac{m}{n}) = f(\frac{1}{n} \times m) = (f(\frac{1}{n}))^m = (f(1))^{\frac{m}{n}}$

故对任意正有理数 r，有 $f(r) = (f(1))^r$。由于 $0 < f(1) < 1$ 且 $f(u)$ 是关于 u 的减函数，因此对任意 $u \geqslant 0$，有 $f(u) = (f(1))^u$。

令 $\lambda = -\ln f(1)$，则 $f(u) = e^{-\lambda u}$，即

$$P(X > u) = e^{-\lambda u} = \int_{+\infty}^{u} e^{-\lambda x} dx$$

$$P(a < X < b) = \int_a^b \lambda e^{-\lambda x} dx \quad (0 \leqslant a < b)$$

说明 X 服从指数分布。 □

3.3.3 正态分布

定义： 如果随机变量 X 的分布密度为：

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$$

则称 X 服从参数为 μ，σ 的正态分布，记为 $X \sim N\left(\mu, \sigma^2\right)$ (参数 $\mu \in \mathbb{R}, \sigma > 0$)

参数 $\mu=0$，$\sigma^2=1$ 时的正态分布称为标准正态分布 $N(0,1)$ ，分布密度是:

$$p(x)=\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}$$

归一性： $\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}dx=1$：

设 $\phi(x)=\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}$, 将积分的平方写为二重积分:

$$\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}dx\times\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{y^2}{2}}dy=\frac{1}{2\pi}\iint_{\mathbb{R}^2}e^{-\frac{x^2+y^2}{2}}dxdy.$$

做极坐标变换:

$$x=r\cos\theta,y=r\sin\theta\Rightarrow\begin{vmatrix}\frac{\partial x}{\partial r}&\frac{\partial y}{\partial r}\\\frac{\partial x}{\partial\theta}&\frac{\partial y}{\partial\theta}\end{vmatrix}=r.$$

因此，二重积分可以写为

$$\frac{1}{2\pi}\int_0^{2\pi}\left(\int_0^{\infty}e^{-\frac{r^2}{2}}rdr\right)d\theta=\int_0^{\infty}e^{-R}dR=1$$

对于其他正态分布的密度函数 $p(x)=\frac{1}{\sqrt{2\pi\sigma^2}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ ：令 $y=\frac{x-\mu}{\sigma}$, 则

$$\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}\cdot\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx=\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{y^2}{2}}dy=1.$$

定义函数 Φ :

$$\Phi(x)=\int_{-\infty}^{x}\phi(x)dx.$$

容易看出 $\Phi(-x)=1-\Phi(x)$.

定理： 令 $x^*=\frac{x-\mu}{\sigma}$, 则

$$P(a<X<b)=\int_a^b\frac{1}{\sigma}\phi\left(\frac{x-\mu}{\sigma}\right)dx=\Phi\left(\frac{b-\mu}{\sigma}\right)-\Phi\left(\frac{a-\mu}{\sigma}\right).$$

推论： 设随机变量 $X\sim N(\mu,\sigma^2)$，则对一切正数 k，有

$$P(\mu-k\sigma<X<\mu+k\sigma)=\Phi(k)-\Phi(-k)=2\Phi(k)-1$$

例如查表得 $\Phi(3)=0.9987$, 因此

$$P(\mu-3\sigma<X<\mu+3\sigma)=\Phi(3)-\Phi(-3)=0.9974$$

该结果说明正态随机变量 X 的取值基本落在区间 $(\mu-3\sigma,\mu+3\sigma)$ 内。

3.3.4 伽马分布

定义： 如果随机变量 X 的分布密度为:

$$p(x)=\frac{\beta^{\alpha}}{\Gamma(\alpha)}x^{\alpha-1}e^{-\beta x},\quad x>0.$$

则称随机变量 X 服从伽马分布，记为 $X\sim\Gamma(\alpha,\beta)$(参数 $\alpha,\beta>0$)

其中，称 $\Gamma(\alpha)=\int_0^\infty y^{\alpha-1}e^{-y}dy$ 为 Γ 函数。

若 $\Gamma(\alpha)$ 为 Γ 函数，则函数具备以下性质:

（1）$\Gamma(\alpha+1)=\alpha\Gamma(\alpha)$

证明:

$$\int_0^\infty y^{\alpha}e^{-y}dy=-\left.y^{\alpha}e^{-y}\right|_0^\infty+\int_0^\infty \alpha y^{\alpha-1}e^{-y}dy=\alpha\int_0^\infty y^{\alpha-1}e^{-y}dy$$

□

（2）$\Gamma(1)=1;\Gamma\left(\frac{1}{2}\right)=\sqrt{\pi}$

证明:

$$\Gamma\left(\frac{1}{2}\right)=\int_0^\infty\frac{1}{\sqrt{y}}e^{-y}dy=\sqrt{2}\int_0^\infty e^{-\frac{x^2}{2}}dx=\sqrt{\pi}.$$

□

（3）$\alpha=1$ 时就是指数分布参数为 β.

3.4 随机变量的严格定义

定义： 假设 $(\Omega,\mathscr{F},P)$ 是概率空间, $X:\Omega\to\mathbb{R}$ 满足:

$$\text{对任意 } x\in\mathbb{R} \text{ 都有 } \{X\leqslant x\}\in\mathscr{F},$$

则称 X 是一个随机变量.

定义： 令 $F(x)=P(X\leqslant x),x\in\mathbb{R}$. 称 F 为随机变量 X 的分布函数, 也记为 F_X.

定理: 分布函数 $F=F_X$ 的三条性质:

(1) 单调性: 若 $x\leqslant y$, 则 $F(x)\leqslant F(y)$.

(2) 规范性: $\lim_{x\to-\infty}F(x)=0;\lim_{x\to\infty}F(x)=1$.

(3) 右连续性: $\lim_{y\to x+}F(y)=F(x)$.

- 离散型: $P\left(X=x_i\right)=p_i$. $\quad x_i$ 为 F_X 的跳点, p_i 为跳跃幅度.
- 连续型: $F_X(x)=\int_{-\infty}^x p(z)dz$, 且

$$p(x)=F_X'(x).$$

反过来, 若 F_X “几乎”连续可导, 则为连续型 (定理 4.3, 4.4).

- 尾分布函数: $G(x)=P(X>x)=1-F(x)$.

  连续型: $p(x)=-G'(x)$.
- 例. $X\sim\operatorname{Exp}(\lambda)$.

$$\begin{aligned}G(x)&=e^{-\lambda x},\quad \forall x>0,\\ \Rightarrow G'(x)&=-\lambda G(x).\quad \lambda: \text{速率}.\end{aligned}$$

- 由 $F_X(x)$ 可求出 $P(X\in B),\forall B$.
- 若 $F_X=F_Y$, 则称 X 与 Y 同分布, 记为 $X\overset{d}{=}Y$.
- $X=Y$, 即 $P(X=Y)=1$, 则 $F_X=F_Y$. 反之不然.

4.1 随机变量的函数

随机变量的函数： 设 $y = g(x)$ 是定义在 $\mathbb{R}$ 上的一个函数，X 是一个随机变量，那么 $Y = g(X)$ 作为 X 的函数，同样也是一个随机变量。

在实际问题中，如果已知随机变量 X 的分布，我们可以求出另一个随机变量 $Y = g(X)$ 的分布。我们将从离散和连续两种场合分别讨论随机变量函数的分布。

注：为了让 Y 是数学意义上严格定义的随机变量，必须对函数 $f(x)$ 有所假定才能使得 $\{Y \leqslant c\}$ 是有概率的事件，通常假定 $f(x)$ 是 Borel 函数，即对于任何实数 c，$\{x : f(x) \leqslant c\}$ 是 Borel 集，有以下定理：

定理： 设 $X = X(\omega)$ 是概率空间 $(\Omega, \mathscr{F}, P)$ 上的随机变量，则对任何 Borel 函数 $f(x)$，$Y = f(X(\omega))$ 也是这个概率空间上的随机变量。

证明： 给定任意实数 c，令

$$B = \{x : f(x) \leqslant c\}$$

则 $\{\omega : Y \leqslant c\} = \{\omega : f(X(\omega)) \leqslant c\} = \{\omega : X(\omega) \in B\}$，由于 B 是 Borel 集，则由定理 [?] 知 $\{\omega : X(\omega) \in B\} \in \mathscr{F}$，所以 $\{Y \leqslant c\} \in \mathscr{F}$，$Y$ 是随机变量。

我们遇到的随机函数一般都是 Borel 函数，所以 $Y = X(\omega)$ 一般都是随机变量。

4.1.1 离散随机变量函数的分布

设 X 是离散随机变量，X 的分布列为：则 $Y = g(X)$ 也是一个离散随机变量，此时 Y 的分布列可

X	x_1	x_2	$\cdots$	x_k	$\cdots$
p	p_{x_1}	p_{x_2}	$\cdots$	p_{x_k}	$\cdots$

以简单表示为：若 $p_{x_1}, p_{x_2}, \cdots, p_{x_k}, \cdots$ 中有某些值相等时，把那些相等的值分别合并，并将对应概

Y	$g(x_1)$	$g(x_2)$	$\cdots$	$g(x_k)$	$\cdots$
p	p_{x_1}	p_{x_2}	$\cdots$	p_{x_k}	$\cdots$

率相加。

例： 已知随机变量 X 的分布如下，求 $Y = X^2 + X$ 的分布列。

X	-2	-1	0	1	2
p	0.2	0.1	0.1	0.3	0.3

解： $Y = X^2 + X$ 的分布列为

Y	2	0	0	2	6
p	0.2	0.1	0.1	0.3	0.3

合并得到

Y	0	2	6
p	0.2	0.5	0.3

定理：（离散卷积公式）若 ξ, η 是相互独立的随机变量，且取非负整数值，分布列分别为 $\{k; a_k\}$ 和 $\{k; b_k\}$。则随机变量 $\zeta = \xi + \eta$ 的分布列为 $P(\zeta = k) = \sum\limits_{i=0}^{k} a_i b_{k-i}$，称为**卷积公式**。

证明：注意到 $P(\zeta = k) = P(\xi = 0, \eta = k) + P(\xi = 1, \eta = k-1) + \cdots + P(\xi = k, \eta = 0)$。其中 $= P(\xi = i, \eta = k-i) = a_i b_{k-i}$，因此 $P(\zeta = k) = \sum\limits_{i=0}^{k} a_i b_{k-i}$。 □

例：（泊松分布可加性）设 $X \sim \mathscr{P}(\lambda_1), Y \sim \mathscr{P}(\lambda_2)$，且 X, Y 相互独立，证明 $X + Y \sim \mathscr{P}(\lambda_1 + \lambda_2)$。

解： 泊松分布函数 $P(X = k) = \frac{\lambda_1^k}{k!} e^{-\lambda_1}$，$P(Y = k) = \frac{\lambda_2^k}{k!} e^{-\lambda_2}$，由卷积公式，

$$P(X + Y = k) = \sum_{i=0}^{k} P(X = i) P(X = k - i) = \sum_{i=0}^{k} \frac{\lambda_1^i}{i!} e^{-\lambda_1} \frac{\lambda_2^{k-i}}{(k-i)!} e^{-\lambda_2}$$

由二项式展开，上式整理为

$$\frac{e^{-(\lambda_1+\lambda_2)}}{k!} \sum_{i=0}^{k} \frac{\lambda_1^i \lambda_2^{k-i} k!}{i!(k-i)!} = \frac{e^{-(\lambda_1+\lambda_2)}}{k!} (\lambda_1 + \lambda_2)^k$$

□

4.1.2 连续随机变量函数的分布

对于连续随机变量，一般先求分布函数，如果能写出分布密度就写出分布密度。

例： 设 $X \sim N(\mu, \sigma^2)$，试求 $Y = \frac{1}{\sigma}(X - \mu)$ 的概率分布。

解： 对任何实数 y，由于 $\{Y \leqslant y\} = \{X \leqslant \sigma y + \mu\}$，于是

$$P(Y \leqslant y) = P(X \leqslant \sigma y + \mu)$$

$$= \int_{-\infty}^{\mu+\sigma y} \frac{1}{\sqrt{2\pi}\sigma} \exp\{-\frac{1}{2\sigma^2}(x-\mu)^2\} dx$$

变量替换 $\frac{x-\mu}{\sigma} = t$ 得

$$P(Y \leqslant y) = \int_{-\infty}^{y} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dx$$

说明 $Y \sim N(0,1)$ □

定理： 设随机变量 X 有分布密度 $p(x)$，且在区间 $(a,b)(-\infty \leqslant a < b \leqslant +\infty)$ 上满足 $P(a < X < b) = 1$。又 $Y = f(X)$，其中 $f(x)$ 是 (a,b) 上严格单调的连续函数，$g(y)$ 是 $f(x)$ 的反函数，且 $g'(y)$ 处处存在，令

$$q(y) = \begin{cases} p(g(y))|g'(y)|, & y \in (\alpha, \beta), \\ 0, & \text{其他} \end{cases}$$

其中 (α, β) 是反函数 $g(y)$ 的存在区间，即 $\alpha = \min\{A, B\}, \beta = \max\{A, B\}, A \triangleq \lim_{x\to a+} f(x), \quad B \triangleq \lim_{x\to b-} f(x)$，则 $q(y)$ 是 Y 的分布密度。

证明： 设 $f(x)$ 是严格增函数（当 $f(x)$ 是严格减函数时，可以类似的证明）。那么对于 $u \in (\alpha, \beta)$ 有

$$P(Y \leqslant u) = P(f(X) \leqslant u) = P(X \leqslant g(u))$$
$$= \int_{-\infty}^{g(u)} p(x)dx = \int_{a}^{g(u)} p(x)dx$$

做变量替换 $x = g(y)$，则

$$P(Y \leqslant u) = \int_{a}^{u} p(g(y)) \mid g'(y) \mid dy = \int_{-\infty}^{u} q(y)dy$$

当 $u \leqslant \alpha$ 时，

$$P(Y \leqslant u) = P(X \leqslant a) = 0 = \int_{-\infty}^{u} q(y)dy$$

当 $u \geqslant \beta$ 时，

$$P(Y \leqslant u) = P(X \leqslant b) = 1 = \int_{a}^{b} p(x)dx$$

$$\int_{\alpha}^{\beta} p(g(y)) \mid g'(y) \mid dy = \int_{-\infty}^{u} q(y)dy$$

综上，对于一切实数 u，有 $P(Y \leqslant u) = \int_{-\infty}^{u} q(y)dy$，故 $g(y)$ 是 $Y = f(X)$ 的密度函数。 □

例：（对应郑书例 5.3）研究水箱内某种微生物的增长情况。设在时 0 微生物的总数是 $v(v > 0)$，增长率是 X，在时刻 t 微生物总数是 $Y = ve^{Xt}(t > 0)$。若 X 有分布密度

$$p(x) = \begin{cases} 3(1-x)^2, & 0 < x < 1, \\ 0, & \text{其他,} \end{cases}$$

试求 Y 的概率分布。

解： 反函数的求解需要注意函数和区间的变化。

令 $f(x)=ve^{Xt}(0<x<1)$，则其反函数为：

$$g(y)=\frac{1}{t}\ln\frac{y}{v}\quad(v<y<ve^t)$$

易知 $g'(y)=\frac{1}{ty}$，根据定理知，$Y=ve^{xt}$ 的分布密度是：

$$q(y)=\begin{cases}3(1-\frac{1}{t}\ln\frac{y}{v})^2\frac{1}{ty}, & v<y<ve^t,\\ 0, & \text{其他},\end{cases}$$

□

例：（对应郑书例 5.4，对数正态分布）设 X 是只取正值的随机变量，使得 $Y=\ln X$ 服从正态分布 $N(\mu,\sigma^2)$，试求出 X 的分布函数和分布密度。

解： 对任何 $x>0$，有

$$\begin{aligned}F_X(x)&=P(X\leqslant x)=P(\ln X\leqslant\ln x)=P(Y\leqslant\ln x)\\&=\int_{-\infty}^{\ln x}\frac{1}{\sqrt{2\pi}\sigma}\exp\left\{-\frac{1}{2\sigma^2}(y-\mu)^2\right\}dy\end{aligned}$$

做变量替换 $y=\ln u$，得

$$F_X(x)=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}\sigma u}\exp\left\{-\frac{1}{2\sigma^2}(\ln u-\mu)^2\right\}du$$

当 $x\leqslant 00$ 时，称变量 X 服从对数正态分布。不难看出，X 的分布密度 $p(u)$ 为：当 $u\leqslant 0$ 时，$p(u)=0$，当 $u>0$ 时，$p(u)$ 是上式中的被积函数。 □

例： 设 $\theta\sim U(-\frac{\pi}{2},\frac{\pi}{2})$，$\psi=tan\theta$，求 ψ 的密度函数。

解： 设 $\psi=tan\theta$ 的反函数为 $g(y)$，则 $g(y)=\arctan y$。由定理得 $p_\psi(y)=p_{U(-\frac{\pi}{2},\frac{\pi}{2})}(g(y))g'(y)=p_{U(-\frac{\pi}{2},\frac{\pi}{2})}(\arctan y)\frac{1}{1+y^2}=\frac{1}{\pi(1+y^2)}$，$y\in\mathbb{R}$，称该变量 ψ 符合 **Cauchy 分布**。 □

4.2 随机变量的反函数

随机变量的反函数： 设 $F(x)$ 是任何分布函数（即 $F(x)$ 非减，右连续，且 $\lim_{x\to-\infty}F(x)=0$，$\lim_{x\to+\infty}F(x)=1$），令

$$F^{-1}(p)\triangleq\min\{x:F(x)\geqslant p\}\quad(0<p<1)$$

则称 $F^{-1}(p)$ 是 $F(x)$ 的**广义反函数**。

注意，$F(x)$ 是右连续增函数，满足不等式 $F(x)\geqslant p$ 的 x 中必有最小者，当 $F(x)$ 是严格增的连续函数时，$F^{-1}(p)$ 正好是方程 $F(x)=p$ 的唯一根，此时 $F^{-1}(p)$ 是 $F(x)$ 的普通反函数。

引理： $F^{-1}(p)(0<p<1)$ 有如下性质：

（1）$F^{-1}(p)$ 是 p 的增函数。

（2）$F(F^{-1}(p))\geqslant p$，若 $F(x)$ 在点 $x=F^{-1}(p)$ 处连续，则

$$F(F^{-1}(p))=p.$$

（3）$F^{-1}(p)\leqslant x$ 的充分必要条件是 $p\leqslant F(x)$。

证明：（2）由于 $F(F^{-1}(p)+\varepsilon)\geqslant p\quad(\forall\varepsilon>0)$，令 $\varepsilon\to0$，利用 $F(x)$ 的右连续性知 $F(F^{-1}(p))\geqslant p$。若 $F(x)$ 在点 $F^{-1}(p)$ 处连续，从 $F(F^{-1}(p)-\varepsilon)<p\quad(\varepsilon>0)$ 推知 $F(F^{-1}(p))=\lim_{\varepsilon\to0}F(F^{-1}(p)-\varepsilon)\leqslant p$，从而 $F(F^{-1}(p))=p$。

(3) 若 $F(x)\geqslant p$，从非减性质知 $x\geqslant F^{-1}(p)$；反之若 $x\geqslant F^{-1}(p)$，则 $F(x)\geqslant F(F^{-1}(p))\geqslant p$，故性质（3）成立。 □

定理： 设 $F(x)$ 是任何分布函数，若 U 是服从区间 $[0,1]$ 上的均匀分布的随机变量，且

$$X=F^{-1}(U)$$

则 X 的分布函数恰好是 $F(x)$。

证明： 对任何 $y\in(0,1)$，从性质（3）知 $x\geqslant F^{-1}(y)$ 的充分必要条件是 $F(x)\geqslant y$，于是

$$P(X\leqslant x)=P(F^{-1}(U)\leqslant x)=P(U\leqslant F(x))=F(x).$$

这表明 X 的分布函数是 $F(x)$。 □

5.1 随机变量的数学期望

实际问题的概率分布比较难以确定，有时只需掌握随机变量的数学特征就足够了。随机变量的数学期望 (expectation) 的含义是，随机变量平均取值 (mean) 的大小。

- X 的大量独立观测值 (记为 $a_1, a_2, \cdots, a_n$) 的算术平均，当样本数无穷大时，算术平均收敛于期望值:

$$\bar{a} = \frac{1}{n}\left(a_1 + \cdots + a_n\right).$$

- X 的所有可能值的加权平均 (总和).

5.1.1 离散型随机变量的数学期望

离散型随机变量的数学期望： 假设 X 是离散型随机变量, 分布列为

$$P\left(X = x_k\right) = p_k, \quad k = 1, \cdots, n \text{ 或} k = 1, 2, \cdots.$$

其中 X 的可能值是 $x_1, x_2, \cdots$，如果 $\sum_k \left|x_k\right| p_k < \infty$, 那么, 称 X 的期望存在, 称 $\sum_k x_k p_k$ 为 X 的数学期望, 记为 EX.

注意，级数 $\sum_k \left|x_k\right| p_k$ 收敛可以保证和数 $\sum_k x_k p_k$ 与加项的先后次序无关。更一般的假定是级数 $\sum_k x_k^+ p_k$ 和 $\sum_k x_k^- p_k$ 中至少一个收敛（这里 $x_k^+ = \max\{x_k, 0\}$，$x_k^- = \max\{-x_k, 0\}$）这时和数 $\sum_k x_k p_k$ 与加项的先后次序无关。

注意到 $E(X)$ 完全由 X 的概率分布确定，因此 $E(X)$ 也称为相应概率分布的期望，下面计算几个常见的概率分布的期望:

（1）两点分布

设随机变量 X 服从两点分布，$P(X=1) = p, P(X=0) = 1-p$. 则,

$$E(X) = 1 \cdot p + 0 \cdot (1-p) = p.$$

（2）二项分布

设随机变量 X 服从二项分布：$P(X=k) = C_n^k p^k q^{n-k} := b(n;k), k = 0, 1, \cdots, n, (q = 1-p)$.

对于 $\forall 1 \leqslant k \leqslant n$,

$$
\begin{aligned}
k \cdot b(n;k) = k \cdot \frac{n!}{k!(n-k)!} p^k q^{n-k} &= \frac{n!}{(k-1)!(n-k)!} p^k q^{n-k} \\
&= \frac{n \cdot (n-1)!}{(k-1)!(n-k)!} p \cdot p^{k-1} q^{n-k} = np \cdot b(n-1;k-1)
\end{aligned}
$$

因此,

$$
\begin{aligned}
E(X) = \sum_{k=0}^{n} k \cdot b(n;k) &= \sum_{k=1}^{n} np \cdot b(n-1;k-1) \\
&= np \sum_{\ell=0}^{n-1} b(n-1,\ell) = np.
\end{aligned}
$$

（3）泊松分布

设随机变量 X 服从泊松分布:

$$
P(X=k) = \frac{\lambda^k}{k!} e^{-\lambda} =: p_k, \quad k = 0,1,2,\cdots.
$$

则对于 $\forall k \geqslant 1$,

$$
x_k p_k = k \frac{\lambda^k}{k!} e^{-\lambda} = \lambda \frac{\lambda^{k-1}}{(k-1)!} e^{-\lambda} = \lambda p_{k-1}.
$$

因此,

$$
E(X) = \sum_{k=0}^{\infty} k p_k = \sum_{k=1}^{\infty} \lambda p_{k-1} = \lambda \sum_{\ell=0}^{\infty} p_\ell = \lambda.
$$

（4）几何分布

设随机变量 X 满足几何分布，即

$$
P(X=k) = q^{k-1} p =: p_k, \quad k = 1,2,\cdots,(q=1-p).
$$

直接计算期望:

$$
E(X) = \sum_{k=1}^{\infty} k p_k = \frac{1}{p}.
$$

（5）离散均匀分布

设随机变量 X 的可能值是 $1,\cdots,N$，且

$$
P(X=k) = \frac{1}{N} \quad (k=1,\cdots,N).
$$

直接计算

$$
E(X) = \sum_{k=1}^{N} k P(X=k) = \frac{N+1}{2}.
$$

（6）超几何分布

设随机变量 X 满足超几何分布，即

$$P(X=k)=\frac{C_D^k C_{N-D}^{n-k}}{C_N^n},\quad k=0,1,\cdots,n.$$

记 $h(N,D,n;k)=A_1\cdot A_2\cdot A_3$

$$=\frac{D!}{k!(D-k)!}\cdot\frac{(N-D)!}{(n-k)!(N-D-(n-k))!}\cdot\frac{n!(N-n)!}{N!}.$$

记 $x'=x-1$. 则, $\forall 1\leqslant k\leqslant n$,

$$k\cdot A_1=\frac{D!}{(k-1)!(D-k)!}=D\times\frac{D'!}{k'!\,(D'-k')!}.$$

进一步,

$$A_2=\frac{(N'-D')!}{(n'-k')!\,(N'-D'-(n'-k'))!},$$
$$A_3=\frac{n\cdot n'!\,(N'-n')!}{N\cdot N'!}=\frac{n}{N}\times\frac{n'!\,(N'-n')!}{N'!}.$$

记 $x'=x-1$. 则 $\forall 1\leqslant k\leqslant n$,

$$k\cdot h(N,D,n;k)=\frac{nD}{N}\times h\left(N',D',n';k'\right).$$

因此,

$$E(X)=\sum_{k=1}^{n}k\cdot h(N,D,n;k)=\frac{nD}{N}\sum_{k'=0}^{n'}h\left(N',D',n';k'\right)=\frac{nD}{N}$$

对于该期望，当 $D=1$ 时, 退化为伯努利分布, $E(X)=p=\frac{D}{N}$.

当 $D\geqslant 2$ 时, 不放回抽样, 仍有 $E(X)=np$.

5.1.2 一般随机变量的数学期望

若 X 为任意随机变量. 做如下近似: 对于 $\forall n\in\mathbb{Z}$,

$$\text{当} n\varepsilon<X\leqslant(n+1)\varepsilon \text{ 时, 令} X^*=n\varepsilon. \tag{5.1.1}$$

该假设的直观含义是: $X^*\leqslant X<X^*+\varepsilon$, 因此 $EX^*\leqslant EX<EX^*+\varepsilon$.

一般随机变量的数学期望： 若 EX^* 存在且当 $\varepsilon\to 0$ 时有极限, 则称 X 的期望存在, 且称该极限为 X 的期望, 记为 $E(X)$。

对离散型随机变量, 离散型随机变量期望的定义和一般随机变量的数学期望的定义一致。

例： 对于连续性随机变量 X，且 $X \geqslant 0$. 证明 $E(X)=\int_0^{+\infty} P(X>x)dx$.

解： 令

$$G(x)=P(X>x)=\int_x^{\infty} p(y)dy$$

则 $G'(x)=-p(x)$. 于是，

$$\int_0^{\infty} xp(x)dx=\int_0^{\infty} xdG(x)=\int_0^{\infty} G(x)dx.$$

接下来，我们计算一些常见连续型随机变量的数学期望：

（1）均匀分布

设随机变量 X 服从区间 $[a,b]$ 上的均匀分布，即 X 有密度分布：

$$p(x)=\begin{cases} \frac{1}{b-a}, & a \leqslant x \leqslant b, \\ 0, & \text{其他} \end{cases}$$

由定义知

$$E(X)=\int_b^a x\frac{1}{b-a}dx=\frac{a+b}{2}.$$

（2）指数分布

设随机变量 X 有分布密度

$$p(x)=\lambda e^{-\lambda x}, \quad x>0, \lambda>0.$$

由定义知 $E(X)=\int_0^{\infty} x\cdot\lambda e^{-\lambda x}dx=-\int_0^{\infty} xde^{-\lambda x}=\int_0^{\infty} e^{-\lambda x}dx=\frac{1}{\lambda}$.

（3）正态分布

设随机变量 X 有分布密度

$$p(x)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

对于 $X\sim N(0,1)$，由对称性直接计算得，

$$E(X)=\int_{-\infty}^{\infty} x\cdot\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}dx=0$$

同理, $X \sim N\left(\mu,\sigma^2\right)$, 则 $p(\mu+x)=p(\mu-x)$, 因此 $E(X)=\int_{-\infty}^{\infty}(x+\mu)p(\mu+x)d(x+\mu)=\int_{-\infty}^{\infty} xp(x+\mu)dx+\mu\int_{-\infty}^{\infty} p(x+\mu)dx=\mu$.

例, 对于柯西分布,

$$p(x) = \frac{1}{\pi} \cdot \frac{1}{1+x^2}.$$

但是, $\int_{-\infty}^{\infty} |x|p(x)dx = \infty$. 因此, EX 不存在!

（4）伽马分布

设随机变量 X 有分布密度

$$p(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0$$

对于 $\forall x > 0$,

$$xp(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha} e^{-\beta x} = \frac{\Gamma(\alpha+1)}{\beta\Gamma(\alpha)} \cdot \frac{\beta^{\alpha+1}}{\Gamma(\alpha+1)} x^{\alpha} e^{-\beta x} = \frac{\alpha}{\beta} \cdot \hat{p}(x).$$

因此,

$$E(X) = \int_0^\infty xp(x)dx = \frac{\alpha}{\beta} \int_0^\infty \hat{p}(x)dx = \frac{\alpha}{\beta}$$

5.1.3 数学期望的性质

定理： (1) 若 $X \equiv a$, 则 $E(X) = a$;

(2) 若 $X \geqslant 0$, 且 $E(X)$ 存在, 则 $EX \geqslant 0$;

(3) 若 $F_X = F_Y$ (或, 若 $X = Y$), 且 $E(X)$ 存在, 则 $E(Y)$ 存在, 且 $E(X) = E(Y)$;

(4) 线性：假设 $E(X), E(Y)$ 存在. 则,

$$E(a(X)) = aE(X), \quad E(X+Y) = E(X) + E(Y).$$

(5) 单调性：假设 $E(X)$,$E(Y)$ 存在, 又若 $X \geq Y$, 则 $E(X) \geq E(Y)$;

（6）$E|X| \geqslant |E(X)|$;

（7）若随机变量 X, Y 独立，且期望 $E(X), E(Y)$ 存在，则

$$E(XY) = E(X)E(Y).$$

推论： (1) 线性：假设 $E(X), E(Y)$ 存在. 则,

$$E(aX + bY) = aE(X) + bE(Y).$$

(2) 和的期望: 假设 $E(X_1), \cdots, E(X_n)$ 都存在, $\eta = X_1 + \cdots + X_n$. 则 $E(\eta)$ 存在, 且

$$E(\eta) = \sum_{i=1}^{n} E(X_i)$$

推论（1）可以由性质（4）推出，推论（2）可以由数学归纳法和性质（4）推出。

例: 超几何分布 $\eta \sim H(N, D, n)$ 的期望可以使用推论 (2) 计算: 若第 i 个产品是次品, 则令 $X_i = 1$; 否则, 令 $X_i = 0$. 则,

$$\eta = X_1 + \cdots + X_n \Rightarrow E(\eta) = np$$

马尔科夫不等式: 设 $X \geqslant 0$, 且 EX 存在. 则对任意 $C > 0$, 有

$$P(X \geqslant C) \leqslant \frac{1}{C} EX.$$

证明: 令 $A = \{X \geqslant C\}$. 则 $1_A \leqslant \frac{X}{C}$. 于是,

$$P(A) = E1_A \leqslant E\frac{X}{C} = \frac{1}{C} EX.$$

例: 若 $X \geqslant 0$, 且 $EX = 0$, 证明 $P(X > 0) = 0$。

解:

$$P\left(X \geqslant \frac{1}{n}\right) \leqslant nEX = 0$$
$$\Rightarrow P(X > 0) = \lim_{n\to\infty} P\left(X \geqslant \frac{1}{n}\right) = 0.$$

□

5.2 随机变量函数的期望

定理: (1) X 是离散型随机变量, 且下面的级数绝对收敛, 则

$$Ef(X) = \sum_k f(x_k) p_k \tag{5.2.1}$$

(2) X 是连续型随机变量, 且下面的积分绝对收敛, 则

$$Ef(X) = \int_{-\infty}^{\infty} f(x)p(x)dx. \tag{5.2.2}$$

例: (对应郑书例 6.1) 设 $X \sim U(0, 2\pi)$, 求 $E(\sin X)$.

解: 令 $p(x)$ 是 x 的分布密度, 用公式:

$$E\sin X = \int_{-\infty}^{\infty} \sin x \cdot p(x)dx = \frac{1}{2\pi}\int_0^{2\pi} \sin x dx = 0$$

□

例：（对应郑书例 6.2）设随机变量 X 服从参数为 λ 的指数分布，又 $v_0 > 0$，

$$Y = \begin{cases} X, & X < v_0, \\ v_0, & X \geqslant v_0, \end{cases}$$

求 $E(Y)$。

解： 设 $f(x) = \min\{x, v_0\}$，则 $Y = f(X)$，由于 X 的分布密度是

$$p(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0, \\ 0, & X \leqslant 0, \end{cases}$$

由式5.2.2知

$$\begin{aligned} E(Y) &= \int_{-\infty}^{+\infty} f(x)p(x)dx = \int_0^{+\infty} f(x)\lambda e^{-\lambda x}dx \\ &= \int_0^{v_0} x\lambda e^{-\lambda x}dx + \int_{v_0}^{+\infty} v_0\lambda e^{-\lambda x}dx \\ &= \frac{1}{\lambda}(1 - e^{-\lambda v_0}) \end{aligned}$$

□

琴生不等式： 若 ϕ 为凸函数，则

$$\phi(E(X)) \leqslant E(\phi(X)).$$

将期望等价于平均，代入琴生不等式即可证明。

例： 连续型随机变量 X，Y 的概率密度函数分别为 $p(x)$，$q(x)$ 且 $p(x)$，$q(x) \neq 0$，f 为一凸函数，$f(1) = 0$, 证明: $E_{x\sim q} f\left(\frac{p(x)}{q(x)}\right) \geqslant 0$.

证明： 由琴生不等式，

$$E_{x\sim q} f\left(\frac{p(x)}{q(x)}\right) \geqslant f\left(E_{x\sim q}\left(\frac{p(x)}{q(x)}\right)\right) = f\left(\int_{-\infty}^{+\infty} \frac{p(x)}{q(x)} q(x)dx\right) = f(1) = 0.$$

例： 连续型随机变量 X, Y 的概率密度函数分别为 $p(x), q(x)$ 且 $p(x), q(x) \neq 0$，我们定义 X 关于 Y 的 KL-divergence 为 $\mathrm{KL}(X||Y) = E_X\left(\ln \frac{p(x)}{q(x)}\right)$，试证明 $\mathrm{KL}(X||Y) \geqslant 0$。

证明：

$$\mathrm{KL}(X||Y) = \int p(x)\left(-\ln \frac{q(x)}{p(x)}\right) dx,$$

由于 $-\ln x$ 是凸函数，由琴生不等式知

$$\int p(x)\left(-\ln \frac{q(x)}{p(x)} dx\right) \geqslant -\ln\left(\int p(x)\frac{q(x)}{p(x)} dx\right) = -\ln 1 = 0.$$

□

例： 设随机变量 X 服从参数为 λ 的泊松分布，证明

$$E(X^n) = \lambda E((X+1)^{n-1}).$$

利用此结果计算 $E(X^3)$。

证明：

$$E(X^n) = \sum_{k=0}^{\infty} k^n \frac{\lambda^n}{k!} e^{-\lambda} = \lambda e^{-\lambda} \sum_{k=1}^{\infty} k^{n-1} \frac{\lambda^{k-1}}{(k-1)!}$$

设 $k' = k-1$，则

$$E(X^n) = \lambda e^{-\lambda} \sum_{k'=0}^{\infty} (k'+1)^{n-1} \frac{\lambda^{k'}}{k'!} = \lambda E((X+1)^{n+1}).$$

由此得

$$E(X^3) = \lambda E(X+1)^2 = \lambda(E(X^2) + 2E(X) + 1) = \lambda(\lambda E(X+1) + 2\lambda + 1) = \lambda^3 + 3\lambda^2 + \lambda.$$

例： 设 X 是仅取非负整数的离散随机变量，若其数学期望存在，证明

(1)$E(X) = \sum_{k=1}^{\infty} P(X \geqslant k)$.

(2)$\sum_{k=0}^{\infty} kP(X > k) = \frac{1}{2}[E(X^2) - E(X)]$.

证明： (1) 由于 $E(X) = \sum_{k=1}^{\infty} kP(X=k)$ 存在，所以该级数绝对收敛，从而

$$\begin{aligned} E(X) &= \sum_{k=1}^{\infty} kP(X=k) = \sum_{k=1}^{\infty} \left[\sum_{i=1}^{k} P(X=k)\right] \\ &= \sum_{i=1}^{\infty} \left[\sum_{k=i}^{\infty} P(X=k)\right] = \sum_{k=1}^{\infty} P(X \geqslant k). \end{aligned}$$

(2)

$$\begin{aligned} \sum_{k=0}^{\infty} kP(X>k) &= \sum_{k=0}^{\infty} k \sum_{i=k+1}^{\infty} P(X=i) = \sum_{i=1}^{\infty} \sum_{k=0}^{i-1} kP(X=i) \\ &= \sum_{i=1}^{\infty} P(X=i) \frac{(i-1)i}{2} = \frac{1}{2} \sum_{i=1}^{\infty} i^2 P(X=i) - \frac{1}{2} \sum_{i=1}^{\infty} iP(X=i) \\ &= \frac{1}{2} E(X^2) - \frac{1}{2} E(X). \end{aligned}$$

例： 甲乙两人进行象棋比赛，每局甲胜的概率为 p，乙胜的概率为 $q = 1-p$，比赛进行到有一人连胜两局为止，求平均比赛局数。

解： 设 X 为决定胜负所需的局数，可以取值为 $2,3,\cdots$，事件 $\{X\geqslant k\}$ 表示"到 $k-1$ 局时没有一人连胜两局"，所以

$$P(X\geqslant 1)=1,$$
$$P(X\geqslant 2k)=p^kq^{k-1}+p^{k-1}q^k=(pq)^{k-1},\quad k=1,2,\cdots,$$
$$P(X\geqslant 2k+1)=2p^kq^k,\quad k=1,2,\cdots.$$

利用上一题第一问提供的公式，可得

$$\begin{aligned}E(X)&=\sum_{k=1}^{\infty}P(X\geqslant k)=1+\sum_{k=1}^{\infty}(pq)^{k-1}+2\sum_{k=1}^{\infty}(pq)^k\\&=1+\frac{1}{1-pq}+\frac{2pq}{1-pq}=\frac{2+pq}{1-pq}.\end{aligned}$$

注意到对任意的 $0<p<1$ 总有 $p(1-p)\leqslant\frac{1}{4}$，故由 $E(X)$ 关于 pq 单调增可得

$$E(X)\leqslant\frac{2+\frac{1}{4}}{1-\frac{1}{4}}=3$$

故这种比赛最终决定胜负的平均局数不超过 3 局，在 $p=\frac{1}{2}$ 时达到上界。

5.3 随机变量的方差

随机变量的方差和标准差： 假设 $E(X)$ 存在, 且 $E(X-EX)^2$ 也存在. 则称 $E(X-EX)^2$ 为 X 的方差, 记为 $\operatorname{var}(X)$ 或 $D(X)$. 称 $\sqrt{\operatorname{var}(X)}$ 为标准差。

切比雪夫不等式： 设 X 是随机变量，如果 $E(X)$ 和 $\operatorname{var}(X)$ 都存在, 则 $\forall\varepsilon>0$, 有

$$P(|X-EX|\geqslant\varepsilon)\leqslant\frac{1}{\varepsilon^2}\operatorname{var}(X).\tag{5.3.1}$$

证明： $\{|X-EX|\geqslant\varepsilon\}=\{(X-EX)^2\geqslant\varepsilon^2\}$, 对 $Y=(X-EX)^2$ 用马尔可夫不等式，得

$$P(|X-EX|\geqslant\varepsilon)=P(Y\geqslant\varepsilon^2)\leqslant\frac{1}{\varepsilon^2}E(Y).$$

□

推论： 若 $\operatorname{var}(X)=0$, 则

$$P(X=E(X))=1.$$

证明： 由切比雪夫不等式知

$$P(|X-E(X)|\geqslant\frac{1}{n})=0\quad(n=1,2,\cdots),$$

于是

$$P(X \neq E(X)) = P(\bigcup_{n=1}^{\infty}\left\{|X - E(X)| \geqslant \frac{1}{n}\right\}) \leqslant \sum_{n=1}^{\infty} P(|X - E(X)| \geqslant \frac{1}{n}) = 0.$$

所以 $P(X = E(X)) = 1$。 □

对于方差的计算方法，有以下定理：

定理： X 为一般随机变量，且期望 $E(X^2)$ 和 $E(X)$ 存在，则

$$\operatorname{var}(X) = E(X^2) - (EX)^2. \tag{5.3.2}$$

证明：

$$\begin{aligned}\operatorname{var}(X) &= E\left(X^2 - 2X \cdot EX + (EX)^2\right) \\ &= E(X^2) - 2E(X) \cdot E(X) + (E(X))^2 = E(X^2) - (EX)^2\end{aligned}$$

具体地, 离散型或连续型的公式如下:

$$\operatorname{var}(X) = \sum_k x_k^2 p_k - (EX)^2$$

$$\operatorname{var}(X) = \int_{-\infty}^{\infty} x^2 p(x) dx - (EX)^2$$

□

定理： X 的线性变换的方差:

$$\operatorname{var}(aX + b) = a^2 \operatorname{var}(X)$$

该定理可以利用式5.3.2计算。

$$\begin{aligned}\operatorname{var}(aX + b) &= E((aX + b)^2) - (E(aX + b))^2 \\ &= (a^2 E(X^2) + 2abE(X) + b^2) - (a^2 (E(X))^2 + 2abE(X) + b^2) \\ &= a^2 (E(X^2) - a^2 (E(X))^2 = a^2 \operatorname{var}(X)\end{aligned}$$

□

定理： 设 X 为随机变量，则方差 $D(X) = \inf_{c\in\mathbb{R}} E(X - c)^2$。

证明：【方法一】利用 $E(X + c) = E(X) + c$ 与 $D(X + c) = D(X)$，可得

$$D(X) = D(X - c) = E(X - c)^2 - (E(X - c))^2 \leqslant E(X - c)^2.$$

等号成立条件是 $E(X)=c$。

【方法二】利用

$$\begin{aligned}E(X-c)^2 &= E(X-E(X)+E(X)-c)^2\\ &= D(X)+2E[(X-E(X))(E(X)-c)]+(E(X)-c)^2\\ &= D(X)+(E(X)-c)^2.\end{aligned}$$

在 $c=E(X)$ 处取得最小值 $D(X)$。 □

下面计算常见随机变量的方差:

(1)两点分布

设随机变量 X 服从两点分布，即 $X\sim B(1,p)$，根据之前的计算 $E(X)=p$，$E(X^2)=0^2\cdot P(X=0)+1^2\cdot P(X=1)=p$，由式5.3.2知

$$D(X)=E(X^2)-(E(X))^2=p-p^2=p(1-p)$$

(2) 二项分布

设随机变量 X 服从参数为 n,p 的二项分布，即

$$P(X=k)=C_n^k p^k q^{n-k}=:b(n;k),\quad k=0,1,\cdots,n,(q=1-p).$$

已经计算期望 $EX=np$, 且由分布函数知，对于 $\forall 1\leqslant k\leqslant n$,

$$k\cdot b(n;k)=np\cdot b(n-1,k-1).$$

那么对于 $\forall 2\leqslant k\leqslant n$,

$$\begin{aligned}k(k-1)\cdot b(n;k) &= np\cdot(k-1)\cdot b(n-1,k-1)\\ &= np\cdot(n-1)p\cdot b(n-2,k-2)\end{aligned}$$

于是,

$$E(X(X-1))=\sum_{k=2}^{n}k(k-1)\cdot b(n;k)=np(n-1)p\sum_{k=2}^{n}b(n-2:k-2)=np(n-1)p=(np)^2-np^2,$$

从而

$$D(X)=E(X^2)-(E(X))^2=E(X(X-1))+E(X)-(E(X))^2=npq.$$

(3)泊松分布

设随机变量 X 服从参数为 λ 的泊松分布，即

$$P(X=k)=\frac{\lambda^k}{k!}e^{-\lambda},\quad k=0,1,2,\cdots.$$

已经计算 X 的期望 $E(X)=\lambda$, 且由分布函数，$\forall k\geqslant 1, kp_k=\lambda p_{k-1}$. 因此, 对于 $\forall k\geqslant 2$,

$$k(k-1)p_k=\lambda(k-1)p_{k-1}=\lambda^2 p_{k-2}.$$

于是,

$$E(X(X-1))=\sum_{k=2}^{\infty}k(k-1)\cdot p_k=\lambda^2\sum_{k=2}^{\infty}p_{k-2}=\lambda^2,$$

从而

$$Dvar(X)=E(X^2)-(E(X))^2=E(X(X-1))+E(X)-(E(X))^2=\lambda.$$

（4）均匀分布

设随机变量 X 服从区间 $[a,b]$ 上的均匀分布，即 X 有密度分布:

$$p(x)=\begin{cases}\frac{1}{b-a}, & a\leqslant x\leqslant b,\\ 0, & \text{其他}\end{cases}$$

已经计算 X 的期望 $E(x)=\frac{a+b}{2}$，且

$$\int_{-\infty}^{+\infty}x^2p(x)dx=\frac{1}{b-a}\int_a^b x^2dx=\frac{b^2+ab+a^2}{3}.$$

由式5.3.2得

$$D(X)=\frac{b^2+ab+a^2}{3}-\left(\frac{a+b}{2}\right)^2=\frac{(b-a)^2}{12}.$$

（5）指数分布

设随机变量 X 服从参数为 λ 的指数分布，即 X 的分布函数为:

$$p(x)=\begin{cases}\lambda e^{-\lambda x}, & x>0,\\ 0, & X\leqslant 0,\end{cases}$$

已经计算期望 $E(X)=\frac{1}{\lambda}$，且

$$\int_{-\infty}^{+\infty}x^2p(x)dx=\lambda\int_0^{+\infty}x^2e^{-\lambda x}dx=\frac{2}{\lambda^2}$$

由式5.3.2得

$$D(X)=\frac{2}{\lambda^2}-\left(\frac{1}{\lambda}\right)^2=\frac{1}{\lambda^2}$$

（6）正态分布

设随机变量 X 服从正态分布，即 X 的分布函数为：

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

若 $\mu = E(X) = 0, \sigma^2 = 1$, 则,

$$\begin{aligned} D(X) = E(X^2) &= \int_{-\infty}^{\infty} x^2 \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \\ &= -\frac{2}{\sqrt{2\pi}} \int_0^{\infty} x d e^{-\frac{x^2}{2}} = \frac{2}{\sqrt{2\pi}} \int_0^{\infty} e^{-\frac{x^2}{2}} dx = 1 \end{aligned}$$

一般情形, 做变量替换 $Y = \frac{X-\mu}{\sigma} \sim N(0,1)$. 则

$$\begin{aligned} X - E(X) = (\mu + \sigma Y) - (\mu + \sigma E(Y)) = \sigma(Y - E(Y)) \\ \Rightarrow D(X) = E((X - E(X))^2) = E(\sigma(Y - EY))^2 = \sigma^2 D(Y) = \sigma^2 \end{aligned}$$

（7）伽马分布

设随机变量 X 服从伽马分布，有分布密度

$$p(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0$$

已经计算 X 的期望 $E(X) = \frac{\alpha}{\beta}$，由式5.3.2知

$$D(X) = \int_0^{+\infty} x^2 \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} dx - \left(\frac{\alpha}{\beta}\right)^2$$

做变量替换 $\beta x = t$，易知

$$\begin{aligned} D(X) &= \frac{1}{\Gamma(\alpha)\beta^2} \int_0^{+\infty} t^{\alpha+1} e^{-t} dt - \left(\frac{\alpha}{\beta}\right)^2 \\ &= \frac{1}{\Gamma(\alpha)\beta^2} \Gamma(\alpha+2) - \left(\frac{\alpha}{\beta}\right)^2 \\ &= \frac{(\alpha+1)\alpha\Gamma(\alpha)}{\Gamma(\alpha)\beta^2} - \left(\frac{\alpha}{\beta}\right)^2 = \frac{\alpha}{\beta^2} \end{aligned}$$

随机变量的标准化：一般地, 若 X 的方差存在, 且 $\mathrm{var}(X) > 0$, 则

$$X^* = \frac{X - E(X)}{\sqrt{\mathrm{var}(X)}}$$

满足 $E(X^*)=0, \operatorname{var}(X^*)=1$. 称 X^* 为 X 的标准化。

例： 设随机变量 $X\sim N(0,1)$，则对一切正整数 k，

$$E(X^{2k-1})=0,\quad E(X^{2k})=(2k-1)(2k-3)\cdots\cdot 3\cdot 1.$$

证明： 对任何 $m\geqslant 1$，积分 $\int_{-\infty}^{+\infty}|x|^m e^{-x^2/2}dx$ 收敛，因此 $E(X^m)$ 存在，由于

$$x^{2k-1}\frac{1}{\sqrt{2\pi}}e^{-x^2/2}$$

是 x 的奇函数，故

$$E(X^{2k-1})=\int_{-\infty}^{+\infty}x^{2k-1}\frac{1}{\sqrt{2\pi}}e^{-x^2/2}dx=0$$

$$\begin{aligned}E(X^{2k})&=\int_{-\infty}^{+\infty}x^{2k}\frac{1}{\sqrt{2\pi}}e^{-x^2/2}dx\\&=\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}x^{2k-1}d(e^{-x^2/2})\\&=(2k-1)\int_{-\infty}^{+\infty}x^{2k-2}\frac{1}{\sqrt{2\pi}}e^{-x^2/2}dx\\&=(2k-1)E(X^{2k-2}).\end{aligned}$$

这是递推公式，故

$$E(X^{2k})=(2k-1)(2k-3)\cdots\cdot 3\cdot 1$$

例： 设随机变量 X 的概率密度函数为 $f(x)=\frac{k\theta^k}{x^{k+1}}, x>\theta>0$, $k>2$ 为正整数，求 (1)$E(X)$, (2)$D(X)$.

解： (1):

$$E(X)=\int_{\theta}^{+\infty}\frac{k\theta^k}{x^{k+1}}xdx=\frac{k\theta}{k-1}.$$

(2):

$$D(X)=\int_{\theta}^{+\infty}\frac{k\theta^k}{x^{k+1}}x^2dx-(E(X))^2=\frac{3k-2k^2}{(k-2)(k-1)^2}.$$

例： 设连续随机变量 X 的分布函数为 $F(x)$，且数学期望存在，证明：

$$E(X)=\int_0^{\infty}[1-F(x)]dx-\int_{-\infty}^0F(x)dx.$$

证明：

$$E(X)=\int_{-\infty}^{\infty}xp(x)dx=\int_{-\infty}^{0}xp(x)dx+\int_{0}^{\infty}xp(x)dx.$$

将第一个积分改写为:

$$\begin{aligned}\int_{-\infty}^{0} xp(x)dx &= \int_{-\infty}^{0} -\left(\int_{x}^{0} dy\right) p(x)dx \\ &= -\int_{-\infty}^{0}\int_{-\infty}^{y} p(x)dxdy \\ &= -\int_{-\infty}^{0} F(y)dy.\end{aligned}$$

第二个积分同理,

$$\begin{aligned}\int_{0}^{\infty} xp(x)dx &= \int_{0}^{\infty} \left(\int_{0}^{x} dy\right) p(x)dx \\ &= \int_{0}^{\infty}\int_{y}^{\infty} p(x)dxdy \\ &= \int_{0}^{\infty} [1-F(y)]dy.\end{aligned}$$

将二式加和即可得

$$E(X) = \int_{0}^{\infty} [1-F(x)]dx - \int_{-\infty}^{0} F(x)dx.$$

5.4 随机变量的其他数学特征

原点矩和中心矩:
设 X 是随机变量，如果 $E(X^k)$ 存在（k 是正整数），则称 $E(X^k)$ 是 X 的 k **阶原点矩**，常常记为 ν_k。
设 X 是随机变量，如果 $E(X)$ 存在，且 $E(X-E(X))^k$ 存在（k 是正整数），则称 $E(X-E(X))^k$ 为 X 的 k **阶中心矩**，常常记为 μ_k。

显然，$E(X)=\nu_1$，$\mathrm{var}(X)=\mu_2$。

随机变量的 p 分位数: 若 X 是随机变量，$0<p<1$，且

$$P(X<a) \leqslant p \leqslant P(X \leqslant a),$$

则称 a 为 X 的一个 p **分位数**。

$p=0.5$ 时, 也称 a 为一个中位数.

例: 设随机变量 X 的可能值是 $1,2,3$ 且

$$P(X=1)=\frac{1}{3},\quad P(X=2)=\frac{1}{6},\quad P(X=3)=\frac{1}{2}.$$

则 $E(X)=\frac{13}{6}$，中位数有无穷个，区间 $[2,3]$ 中的每个数都是 X 的中位数。

例：（对应郑书例 8.3）设随机变量 $X\sim N(0,1)$，则对一切正整数 k，

$$E(x^{2k-1})=0,\quad E(X^{2k})=(2k-1)(2k-3)\cdot\cdots\cdot 3\cdot 1.$$

□

定理： 设 $X=X(\omega)$ 是随机变量，对某个 $\alpha\geqslant 1$，$E(|X|^{\alpha})$ 存在，则 $E(X)$ 存在，且

$$E(|X|)\leqslant(E(|X|^{\alpha}))^{1/\alpha}.$$

证明： 首先指出，对一切 $x\geqslant 0$，$\alpha\geqslant 0$，如下不等式成立：

$$x^{\alpha}\geqslant a^{\alpha}+\alpha a^{\alpha-1}(x-a).\tag{5.4.1}$$

实际上，令 $f(x)=x^{\alpha}-a^{\alpha}-\alpha a^{\alpha-1}(x-a)$，则 $f'(x)=\alpha(x^{\alpha-1}-a^{\alpha-1})$，从而 $f(x)$ 在 $x=a$ 处达到最小值，由于 $f(a)=0$，因此式5.4.1成立。

由于 $\alpha\geqslant 1$，有 $|X(\omega)|\leqslant|X(\omega)|^{\alpha}+1$，知 $E(X)$ 存在。令 $a=E(X)$，由式5.4.1知

$$|X(\omega)|^{\alpha}\geqslant(E(|X|))^{\alpha}+\alpha(E(|X|))^{\alpha-1}(|X(\omega)|-E(|X|)).$$

两侧取数学期望，得 $(E(|X|))^{\alpha}\leqslant E(|X|^{\alpha})$，表明定理成立。 □

6.1 随机向量的定义

n **维随机向量：** 称 n 个随机变量 $X_1, \cdots, X_n$ 的整体 $\xi = (X_1, \cdots, X_n)$ 为 n **维随机向量**（或者 n **维随机变量**），一维随机向量简称随机变量。

n **维随机变量数学上的精确定义：** 设 $X_1 = X_1(\omega), \cdots, X_n = X_n(\omega)$ 都是概率空间 $(\Omega, \mathscr{F}, P)$ 上的随机变量，则称

$$\xi = \xi(\Omega) \triangleq (X_1(\omega), \cdots, X_n(\omega))$$

为概率空间 $(\Omega, \mathscr{F}, P)$ 上的 n **维随机向（变）量**。

例如，用炮弹向远处目标攻击，炮弹的落点用平面坐标系中的坐标表示为 (X, Y)，是一个二维随机向量。

随机向量的函数： 设 $X_1 = X_1(\omega), \cdots, X_n = X_n(\omega)$ 是 n 个随机变量，$f(x_1, \cdots, x_n)$ 是 n 元实值函数，则称随机变量 $Y \triangleq f(x_1, \cdots, x_n)$ 为随机变量 $X_1, \cdots, X_n$ 的函数（即随机向量 $(X_1, \cdots, X_n)$ 的函数）。

6.2 二维随机变量的联合分布和边缘分布

6.2.1 离散情形

离散型二维随机向量： 称二维随机向量 $\xi = (X, Y)$ 是离散型的，若它只取至多可列个不同的值，即 ξ 可能取的值可以排成一个（有限或无穷序列）。

二维离散型随机向量的概率分布： 设 $\xi = (X, Y)$ 是二维离散型随机向量，其可能值是 $\boldsymbol{a}_1, \boldsymbol{a}_2, \cdots$（有限个或者无穷可列个），$p_1 \triangleq P(\xi = a_i)(i = 1, 2, \cdots)$，则称

$$\{p_i : i = 1, 2, \cdots\}$$

为 ξ 的**概率分布**，也称为 ξ 的概率函数或概率分布律。$\xi = (X, Y)$ 的概率分布也叫做 (X, Y) 的**联合概率分布**（简称联合分布）。

令

$$p_{ij} = P(X = x_i, Y = y_i) \quad (i, j = 1, 2, \cdots),$$

$\{p_{ij}\}$ 就是 $\xi = (X, Y)$ 的概率分布，可以用表6.3来表示，表6.3也称 $\xi = (X, Y)$ 的**概率分布表**。

联合分布满足性质：

表 6.3: (X,Y) 的概率分布表。

$X \backslash Y$	y_1	y_2	$\cdots$	y_j	$\cdots$
x_1	p_{11}	p_{12}	$\cdots$	p_{1j}	$\cdots$
x_2	p_{21}	p_{22}	$\cdots$	p_{2j}	$\cdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_i	p_{i1}	p_{i2}	$\cdots$	p_{ij}	$\cdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

（1）非负性：$p_{ij} \geqslant 0, i,j = 1,2,\cdots$ ；

（2）规范性：$\sum_{i,j} p_{ij} = 1$。

例:（三项分布）设二维随机向量 $\xi = (X,Y)$ 取值于集合 $E = \{(k_1,k_2) : k_1\text{和}k_2\text{都是非负整数且}k_1 + k_2 \leqslant n\}$，$\xi$ 的概率分布是：

$$P((X,Y) = (k_1,k_2)) = \frac{n!}{k_1!k_2!(n-k_1-k_2)!} p_1^{k_1} p_2^{k_2} (1-p_1-p_2)^{n-k_1-k_2},$$

其中 $n \geqslant 1, 0 < p_1, 0 < p_2, p_1 + p_2 < 1, (k_1,k_2) \in E$，这时称 ξ 服从三项分布。

例: 有一大批量粉笔，其中 60% 是白的，25% 是黄的，15% 是红的，现从中随机的依次取出 6 支，问：其中恰有 3 支白色，1 支黄色，2 支红色的概率是多少?

解: 令 $X =$ "6 支中白粉笔的个数"，$Y =$ "6 支中黄粉笔的个数"，则事件"6 支中恰有 3 支白色，1 支黄色，2 支红色"就是事件

$$\{X = 3, Y = 1\}, \text{即}\{(X,Y) = (3,1)\}.$$

由三项分布，概率可表示为

$$P((X,Y) = (3,1)) = \frac{6!}{3!1!2!} 0.6^3 \times 0.25 \times 0.15^2.$$

用组合数方法同样可以得到上述结果。

一般的，对于满足 $k_1 \geqslant 0, k_2 \geqslant 0$ 及 $k_1 + k_2 \leqslant 6$ 的 k_1, k_2，由三项分布有

$$P((X,Y) = (k_1,k_2)) = \frac{6!}{k_1!k_2!(6-k_1-k_2)!} 0.6^{k_1} \times 0.25^{k_2} \times 0.15^{6-k_1-k_2}.$$

□

二维随机向量的边缘分布：对于二维随机向量 $\xi = (X, Y)$，分量 X 的概率分布称为 ξ 关于 X 的**边缘分布**，分量 Y 的概率分布称为 ξ 关于 Y 的**边缘分布**。

二维随机向量 $\xi = (X, Y)$ 的两个边缘分布均由 ξ 的概率分布完全确定。

例：从 $1, 2, 3, 4$ 中任取一数记为 X，再从 $1, \cdots, X$ 中任取一数记为 Y，求 $(X\ Y)$ 的联合分布列及 $P(X = Y)$。

解：易知 X 的分布列为：

$$P(X = i) = \frac{1}{4}, \quad i = 1, 2, 3, 4.$$

显然，$P(X = i, Y = j) = 0, j > i, i = 1, 2, 3, 4$，当 $1 \leqslant j \leqslant i \leqslant 4$ 时，由乘法公式得

$$P(X = i, Y = j) = P(X = i)P(Y = j|X = i) = \frac{1}{4} \times \frac{1}{i} = \frac{1}{4i}.$$

从而 (X, Y) 的分布列为 由此可算得

$Y \backslash X$	1	2	3	4
1	$\frac{1}{4}$	0	0	0
2	$\frac{1}{8}$	$\frac{1}{8}$	0	0
3	$\frac{1}{12}$	$\frac{1}{12}$	$\frac{1}{12}$	0
4	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$

$$P(X = Y) = \sum_{i=1}^{4} P(X = Y = i) = \sum_{i=1}^{4} \frac{1}{4i} = \frac{25}{48}.$$

□

例：（对应郑书例 2.5）设随机变量 X 取值是 0 或 1，随机变量 Y 取值也是 0 或 1，且二维随机向量 (X, Y) 的概率分布是

$$P((X, Y) = (0, 0)) = \frac{1}{4} + \varepsilon, \quad P((X, Y) = (0, 1)) = \frac{1}{4} - \varepsilon,$$

$$P((X, Y) = (1, 0)) = \frac{1}{4} - \varepsilon, \quad P((X, Y) = (1, 1)) = \frac{1}{4} + \varepsilon,$$

其中 $0 \leqslant \varepsilon \leqslant \frac{1}{4}$。

易知不同的 ε 对应不同的联合分布，但是

$$P(X = 0) = P((X, Y) = (0, 0)) + P((X, Y) = (0, 1)) = \frac{1}{2},$$

$$P(X=1)=P((X,Y)=(1,0))+P((X,Y)=(1,1))=\frac{1}{2}.$$

同理，

$$P(Y=0)=P(Y=1)=\frac{1}{2},$$

由此可见，两个边缘分布均与 ε 无关，表明有无穷多个不同的联合分布具有相同的边缘分布。

6.2.2 连续情形

连续型随机向量及其联合密度函数： 设 $\xi=(X,Y)$ 为二维随机向量，若存在非负函数 $p(x,y)$ 使得

$$P(\xi\in D)=\iint_D p(x,y)dxdy,$$

对任意开矩形 D 成立, 则称 ξ 为**连续型随机向量**, 称 $p(x,y)$ 为 ξ 的**联合密度** (函数)，也称概率分布密度函数，记为 $p_{X,Y}(x,y)$.

对于二维连续型随机向量 $\xi=(X,Y)$，对于平面上任意的集合 A，有

$$P(\xi\in A)=\iint_A p(x,y)dxdy, \tag{6.2.1}$$

联合密度满足归一性:

$$p(x,y)\geqslant 0;\qquad \iint_{\mathbb{R}^2} p(x,y)dxdy=1.$$

例：（对应郑书例 2.6）设二维随机向量 $\xi=(X,Y)$ 的联合密度为

$$p(x,y)=\begin{cases} ce^{-(x+y)}, & x\geqslant 0\text{且}y\geqslant 0,\\ 0, & \text{其他}, \end{cases}$$

其中 c 是一个常数，求:

（1）c 的值；　（2）$P(0<X<1,0<Y<1)$.

解：（1）由归一性知

$$1=\int_0^{+\infty}\int_0^{+\infty} ce^{-(x+y)}dxdy=c\int_0^{+\infty}e^{-x}dx\cdot\int_0^{+\infty}e^{-y}dy$$

于是 $c=1$。

（2）取 $D=\{(x,y):0<x<1,0<y<1\}$，由定义知

$$P(0<X<1,0<Y<1)=P((X,Y)\in D)=\int_0^1\int_0^1 e^{-(x+y)}dxdy$$

$$= \int_0^1 e^{-x}dx \cdot \int_0^1 e^{-y}dy = (1-e^{-1})^2.$$

□

定义：设 G 是平面上面积为 $a(0<a<+\infty)$ 的区域，称二维随机向量 $\xi=(X,Y)$ 服从 G 上的**均匀分布**，若 $P((X,Y)\in G)=1$，且 (X,Y) 取值属于 G 的任何部分 A（A 是 G 的子区域）的概率与 A 的面积成正比。容易推知二维随机向量 $\xi=(X,Y)$ 有联合密度为

$$p(x,y)=\begin{cases} \frac{1}{a}, & (x,y)\in G, \\ 0, & \text{其他}, \end{cases} \tag{6.2.2}$$

连续型随机向量的边缘分布：设 $p(x,y)$ 是二维随机向量 $\xi=(X,Y)$ 的联合密度，则

$$p_X(x)\triangleq\int_{-\infty}^{+\infty}p(x,y)dy,\quad p_Y(y)\triangleq\int_{-\infty}^{+\infty}p(x,y)dx$$

分别是 X,Y 的分布密度。

证明：对任何 $a<b$，令 $A=\{(x,y):a<x<b,-\infty<y<+\infty\}$，由式6.2.1知

$$P((X,Y)\in A)=P(a<X<b)=\int_a^b\int_{-\infty}^{+\infty}p(x,y)dxdy$$

$$=\int_a^b(\int_{-\infty}^{+\infty}p(x,y)dy)dx=\int_a^b p_X(x)dx.$$

这表明 $p_X(x)$ 是 X 的分布密度，同理知 $p_Y(y)$ 是 Y 的分布密度。 □

例：（对应郑书例 2.7）设 G 是由抛物线 $y=x^2$ 和直线 $y=x$ 所围成的区域（图6.3）若二维随机向量 $\xi=(X,Y)$ 服从 G 上的均匀分布，试求 ξ 的联合分布和两个边缘分布密度。

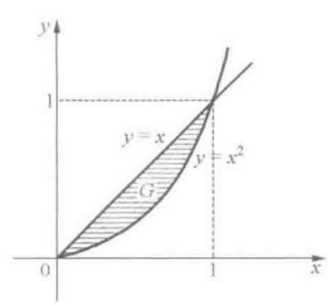

图 6.3: 区域 G 的示意图

解： 由于 G 的面积为

$$\int_0^1 (x-x^2)dx = \frac{1}{6},$$

由式6.2.2知联合密度为

$$p(x,y) = \begin{cases} 6, & (x,y) \in G, \\ 0, & \text{其他}, \end{cases}$$

得 X 的分布密度 $p_X(x)$ 和 Y 的分布密度 $p_Y(y)$ 分别如下：

$$\begin{aligned} p_X(x) &= \int_{-\infty}^{+\infty} p(x,y)dy \\ &= \int_{x^2}^{x} 6dy = 6(x-x^2) \quad (0 \leqslant x \leqslant 1), \\ p_X(x) &= 0 \quad (x \notin [0,1]), \\ p_Y(y) &= \int_{-\infty}^{+\infty} p(x,y)dx \\ &= \int_{y}^{\sqrt{y}} 6dx = 6(\sqrt{y}-y) \quad (0 \leqslant y \leqslant 1), \\ p_Y(y) &= 0 \quad (y \notin [0,1]). \end{aligned}$$

□

由定义知边缘密度函数由联合密度确定，但是不同的联合密度可能有相同的边缘分布密度，即联合密度不能由两个边缘分布密度完全确定。

例： 设二维随机向量 $\xi = (X,Y)$ 有联合密度

$$p_1(x,y) = \frac{1}{2\pi} \exp\{-\frac{1}{2}(x^2+y^2)\},$$

二维随机向量 $\eta = (U,V)$ 有联合密度

$$p_2(x,y) = \begin{cases} 2p_1(x,y), & xy \geqslant 0, \\ 0, & \text{其他}. \end{cases}$$

则 X 与 U 有相同的分布密度，Y 与 V 有相同的分布密度。

一方面，当 $x \leqslant 0$ 时，

$$\int_{-\infty}^{+\infty} p_2(x,y)dy = \int_{-\infty}^{0} 2p_1(x,y)dy = \frac{1}{\pi}\int_{-\infty}^{0} e^{-(x^2+y^2)/2}dy$$

$$= \frac{1}{\pi}e^{-x^2/2}\int_{-\infty}^{0} e^{-y^2/2} = \frac{1}{\pi}e^{-x^2/2}\frac{1}{2}\int_{-\infty}^{+\infty} e^{-y^2/2} = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}.$$

类似的，当 $x>0$ 时，

$$\begin{aligned}\int_{-\infty}^{+\infty} p_2(x,y)dy &= \int_0^{+\infty} 2p_1(x,y)dy \\ &= \frac{1}{\pi}\int_0^{+\infty} e^{-(x^2+y^2)/2}dy = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}.\end{aligned}$$

即，对一切 x，$\int_{-\infty}^{+\infty} p_2(x,y)dy = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$。

同理，对一切 y，$\int_{-\infty}^{+\infty} p_2(x,y)dx = \frac{1}{\sqrt{2\pi}}e^{-y^2/2}$。

6.2.3 一般情形

一般二维随机向量及其联合分布函数： 设 $\xi=(X,Y)$ 是二维随机向量，则称

$$F(x,y)=P(X\leqslant x, Y\leqslant y)\quad (x,y\in\mathbb{R})$$

为 ξ 的分布函数。也称为 (X,Y) 的**联合分布函数**。

分布函数 $F(x,y)$ 有以下性质：

（1）$0\leqslant F(x,y)\leqslant 1$;

（2）$F(x,y)$ 是 x 的右连续增函数，也是 y 的右连续增函数;

（3）$\lim_{x\to-\infty} F(x,y)=0, \lim_{y\to-\infty} F(x,y)=0$;

（4）$\lim_{x\to+\infty} F(x,y)=P(Y\leqslant y), \lim_{y\to+\infty} F(x,y)=P(X\leqslant x)$;

（5）对任何 $x_1\leqslant x_2, y_1\leqslant y_2$，有

$$F(x_2,y_2)-F(x_1,y_2)-F(x_2,y_1)+F(x_1,y_1)\geqslant 0.$$

对性质（1）-（4）可以效仿一维随机变量的证明。

现在证明性质（5），我们指出，对一切 $x_1\leqslant x_2, y_1\leqslant y_2$，有

$$\begin{aligned}P(x_1<X\leqslant x_2, y_1<Y\leqslant y_2) &= P(x_1<X\leqslant x_2, Y\leqslant y_2)-P(x_1<X\leqslant x_2, Y\leqslant y_1) \\ &= P(X\leqslant x_2, Y\leqslant y_2)-P(X\leqslant x_1, Y\leqslant y_2) \\ &\quad -[P(X\leqslant x_2, Y\leqslant y_1)-P(X\leqslant x_1, Y\leqslant y_1)] \\ &= F(x_2,y_2)-F(x_1,y_2)-[F(x_2,y_1)-F(x_1,y_1)]\end{aligned}$$

由 $P(x_1<X\leqslant x_2, y_1<Y\leqslant y_2)\geqslant 0$ 知性质（5）成立。 □

若二维随机向量 $\xi=(X,Y)$ 有联合密度 $p(x,y)$，则 ξ 的联合分布函数 $F(x,y)$ 与联合密度 $p(x,y)$ 有关系式

$$F(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{y}p(u,v)dudv. \tag{6.2.3}$$

例： 设二维随机向量 (X,Y) 有密度函数

$$p(x,y)=\begin{cases} Ce^{-(2x+y)}, & x>0,y>0,\\ 0, & \text{其他}. \end{cases}$$

求（1）常数 C 的值；（2）联合分布函数 $F(x,y)$；（3）概率 $P(X\leqslant Y)$。

解：（1）由于

$$1=C\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}p(x,y)dxdy=C\int_{0}^{+\infty}e^{-2x}dx\int_{0}^{+\infty}e^{-y}dy=\frac{C}{2}$$

得 $C=2$。

（2）利用公式

$$\begin{aligned} F(x,y)&=\int_{-\infty}^{y}\int_{-\infty}^{x}p(t,r)dtdr\\ &=\begin{cases} \int_0^y\int_0^x 2e^{-2t-r}dtdr, & x>0,y>0,\\ 0, & \text{其他}, \end{cases}\\ &=\begin{cases} (1-e^{-2x})(1-e^{-y}), & x>0,y>0,\\ 0, & \text{其他}. \end{cases} \end{aligned}$$

（3）设区域 $G=\{(x,y)|x\leqslant y\}$，则

$$P(X\leqslant Y)=P((X,Y)\in G)=\iint_G p(x,y)dydx=\int_0^{+\infty}\int_x^{+\infty}2e^{-2x-y}dydx=\frac{2}{3}.$$

□

例： 设 (X,Y) 的联合密度函数为

$$p(x,y)=\begin{cases} 1, & 0<x<1,|y|<x,\\ 0, & \text{其他}. \end{cases}$$

求边际密度函数。

解： 根据定义

$$p_X(x)=\int_{-\infty}^{+\infty}p(x,y)dy=\begin{cases} \int_{-x}^{x}1dy=2x & x\in(0,1),\\ 0, & x\notin(0,1). \end{cases}$$

$$p_Y(y)=\int_{-\infty}^{+\infty}p(x,y)dx=\begin{cases}\int_y^1 1dx=1-y & y\in[0,1),\\ \int_{-y}^1 1dx=1+y, & y\in(-1,0),\\ 0, & y\notin(-1,1).\end{cases}$$

□

6.2.4 二维正态分布

二维正态分布： 若 $\xi=(X,Y)$ 的联合密度 $p(x,y)$ 有如下表达式, 则称 ξ 服从**二维（元）正态分布**。

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{-\frac{u^2+v^2-2\rho uv}{2\left(1-\rho^2\right)}\right\}, \tag{6.2.4}$$

其中,

$$u=\frac{x-\mu_1}{\sigma_1},\quad v=\frac{y-\mu_2}{\sigma_2},$$

共有 5 个参数: $\mu_1,\mu_2\in\mathbb{R},\sigma_1,\sigma_2>0,\rho\in(-1,1)$

例： 设二维随机向量 $\xi=(X,Y)$ 服从二维正态分布，试求出 X 的分布密度和 Y 的分布密度。

解： 设 X 的分布密度为 $p_X(x)$，做变量代换 $v=\frac{y-\mu_2}{\sigma_2}$，得

$$\begin{aligned}p_X(x)&=\int_{-\infty}^{+\infty}p(x,y)dy\\&=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x-\mu_1}{\sigma_1}\right)^2\right\}\\&\cdot\int_{-\infty}^{+\infty}\exp\left\{-\frac{1}{2\left(1-\rho^2\right)}\left[\left(\frac{y-\mu_2}{\sigma_2}\right)^2-2\rho\frac{y-\mu_2}{\sigma_2}\frac{x-\mu_1}{\sigma_1}\right]\right\}dy\\&=\frac{1}{2\pi\sigma_1\sqrt{1-\rho^2}}\exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x-\mu_1}{\sigma_1}\right)^2\right\}\cdot\int_{-\infty}^{+\infty}\exp\left\{-\frac{1}{2\left(1-\rho^2\right)}[v^2-2\rho v\frac{x-\mu_1}{\sigma_1}]\right\}dv\end{aligned}$$

其中

$$\begin{aligned}&\int_{-\infty}^{+\infty}\exp\left\{-\frac{1}{2\left(1-\rho^2\right)}[v^2-2\rho v\frac{x-\mu_1}{\sigma_1}]\right\}dv\\&=\int_{-\infty}^{+\infty}\exp\left\{-\frac{1}{2\left(1-\rho^2\right)}\left[\left(v-\rho\frac{x-\mu_1}{\sigma_1}\right)^2-\rho^2\left(\frac{x-\mu_1}{\sigma_1}\right)^2\right]\right\}dv\\&=\exp\left\{\frac{\rho^2}{2(1-\rho^2)}\left(\frac{x-\mu_1}{\sigma_1}\right)^2\right\}\cdot\int_{-\infty}^{+\infty}\exp\left\{-\frac{1}{2\left(1-\rho^2\right)}\left(v-\rho\frac{x-\mu_1}{\sigma_1}\right)^2\right\}dv\end{aligned}$$

$$= \exp\left\{\frac{\rho^2}{2(1-\rho^2)}\left(\frac{x-\mu_1}{\sigma_1}\right)^2\right\}\sqrt{2\pi(1-\rho^2)}.$$

于是

$$p_X(x) = \frac{1}{\sqrt{2\pi}\sigma_1}\exp\left\{-\frac{(x-\mu_1)^2}{2\sigma_1^2}\right\}.$$

同理知

$$p_Y(y) = \frac{1}{\sqrt{2\pi}\sigma_2}\exp\left\{-\frac{(y-\mu_2)^2}{2\sigma_2^2}\right\}.$$

这表明 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$.

例： 假定 $(\xi_1, \xi_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$，试求 (ξ_1, ξ_2) 落在

$$D = \left\{(x,y)|\left(\frac{x-\mu_1}{\sigma_1}\right)^2 - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \left(\frac{y-\mu_2}{\sigma_2}\right)^2 \leqslant \lambda^2\right\}$$

内的概率。

解： 所求概率

$$\iint_D p(x,y)dxdy = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}$$

$$\times\iint_D \exp\left\{-\frac{1}{2\left(1-\rho^2\right)}\left[\left(\frac{x-\mu_1}{\sigma_1}\right)^2 - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \left(\frac{y-\mu_2}{\sigma_2}\right)^2\right]\right\}dxdy$$

做变量代换 $u = \frac{x-\mu_1}{\sigma_1} - \rho\frac{y-\mu_2}{\sigma_2}$， $v = \sqrt{1-\rho^2}\frac{y-\mu_2}{\sigma_2}$，则

$$\left|\frac{\partial(u,v)}{\partial(x,y)}\right| = \begin{vmatrix} \frac{1}{\sigma_1} & 0 \\ -\frac{\rho}{\sigma_2} & \frac{\sqrt{1-\rho^2}}{\sigma_2} \end{vmatrix} = \frac{\sqrt{1-\rho^2}}{\sigma_1\sigma_2}, \quad |J| = \frac{\sigma_1\sigma_2}{\sqrt{1-\rho^2}}.$$

从而

$$\begin{aligned}\iint_D p(x,y)dxdy &= \frac{1}{2\pi(1-\rho^2)}\iint_{\{u^2+v^2\}\leqslant\lambda^2}\exp\left\{-\frac{u^2+v^2}{2(1-\rho^2)}\right\}dudv \\ &= \frac{1}{2\pi(1-\rho^2)}\int_0^{2\pi}\int_0^{\lambda}\exp\left\{-\frac{r^2}{2(1-\rho^2)}\right\}rdrd\theta \\ &= \int_0^{\frac{\lambda^2}{2(1-\rho^2)}} e^{-t}dt = 1-\exp\left\{-\frac{\lambda^2}{2(1-\rho^2)}\right\}.\end{aligned}$$

□

6.3 条件分布

条件分布函数： 设 X 和 Y 是两个随机变量，给定实数 y，如果 $P(Y=y)>0$)，则称 x 的函数 $P(X\leqslant x|Y=y)$ 为在 $Y=y$ 的条件下 X 的**条件分布函数**，记作 $F_{X|Y}(x|y)$，显然，根据条件概率的定义，有

$$F_{X|Y}(x|y)=\frac{P(X\leqslant x,Y=y)}{P(Y=y)}.$$

6.3.1 离散型情形

设 (X,Y) 是二维离散型随机向量，其概率分布为

$$P(X=x_i,Y=y_j)=p_{ij}\quad(i=1,2,\cdots;j=1,2,\cdots),$$

这里 $P(Y=y_i)>0\quad(j\geqslant 1)$，则在 $Y=y_i$ 的条件下 X 的条件分布为

$$P(X=x_i|Y=y_j)=\frac{P(X=x_i,Y=y_j)}{P(Y=y_j)}=\frac{p_{ij}}{\sum_k p_{kj}}\quad(i=1,2,\cdots).$$

例： 设随机变量 X 与 Y 相互独立，X 服从参数为 λ_1 的泊松分布，Y 服从参数为 λ_2 的泊松分布，试求在 $X+Y=n$ 条件下 X 的条件分布（n 为正整数）。

解： 由于 $X+Y$ 服从参数为 $\lambda_1+\lambda_2$ 的泊松分布，故对 $k=0,1,\cdots,n$ 有

$$\begin{aligned}P(X=k|X+Y=n)&=\frac{P(X=k,X+Y=n)}{P(X+Y=n)}\\&=\frac{P(X=k)P(Y=n-k)}{P(X+Y=n)}\\&=\frac{\lambda_1^k}{k!}e^{-\lambda_1}\frac{\lambda_2^{n-k}}{(n-k)!}e^{-\lambda_2}\Big/\left[\frac{1}{n!}(\lambda_1+\lambda_2)^n e^{-(\lambda_1+\lambda_2)}\right]\\&=C_n^k\left(\frac{\lambda_1}{\lambda_1+\lambda_2}\right)^k\left(\frac{\lambda_2}{\lambda_1+\lambda_2}\right)^{n-k}.\end{aligned}$$

这表明，在 $X+Y=n$ 的条件下 X 的条件分布列为参数为 $n,\frac{\lambda_1}{\lambda_1+\lambda_2}$ 的二项分布。 □

例: 设随机变量 X 与 Y 相互独立, 都服从参数是 n,p 的二项分布, 试求在 $X+Y=m(0\leqslant m\leqslant 2n)$ 条件下 X 的条件分布。

解： 记 $l=\min\{n,m\}$，易知

$$P(X+Y=m)=\sum_{i=0}^{l}P(X=i,Y=m-i)$$

$$
\begin{aligned}
&= \sum_{i=0}^{l} P(X=i)P(Y=m-i) \\
&= \sum_{i=0}^{l} C_n^i p^i (1-p)^{n-i} C_n^{m-i} p^{m-i} (1-p)^{n-m+i} \\
&= p^m (1-p)^{2n-m} \sum_{i=0}^{l} C_n^i C_n^{m-i} \\
&= C_{2n}^m p^m (1-p)^{2n-m}.
\end{aligned}
$$

于是，当 $k = 0, 1, \cdots, l$ 时，

$$
\begin{aligned}
P(X=k|X+Y=m) &= \frac{P(X=k, X+Y=m)}{P(X+Y=m)} \\
&= \frac{C_n^k p^k (1-p)^{n-k} C_m^{m-k} p^{m-k} (1-p)^{n-m+k}}{C_{2n}^m p^m (1-p)^{2n-m}} \\
&= \frac{C_n^k C_n^{m-k}}{C_{2n}^m}.
\end{aligned}
$$

当 $k > l$ 时，显然 $P(X=k|X+Y=m) = 0$。

由此可见，在 $X+Y=m$ 条件下 X 的条件分布是超几何分布。 □

例：一射手进行射击，击中目标的概率 $p \in (0,1)$，射击至击中目标两次为止。若以 X 表示首次击中目标所进行的射击次数，以 Y 表示总共进行的射击次数。试求 X 和 Y 的联合分布列及条件分布列。

解：$Y = n$ 表示第 n 次击中目标且前 $n-1$ 次恰有一次击中目标，

$$
P(X=m, Y=n) = p^2(1-p)^{n-2}, \quad n = 2, 3, \cdots, m = 1, \cdots, n-1.
$$

从而

$$
\begin{aligned}
P(X=m) &= \sum_{n=m+1}^{\infty} P(X=m, Y=n) \\
&= \sum_{n=m+1}^{\infty} p^2 (1-p)^{n-2} \\
&= p(1-p)^{m-1}, \quad m = 1, 2, \cdots
\end{aligned}
$$

且

$$\begin{aligned} P(Y=n) &= \sum_{m=1}^{n-1} P(X=m, Y=n) \\ &= \sum_{m=1}^{n-1} p^2(1-p)^{n-2} \\ &= (n-1)p^2(1-p)^{n-2}, \quad n=2,3,\cdots \end{aligned}$$

于是当 $n=2,3,\cdots$ 时,

$$P(X=m|Y=n) = \frac{p^2(1-p)^{n-2}}{(n-1)p^2(1-p)^{n-2}} = \frac{1}{n-1}, \quad m=1,\cdots,n-1.$$

当 $m=1,2,\cdots$ 时,

$$P(Y=n|X=m) = \frac{p^2(1-p)^{n-2}}{p(1-p)^{m-1}} = p(1-p)^{n-m-1}, \quad n=m+1,m+2,\cdots$$

□

6.3.2 连续型情形

设二维随机向量 (X,Y) 有联合分布函数 $F(x,y)$,联合密度 $p(x,y)$,若 $p_Y(y)>0$,则在 $Y=y$ 条件下 X 的条件分布函数为

$$F_{X|Y}(x|y) = \int_{-\infty}^{x} \frac{p(u,y)}{p_Y(y)} du.$$

自然,在 $Y=y$ 条件下 X 的**条件分布密度**为

$$p_{X|Y}(x|y) = \frac{p(x,y)}{p_Y(y)}.$$

连续场合的全概率公式: 由基本公式

$$p(x,y) = p_Y(y)p(x|y) = p_X(x)p(y|x),$$

连续场合的全概率公式为:

$$p_X(x) = \int_{-\infty}^{+\infty} p(x,y)dy = \int_{-\infty}^{+\infty} p_Y(y)p(x|y)dy,$$

$$p_Y(y) = \int_{-\infty}^{+\infty} p(x,y)dx = \int_{-\infty}^{+\infty} p_X(x)p(y|x)dx.$$

连续场合的贝叶斯公式：

$$p(y|x) = \frac{p_Y(y)p(x|y)}{\int_{-\infty}^{+\infty} p_Y(y)p(x|y)dy},$$

$$p(x|y) = \frac{p_X(x)p(y|x)}{\int_{-\infty}^{+\infty} p_X(x)p(y|x)dx}.$$

例： 设二维随机向量 (X, Y) 满足二维正态分布，易知 Y 的分布密度为

$$p_Y(y) = \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left\{-\frac{(y-\mu_2)^2}{2\sigma_2^2}\right\}.$$

则在 $Y = y$ 条件下 X 的分布密度为

$$\begin{aligned} p_{X|Y}(x|y) &= \frac{p(x,y)}{p_Y(y)} \\ &= \frac{1}{\sqrt{2\pi(1-\rho^2)}\sigma_1} \exp\left\{-\frac{(x-m)^2}{2(1-\rho^2)\sigma_1^2}\right\}, \end{aligned}$$

其中 $m = \mu_1 + \rho\frac{\sigma_1}{\sigma_2}(y - \mu_2)$. □

例： 设二维随机向量 (X, Y) 的联合密度为

$$p(x,y) = \begin{cases} \frac{1}{y}e^{-y} \cdot e^{-\frac{x}{y}}, & x > 0, y > 0, \\ 0, & \text{其他} \end{cases}$$

给定 $y > 0$，试求出条件概率 $P(X > 1|Y = y)$。

解： 在 $Y = y$ 条件下 X 的条件分布密度是

$$p_{X|Y}(x|y) = \frac{p(x,y)}{p_Y(y)}.$$

其中 $p_Y(y) = \int_{-\infty}^{+\infty} p(x,y)dx = \int_0^{+\infty} \frac{1}{y}e^{-y} \cdot e^{-\frac{x}{y}}dx = e^{-y}$，于是

$$p_{X|Y}(x|y) = \begin{cases} \frac{1}{y}e^{-\frac{x}{y}}, & x > 0, y > 0 \\ 0, & x \leqslant 0, y > 0 \end{cases}$$

因此

$$P(X > 1|Y = y) = \int_1^{+\infty} \frac{1}{y}e^{-\frac{x}{y}}dx = e^{-\frac{1}{y}}.$$

□

例： 设随机变量 X 在区间 $(0, 1)$ 上随机取值，当观察到 $X = x(0 < x < 1)$ 时，随机变量 Y 在区间 $(x, 1)$ 上随机取值，求 Y 的概率密度函数 $p_Y(y)$。

解： X 服从区间 $(0,1)$ 上的均匀分布，对任意的 $x\in(0,1)$，在 $X=x$ 条件下，Y 的条件概率密度为

$$p(y|x)=\begin{cases}\frac{1}{1-x}, & y\in(x,1),\\ 0, & \text{其他}.\end{cases}$$

从而，

$$p(x,y)=p(y|x)p_X(x)=\begin{cases}\frac{1}{1-x}, & 0<x<y<1,\\ 0, & \text{其他}.\end{cases}$$

故

$$p_Y(y)=\int_{-\infty}^{+\infty}p(x,y)dx=\begin{cases}\int_0^y\frac{1}{1-x}dx=-\ln(1-y), & 0<y<1,\\ 0, & y\notin(0,1).\end{cases}$$

6.4 随机变量的独立性

随机变量的独立性： 设 X 和 Y 都是随机变量，如果对任何 $a<b,c<d$，事件 $\{a<X<b\}$ 和事件 $\{c<Y<d\}$ 相互独立，则称 X 与 Y **相互独立**。

定理： 设随机变量 X 的可能值是 $x_1,x_2,\cdots$（有限个或无穷可列个），随机变量 Y 的可能值是 $y_1,y_2,\cdots$（有限个或无穷可列个），则 X 与 Y 相互独立的充分必要条件是，对一切 i,j 下式成立：

$$P(X=x_i,Y=y_j)=P(X=x_i)P(Y=y_j).$$

定理： 设随机变量 X，Y 分别有分布密度 $p_X(x)$，$p_Y(y)$，则 X 与 Y 相互独立的充分必要条件是二元函数 $p(x,y)=p_X(x)p_Y(y)$ 是二维随机向量 (X,Y) 的联合密度。

证明： 充分性：设 $p_X(x)p_Y(y)$ 是 (X,Y) 的联合密度，则对于任何 $a<b$，$c<d$ 有

$$P(a<X<b,c<Y<d)=\int_a^b\int_c^d p_X(x)p_Y(y)dxdy$$

$$=\int_a^b p_X(x)dx\cdot\int_c^d p_Y(y)dy=P(a<X<b)P(c<Y<d).$$

表明 X 与 Y 相互独立

必要性：设 X 与 Y 相互独立，则对任何 $a<b$，$c<d$ 有

$$P(a<X<b,c<Y<d)=P(a<X<b)P(c<Y<d)$$

$$=\int_a^b p_X(x)dx\cdot\int_c^d p_Y(y)dy=\int_a^b\int_c^d p_X(x)p_Y(y)dxdy$$

表明 $p_X(x)p_Y(Y)$ 是 (X,Y) 的联合密度。 □

推论： 设二维随机向量 (X,Y) 的联合密度 $p(x,y)$ 可以表示为

$$p(x,y)=f(x)g(y),$$

其中 $f(x)\geqslant 0$，$g(y)\geqslant 0$，且 $\int_{-\infty}^{+\infty}f(x)dx$ 收敛，则 X 与 Y 相互独立。

证明： 由于 $\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}p(x,y)dxdy=1$，记 $c\triangleq\int_{-\infty}^{+\infty}f(x)dx>0$，推知 X 的分布密度是 $p_X(x)=\frac{1}{c}f(x)$，Y 的分布密度是 $p_Y(y)=cg(y)$，则 $p(x,y)=f(x)g(y)=p_X(x)p_Y(y)$，因此 X 与 Y 相互独立。 □

定理： 设 $\xi=(X,Y)$ 是二维随机向量，X 的分布函数是 $F_X(x)$，Y 的分布函数是 $F_Y(y)$，则 X 和 Y 相互独立的充分必要条件是 ξ 的分布函数 $F(x,y)$ 等于 $F_X(x)$ 与 $F_Y(y)$ 之积，即

$$F(x,y)=F_X(x)F_Y(y). \tag{6.4.1}$$

证明： 必要性：设 X 与 Y 相互独立，则对任何 $n\geqslant 1$，事件 $\{-n<X\leqslant x\}$ 与事件 $\{-n<Y\leqslant x\}$ 相互独立，于是

$$P(-n<X\leqslant x,-n<Y\leqslant y)=P(-n<X\leqslant x)P(-n<Y\leqslant y).$$

令 $n\to\infty$，即知6.4.1式成立。

充分性：设6.4.1式成立，对任何 $a<b$，$c<d$，有

$$\begin{aligned}P(a<X\leqslant b,c<Y\leqslant d)&=F(b,d)-F(a,d)-F(b,c)+F(a,c)\\&=F_X(b)F_Y(d)-F_X(a)F_Y(d)-F_X(b)F_Y(c)+F_X(a)F_Y(c)\\&=(F_X(b)-F_X(a))(F_Y(d)-F_Y(c))\\&=P(a<X\leqslant b)P(c<Y\leqslant d).\end{aligned}$$

由此知 X 与 Y 相互独立。 □

定理： 若随机变量 X 和 Y 相互独立，且方差 $D(X)$ 和 $D(Y)$ 存在，则 $D(X+Y)=D(X)+D(Y)$。

证明： 由式5.3.2知

$$D(X+Y)=E(X+Y)^2-(E(X+Y))^2=(E(X^2)+E(Y^2)-2E(XY))-((E(X))^2+(E(Y))^2+2E(X)E(Y))$$

由独立的性质知 $E(XY)=E(X)E(Y)$，则

$$D(X+Y)=E(X^2)-(E(X))^2+E(Y^2)-(E(Y))^2=D(X)+D(Y).$$

例： 设二维随机向量 (X,Y) 服从参数为 $\mu_1,\mu_2,\sigma_1,\sigma_2,\rho$ 的二维正态分布，则 X 与 Y 相互独立的充分必要条件是 $\rho=0$。

证明： 已求出 X 和 Y 的分布密度:

$$p_X(x)=\frac{1}{\sqrt{2\pi}\sigma_1}\exp\left\{-\frac{(x-\mu_1)^2}{2\sigma_1^2}\right\}.$$

$$p_Y(y)=\frac{1}{\sqrt{2\pi}\sigma_2}\exp\left\{-\frac{(y-\mu_2)^2}{2\sigma_2^2}\right\}.$$

于是

$$p_X(x)p_Y(y)=\frac{1}{2\pi\sigma_1\sigma_2}\exp\left\{-\frac{(x-\mu_1)^2}{2\sigma_1^2}-\frac{(y-\mu_2)^2}{2\sigma_2^2}\right\}.$$

结合联合密度 $p(x,y)$（式6.2.4），知当 $\rho=0$ 时，

$$p(x,y)=p_X(x)p_Y(y).$$

故 X 与 Y 相互独立。

若 X 与 Y 相互独立，则 $p_X(x)p_Y(y)$ 是 (X,Y) 的联合密度，由于 $p_X(x),p_Y(y),p(x,y)$ 均为连续函数，故

$$p(x,y)\equiv p_X(x)p_Y(y).$$

特别地 $p(\mu_1,\mu_2)=p_X(\mu_1)p_Y(\mu_2)$，于是

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}=\frac{1}{2\pi\sigma_1\sigma_2},$$

从而 $\rho=0$。 □

例： 设 (X,Y) 联合密度为

$$p(x,y)=\begin{cases}8xy, & 0\leqslant x\leqslant y\leqslant 1,\\ 0, & \text{其他}.\end{cases}$$

问 X 与 Y 是否独立?

解： 易得

$$p_X(x)=\int_{-\infty}^{+\infty}p(x,y)dy=\begin{cases}\int_x^1 8xydy=4x(1-x^2), & x\in[0,1],\\ 0, & \text{其他}.\end{cases}$$

$$p_Y(y)=\int_{-\infty}^{+\infty}p(x,y)dx=\begin{cases}\int_0^y 8xydx=4y^3, & y\in[0,1],\\ 0, & \text{其他}.\end{cases}$$

从而，

$$p(x,y)\neq p_X(x)p_Y(y)=\begin{cases}16x(1-x^2)y^3, & x,y\in[0,1],\\ 0, & \text{其他}.\end{cases}$$

故 X，Y 不独立。 $\square$

例： 假定一天内进入邮局的人数为服从参数 λ 的泊松分布的随机变量，如果每个进入邮局的人为男性的概率为 p，为女性的概率为 $1-p$，证明进入邮局的男人数和女人数是相互独立的泊松随机变量，且参数分别为 λp 和 $\lambda(1-p)$。

解： 设 X 和 Y 分别是进入邮局的男人数和女人数，则对任意的自然数 i 和 j，

$$P(X=i,Y=j)=P(X=i,Y=j|X+Y=i+j)P(X+Y=i+j).$$

注意到

$$P(X+Y=i+j)=e^{-\lambda}\frac{\lambda^{i+j}}{(i+j)!}.$$

且在给定 $i+j$ 人进入邮局的条件下，恰有 i 个男人和 j 个女人的概率是 $C_{i+j}^{i}p^{i}(1-p)^{j}$，从而

$$P(X=i,Y=j)=C_{i+j}^{i}p^{i}(1-p)^{j}e^{-\lambda}\frac{\lambda^{i+j}}{(i+j)!}=e^{-\lambda p}\frac{(\lambda p)^{i}}{i!}e^{-\lambda(1-p)}\frac{(\lambda(1-p))^{j}}{j!}.$$

故

$$P(X=i)=e^{-\lambda p}\frac{(\lambda p)^{i}}{i!}\sum_{j=0}^{+\infty}e^{-\lambda(1-p)}\frac{(\lambda(1-p))^{j}}{j!}=e^{-\lambda p}\frac{(\lambda p)^{i}}{i!},\quad i\in\mathbb{N}.$$

且

$$P(X=j)=e^{-\lambda(1-p)}\frac{(\lambda(1-p))^{j}}{j!}\sum_{i=0}^{+\infty}e^{-\lambda p}\frac{(\lambda p)^{i}}{i!}=e^{-\lambda(1-p)}\frac{(\lambda(1-p))^{j}}{j!},\quad j\in\mathbb{N}.$$

$\square$

6.5 两个随机变量的函数

6.5.1 随机向量函数的概率分布

随机向量函数的概率分布： 假设二维随机向量 (X,Y) 有联合密度 $p(x,y)$（对于离散型情形，有类似的结论），随机变量 $Z=f(X,Y)$，对于任何实数 z，令 $A=\{(x,y):f(x,y)\leqslant z\}$，则 Z 的分布函数的计算公式为

$$P(Z\leqslant z)=P(Z\in A)=\iint_{A}p(x,y)dxdy. \tag{6.5.1}$$

定理： 设二维随机向量 (X,Y) 有联合密度 $p(x,y)$，随机变量 $Z=X+Y$，则 Z 的分布密度为

$$p_Z(z)=\int_{-\infty}^{+\infty}p(x,z-x)dx,$$

证明： 令

$$A=\{(x,y):x+y\leqslant z\}$$

由式6.5.1知

$$P(Z\leqslant z)=P((X,Y)\in A)=\iint_{\{x+y\leqslant z\}}p(x,y)dxdy.$$

利用变量替换 $u=x+y$ 有

$$\begin{aligned}\iint_{\{x+y\leqslant z\}}p(x,y)dxdy&=\int_{-\infty}^{+\infty}\left(\int_{-\infty}^{z-x}p(x,y)dy\right)dx\\&=\int_{-\infty}^{+\infty}\left(\int_{-\infty}^{z}p(x,u-x)du\right)dx\\&=\int_{-\infty}^{z}\left(\int_{-\infty}^{+\infty}p(x,u-x)dx\right)du.\end{aligned}$$

因此

$$P(Z\leqslant z)=\int_{-\infty}^{z}\left(\int_{-\infty}^{+\infty}p(x,u-x)dx\right)du.$$

因此 Z 的分布函数为 $p_Z(z)=\int_{-\infty}^{+\infty}p(x,z-x)dx$。 □

推论： 设随机变量 X 和 Y 分别有分布密度 $p_X(x)$ 和 $p_Y(y)$，且 X 和 Y 相互独立，则随机变量 $Z=X+Y$ 有分布密度

$$p_Z(z)=\int_{-\infty}^{+\infty}p_X(x)p_Y(z-x)dx.$$

例： 设 (X,Y) 服从二维正态分布, 联合密度 $p(x,y)$ 为 $p(x,y)=\hat{C}\exp\left\{-\frac{u^2-2\rho uv+v^2}{2(1-\rho^2)}\right\}$，其中 $u=\frac{x-\mu_1}{\sigma_1},v=\frac{y-\mu_2}{\sigma_2}$，$\hat{C}=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}$. 求 $Z=X+Y$ 的密度。

解： 由定理知 Z 的分布密度为 $p_Z(z)=\int_{-\infty}^{\infty}p(x,z-x)dx$. 当 y 取 $z-x$ 时,

$$v=\frac{y-\mu_2}{\sigma_2}=\frac{z-(\mu_1+\sigma_1u)-\mu_2}{\sigma_2}=C-\frac{\sigma_1}{\sigma_2}u,$$

其中, $C=(z-\mu_1-\mu_2)/\sigma_2$.

此时,

$$\begin{aligned}u^2-2\rho uv+v^2&=u^2-2\rho u\left(C-\frac{\sigma_1u}{\sigma_2}\right)+\left(C-\frac{\sigma_1u}{\sigma_2}\right)^2\\&=\left(1+2\rho\frac{\sigma_1}{\sigma_2}+\left(\frac{\sigma_1}{\sigma_2}\right)^2\right)u^2-2\left(\rho+\frac{\sigma_1}{\sigma_2}\right)Cu+C^2.\end{aligned}$$

现在计算 $p_Z(z)=\int_{-\infty}^{\infty}p(x,z-x)dx$，已知:

$$p(x,z-x)=\hat{C}\left\{-\frac{Au^2-2Bu+C^2}{2\left(1-\rho^2\right)}\right\},\quad \text{其中, } u=\frac{x-\mu_1}{\sigma_1},$$

$$A=1+2\rho\frac{\sigma_1}{\sigma_2}+\left(\frac{\sigma_1}{\sigma_2}\right)^2,\quad B=\left(\rho+\frac{\sigma_1}{\sigma_2}\right)C,\quad C=\frac{z-(\mu_1+\mu_2)}{\sigma_2}.$$

配方:

$$Au^2-2Bu+C^2=A\left(u-\frac{B}{A}\right)^2-\left(\frac{B^2}{A}-C^2\right)$$

于是,

$$\begin{aligned} p_Z(z)&=\hat{C}\exp\left\{\frac{\frac{B^2}{A}-C^2}{2\left(1-\rho^2\right)}\right\}\times\int_{-\infty}^{\infty}\exp\left\{-\frac{A\left(u-\frac{B}{A}\right)^2}{2\left(1-\rho^2\right)}\right\}\sigma_1du\\ &=\tilde{C}\exp\left\{\frac{B^2-AC^2}{2\left(1-\rho^2\right)A}\right\}.\quad \tilde{C}=\hat{C}\sigma_1\sqrt{2\pi\frac{1-\rho^2}{A}}=\frac{1}{\sqrt{2\pi\sigma_2^2A}}\end{aligned}$$

已有: $p_Z(z)=\tilde{C}\exp\left\{\frac{B^2-AC^2}{2(1-\rho^2)A}\right\}$, 其中 $\tilde{C}$ 是常数,

$$A=1+2\rho\frac{\sigma_1}{\sigma_2}+\left(\frac{\sigma_1}{\sigma_2}\right)^2,B=\left(\rho+\frac{\sigma_1}{\sigma_2}\right)C,C=\frac{z-(\mu_1+\mu_2)}{\sigma_2}.$$

$$B^2-AC^2=\left(\left(\rho+\frac{\sigma_1}{\sigma_2}\right)^2-A\right)C^2=\left(\rho^2-1\right)\frac{\left(z-(\mu_1+\mu_2)\right)^2}{\sigma_2^2}.$$

因此,

$$p_Z(z)=\tilde{C}\exp\left\{-\frac{(z-\mu)^2}{2\sigma^2}\right\}=\frac{1}{\sqrt{2\pi}\sigma}\exp\left\{-\frac{(z-\mu)^2}{2\sigma^2}\right\}.$$

其中, $\mu=\mu_1+\mu_2,\sigma^2=\sigma_2^2A=\sigma_1^2+\sigma_2^2+2\rho\sigma_1\sigma_2$.

特别地, 若 $\rho=0$ (即 X,Y 相互独立), 则

$$X+Y\sim N\left(\mu_1+\mu_2,\sigma_1^2+\sigma_2^2\right).$$

□

例: 设随机变量 X 与 Y 相互独立，且 X，Y 分别有分布密度:

$$p_X(x)=\begin{cases}\lambda e^{-\lambda x}, & x>0,\\ 0, & x\leqslant 0,\end{cases}\quad(\lambda>0),$$

$$p_Y(y)=\begin{cases}\mu e^{-\mu y}, & y>0,\\ 0, & y\leqslant 0,\end{cases}\quad(\mu>0),$$

试求随机变量 $X+Y$ 的分布密度。

解: 随机变量 $Z=X+Y$ 的分布密度为

$$p(z)=\int_{-\infty}^{\infty}p_X(x)p_Y(z-x)dx.$$

易知，当 $z\leqslant 0$ 时，$p(z)=0$，设 $z>0$，则

$$p(z)=\int_0^z\lambda e^{-\lambda x}\mu e^{-\mu(z-x)}dx=\lambda\mu e^{-\mu z}\int_0^z e^{-(\lambda-\mu)x}dx$$

$$
= \begin{cases} \lambda^2 e^{-\lambda z} z, & \lambda = \mu, \\ \frac{\lambda\mu}{\lambda-\mu}\left(e^{-\mu z} - e^{-\lambda z}\right), & \lambda \neq \mu. \end{cases}
$$

□

定理: 设二维随机向量 (X,Y) 有联合密度 $p(x,y)$. 令 $Z = X/Y$(当$Y=0$ 时, 规定$Z=0$). 则 Z 为连续型, 且

$$
p_Z(z) = \int_{-\infty}^{\infty} |y| p(zy, y) dy.
$$

证明: 首先, $\frac{x}{y} \leqslant z$ 当且仅当 "$y>0$ 且 $x \leqslant yz$" 或者 "$y<0$ 且 $x \geqslant yz$." 于是,

$$
F_Z(z) = P(Y>0, X \leqslant Yz) + P(Y<0, X \geqslant Yz).
$$

其中,

$$
\begin{aligned}
P(Y>0, X \leqslant Yz) &= \int_0^{\infty} \int_{-\infty}^{yz} p(x,y) dx dy = \int_0^{\infty} \int_{-\infty}^{z} p(yu, y) y du dy \\
&= \int_{-\infty}^{z} \left(\int_0^{\infty} y p(yu, y) dy \right) du
\end{aligned}
$$

类似的,

$$
\begin{aligned}
P(Y<0, X \geqslant Yz) &= \int_{-\infty}^{0} \int_{yz}^{\infty} p(x,y) dx dy = \int_{-\infty}^{0} \int_{-\infty}^{z} p(yu, y) |y| du dy \\
&= \int_{-\infty}^{z} \left(\int_{-\infty}^{0} |y| p(yu, y) dy \right) du
\end{aligned}
$$

于是,

$$
F_Z(z) = \int_{-\infty}^{z} \left(\int_{-\infty}^{\infty} |y| p(yu, y) dy \right) du
$$

$$
p_Z(z) = \int_{-\infty}^{\infty} |y| p(zy, y) dy.
$$

□

例: 随机变量 X, Y 相互独立, 都服从 $N(0,1)$. 求随机变量 $Z = X/Y$ 的概率密度.

解: 联合密度为:

$$
p(x,y) = \frac{1}{2\pi} \exp\left\{ -\frac{x^2+y^2}{2} \right\}.
$$

因此,

$$
\begin{aligned}
p_Z(z) &= \int_{-\infty}^{\infty} |y| p(zy, y) dy = \int_{-\infty}^{\infty} |y| \frac{1}{2\pi} \exp\left\{ -\frac{(zy)^2+y^2}{2} \right\} dy \\
&= \frac{2}{2\pi} \int_0^{\infty} y \exp\left\{ -\frac{\left(z^2+1\right) y^2}{2} \right\} dy \\
&= \frac{1}{\pi} \int_0^{\infty} e^{-\left(z^2+1\right) u} du = \frac{1}{\pi\left(z^2+1\right)}.
\end{aligned}
$$

□

例： 设随机变量 X 与 Y 独立同分布，共同分布是 $N(0,1)$，试求随机变量 $Z=\sqrt{X^2+Y^2}$ 的概率分布。

解： 对任何 $z\leqslant 0$，易知 $P(Z\leqslant z)=0$，设 $z>0$，则

$$P(Z\leqslant z)=\iint_{\{x^2+y^2\leqslant z^2\}}\frac{1}{2\pi}\exp\left\{-\frac{x^2+y^2}{2}\right\}dxdy$$

做极坐标变换 $x=r\cos\theta$，$y=r\sin\theta(0\leqslant\theta<2\pi,r\geqslant 0)$，于是

$$P(Z\leqslant z)=\int_0^{2\pi}\left(\int_0^z\frac{1}{2\pi}e^{-r^2/2}rdr\right)d\theta=\int_0^z re^{-r^2/2}dr.$$

可见，$Z=\sqrt{X^2+Y^2}$ 有分布密度

$$p(z)=\begin{cases}0, & z\leqslant 0,\\ ze^{-z^2/2}, & z>0.\end{cases}$$

这样的概率分布也称为瑞利分布。 □

定理： 假设 $\xi=(X,Y)$ 为连续型, 有密度 $p(x,y)$，区域 A 满足 $P((X,Y)\in A)=1$，假设

$$\eta=(U,V),\quad 其中U=f(X,Y),\quad V=g(X,Y).$$

如果：(1) $P(\xi\in A)=1$ 且 $(f,g):A\to G$ 是一对一的;

(2) $f,g\in C^1(A)$, 且$\frac{\partial(u,v)}{\partial(x,y)}\neq 0,\forall(x,y)\in A$,

那么, η 是连续型, 且

$$p_{U,V}(u,v)=p(x(u,v),y(u,v))\left|\frac{\partial(x,y)}{\partial(u,v)}\right|,(u,v)\in G.$$

证明： 对于 $\forall D\subseteq G$, 设 $D^*=\{(x,y):(f(x,y),g(x,y))\in D\}$，易知 $D^*\subseteq A$，$(f(x,y),g(x,y))$ 是 D^* 到 D 上的一一映射，其逆映射是 $(x(u,v),y(u,v))$，根据重积分的变量替换公式，

$$\iint_{D^*}p(x,y)dxdy=\iint_D p(x(u,v),y(u,v))\left|\frac{\partial(x,y)}{\partial(u,v)}\right|dudv.$$

于是,

$$P((U,V)\in D)=P((X,Y)\in D^*)=\iint_{D^*}p(x,y)dxdy=\iint_D p(x(u,v),y(u,v))\left|\frac{\partial(x,y)}{\partial(u,v)}\right|dudv.$$

因此

$$p_{U,V}(u,v)=p(x(u,v),y(u,v))\left|\frac{\partial(x,y)}{\partial(u,v)}\right|,(u,v)\in G.$$

□

6.5.2 两个随机变量函数的数学期望

我们首先考虑一个特殊情形：$f(x,y)=xy$。

定理： 设随机变量 X 与 Y 相互独立，且 $E(X)$ 与 $E(Y)$ 都存在，则

$$E(XY)=E(X)E(Y).$$

连续情形的证明:

$$E(XY)=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}xyp_X(x)p_Y(y)dxdy=(E(X))(E(Y)).$$

定理： 若随机变量 X 与 Y 相互独立, 则

$$\mathrm{var}(X+Y)=\mathrm{var}(X)+\mathrm{var}(Y).$$

证明： 由于 $E(X+Y)=E(X)+E(Y)$，得

$$\mathrm{var}(X+Y)=E(X+Y-(EX+EY))^2$$

$$=\mathrm{var}(X)+\mathrm{var}(Y)+2E(X-E(X))(Y-E(Y)).$$

由 X 与 Y 相互独立得

$$E(X-E(X))(Y-E(Y))=E(X-E(X))E(Y-E(Y))=0$$

因此等式成立。 □

均值公式：（1）设二维随机向量 (X,Y) 的可能值是 $a_1,a_2,\cdots$（有限个或可列无穷个），$f(x,y)$ 是任何二元函数，则

$$E(f(X,Y))=\sum_i f(a_i)P((X,Y)=a_i).$$

（当 a_i 有无穷个时，要求此级数绝对收敛）。

（2）设二维随机向量 (X,Y) 有联合分布密度 $p(x,y)$，二元函数 $p(x,y)$ 满足积分

$$\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}|f(x,y)|p(x,y)dxdy$$

收敛，则

$$E(f(X,Y))=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}f(x,y)p(x,y)dxdy.$$

例： 在长为 a 的线段上，任取两个点 X 和 Y，求此两点间的平均距离。

解： 显然 X 和 Y 服从区间 $(0,a)$ 上的均匀分布，且相互独立，从而 X 和 Y 的联合密度为

$$p(x,y)=\begin{cases}\frac{1}{a^2} & x,y\in(0,a),\\ 0, & \text{其他}.\end{cases}$$

从而，两点间的平均长度为

$$\begin{aligned}E|X-Y| &= \iint_{\mathbb{R}^2}|x-y|p(x,y)dxdy\\ &= \int_0^a\int_0^a |x-y|\frac{1}{a^2}dxdy\\ &= \frac{1}{a^2}\int_0^a\left(\int_0^x(x-y)dy+\int_x^a(y-x)dy\right)dx\\ &= \frac{1}{a^2}\int_0^a\left(x^2-ax+\frac{a^2}{2}\right)dx=\frac{a}{3}.\end{aligned}$$

□

例： x, y, z 为相互独立的随机变量，h, l, f, g 为任意确定性映射。判断

(1) 令 $a=f(x,y)$, $b=g(x,z)$, a 与 b 是否独立，$a,b\mid x$ 是否独立?

(2) 令 $c=x+y$, 则 $x,y\mid c$ 是否独立?

(3) $h(l(x,y),z)$ 与 x 是否独立? $h(l(x,y),z)$ 与 x 在 $l(x,y)$ 给定条件下是否独立?

解：

(1) a 与 b 不独立，都依赖于 x，$a,b\mid x$ 独立。

(2) 不独立

(3) $h(l(x,y),z)$ 与 x 不独立，给定 $l(x,y)$ 则独立。

6.6 二维随机向量的数字特征

两个随机变量的协方差： 假设随机变量 X,Y 的期望和方差存在, 则称

$$E(X-E(X))(Y-E(Y))$$

为 X 与 Y 的**协方差**, 记为 $\mathrm{cov}(X,Y)$或σ_{XY}.
若 $\sigma_{XY}=0$, 则称 X 与 Y 不相关.

注: 协方差存在, 因为

$$2(X-EX)(Y-EY) \leqslant (X-EX)^2+(Y-EY)^2.$$

协方差的计算公式为:

$$\operatorname{cov}(X,Y)=E(XY)-(EX)(EY).$$

注意：协方差为 0 不等价于随机变量 X 和 Y 独立。

例如，令随机变量 $X \sim U(0,2\pi)$，设 $Y=\sin X$，$Z=\cos X$，Y 和 Z 的协方差为

$$\operatorname{cov}(Y,Z)=E(YZ)-E(Y)E(Z)=\frac{1}{2}E(\sin 2X)-E(\sin X)E(\cos X)=0.$$

而 Y 和 Z 显然是不独立的。

定理： 假设 X,Y 的方差存在, 则

$$(\operatorname{cov}(X,Y))^2 \leqslant \operatorname{var}(X)\cdot\operatorname{var}(Y). \tag{6.6.1}$$

证明： 若 $\operatorname{var}(X)=0$, 则 $X\equiv c$, 于是 $\operatorname{cov}(X,Y)=0$. 若 $\operatorname{var}(X)>0$, 则设

$$\begin{aligned} g(t) &:= E(t(X-EX)+(Y-EY))^2 \\ &= t^2\operatorname{var}(X)+2t\operatorname{cov}(X,Y)+\operatorname{var}(Y)\geqslant 0 \end{aligned}$$

由于不等式恒成立，故 $g(t)$ 的判别式 $\leqslant 0$，即 $(\operatorname{cov}(X,Y))^2 \leqslant \operatorname{var}(X)\cdot\operatorname{var}(Y)$. □

随机变量的相关系数： 设 $0<\operatorname{var}(X),\operatorname{var}(Y)<\infty$, 则称

$$\frac{\operatorname{cov}(X,Y)}{\sqrt{\operatorname{var}(X)}\sqrt{\operatorname{var}(Y)}}$$

为 X 与 Y 的**相关系数**, 记为 ρ_{XY}, 简记为 ρ。

定理： 设 ρ 是随机变量 X 与 Y 的相关系数，则有

(1) $|\rho|\leqslant 1$；、

(2) X 与 Y 独立, 则不相关, 从而 $\rho=0$;

(3) $|\rho|=1$ 当且仅当存在 a,b 以概率 1 使得 $Y=a+bX$.

证明： (1) 可以直接由式6.6.1推知成立。

(2) 若 X 与 Y 相互独立，则

$$E(X-E(X))(Y-E(Y))=E(X-E(X))E(Y-E(Y))=0,$$

从而 $\rho=0$。

(3) 设

$$
\begin{aligned}
g(t) &:= E(t(X-EX)+(Y-EY))^2 \\
&= t^2 \operatorname{var}(X)+2t\operatorname{cov}(X,Y)+\operatorname{var}(Y)
\end{aligned}
$$

则 $|\rho|=1$ 当且仅当 $g(t)$ 的判别式为 0 , 即存在 t_0 使得

$$
\begin{gathered}
g\left(t_0\right)=E\left(t_0(X-EX)+(Y-EY)\right)^2=0 \\
\Leftrightarrow Y=-t_0X+EY+t_0EX.
\end{gathered}
$$

□

例： 设 (X,Y) 服从二维正态分布，联合密度为

$$
\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}e^{-\frac{1}{2(1-\rho^2)}\left(u^2+v^2-2\rho uv\right)} \quad u=\frac{x-\mu_1}{\sigma_1}, v=\frac{y-\mu_2}{\sigma_2}.
$$

求 ρ_{XY}。

解： 由之前的结论，$\mu_1=E(X),\mu_2=E(Y),\sigma_1^2=\operatorname{var}(X),\sigma_2=\operatorname{var}(Y)$.

故

$$
\begin{aligned}
\rho_{XY} &= \frac{E\left(X-\mu_1\right)\left(Y-\mu_2\right)}{\sigma_1\sigma_2}=E\left(\frac{X-\mu_1}{\sigma_1}\frac{Y-\mu_2}{\sigma_2}\right) \\
&= \frac{1}{2\pi\sqrt{1-\rho^2}}\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} uv\cdot e^{-\frac{1}{2(1-\rho^2)}\left(u^2+v^2-2\rho uv\right)}dvdu.
\end{aligned}
$$

先对 v 积分, $v^2-2\rho uv+u^2=(v-\rho u)^2+\left(1-\rho^2\right)u^2$,

$$
\begin{aligned}
\int_{-\infty}^{\infty} uv\cdot e^{-\frac{1}{2(1-\rho^2)}\left(u^2+v^2-2\rho uv\right)}dv &= ue^{-\frac{u^2}{2}}\times\int_{-\infty}^{\infty} ve^{-\frac{(v-\rho u)^2}{2(1-\rho^2)}}dv \\
&= ue^{-\frac{u^2}{2}}\times\sqrt{2\pi\left(1-\rho^2\right)}\cdot\rho u.
\end{aligned}
$$

代入积分式，再对 u 积分,

$$
\rho_{XY}=\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty}\rho u^2e^{-\frac{u^2}{2}}du=\rho.
$$

□

例： 设二维随机向量 (X,Y) 的联合密度是

$$
p(x,y)=\begin{cases}\frac{2}{2\pi}\exp\left\{-\frac{1}{2}(x^2+y^2)\right\}, & xy>0, \\ 0, & \text{其他}.\end{cases}
$$

求 ρ_{XY}。

解： 上一讲第二节已经指出 $X \sim N(0,1)$，$Y \sim N(0,1)$，故

$$E(X)=E(Y)=0, \quad \mathrm{var}(X)=\mathrm{var}(Y)=1.$$

因此

$$\begin{aligned}
\mathrm{cov}(X,Y)=E(XY) &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} xyp(x,y)dxdy \\
&= \iint_{\{(x,y):xy>0\}} xy\frac{2}{2\pi}\exp\left\{-\frac{1}{2}(x^2+y^2)\right\}dxdy \\
&= \int_0^{\infty} ye^{-y^2/2}\left(\int_0^{\infty}\frac{2}{2\pi}xe^{-x^2/2}dx\right)dy \\
&+ \int_{-\infty}^{0} ye^{-y^2/2}\left(\int_{-\infty}^{0}\frac{2}{2\pi}xe^{-x^2/2}dx\right)dy \\
&= \int_0^{+\infty}\frac{2}{2\pi}ye^{-y^2/2}dy - \int_{-\infty}^{0}\frac{2}{2\pi}ye^{-y^2/2}dy \\
&= \int_0^{+\infty}\frac{2}{\pi}ye^{-y^2/2}dy = \frac{2}{\pi}
\end{aligned}$$

故相关系数为 $\rho_{XY}=\frac{2}{\pi}$。 □

6.7 条件期望

条件期望的定义： 设 X 和 Y 是两个随机变量。
(1) 若在 $Y=y$ 的条件下 X 的可能值是 $x_1,x_2,\cdots$（有限个或无穷可列个），条件概率分布是 $P(X=x_i|Y=y_i)(i=1,2,\cdots)$ 则称

$$\sum_i x_iP(X=x_i|Y=y)$$

为在 $Y=y$ 条件下 X 的**条件期望**，记为 $E(X|Y=y)$。
(2) 若在 $Y=y$ 的条件下 X 有条件分布密度 $p_{X|Y}(x|y)$，则称积分

$$\int_{-\infty}^{\infty} xp_{X|Y}(x|y)dx$$

为在 $Y=y$ 的条件下 X 的**条件期望**，记为 $E(X|Y=y)$。

设二维随机向量 (X,Y) 有联合密度 $p(x,y)$，有

$$E(X|Y=y)=\frac{1}{p_Y(y)}\int_{-\infty}^{\infty} xp(x,y)dx.$$

定理： 设二维随机向量 (X,Y) 有联合密度 $p(x,y)$，则

$$E(X)=\int_{\{y:p_Y(y)>0\}}E(X|Y=y)p_Y(y)dy.$$

证明： 首先，若 $p_Y(y)=0$，则对任何 $A>0$ 有

$$\left|\int_{-A}^{A}xp(x,y)dx\right|\leqslant A\int_{-A}^{A}p(x,y)dx\leqslant A\int_{-\infty}^{+\infty}p(x,y)dx=Ap_Y(y)=0,$$

于是

$$\int_{-\infty}^{+\infty}xp(x,y)dx=\lim_{A\to\infty}\int_{-A}^{A}xp(x,y)dx=0$$

可见

$$\begin{aligned}&\int_{\{y:p_Y(y)>0\}}E(X|Y=y)p_Y(y)dy=\int_{\{y:p_Y(y)>0\}}\left(\int_{-\infty}^{+\infty}xp(x,y)dx\right)dy\\&=\int_{-\infty}^{+\infty}\left(\int_{-\infty}^{+\infty}xp(x,y)dx\right)dy=\int_{-\infty}^{+\infty}x\left(\int_{-\infty}^{+\infty}p(x,y)dy\right)dx\\&=\int_{-\infty}^{+\infty}xp_X(x)dx=E(X).\end{aligned}$$

□

对于离散情形，有类似的定理。

定理： 设 (X,Y) 是二维随机向量，Y 的可能值是 $y_1,y_2,\cdots$（有限个或可列无穷个），$P(Y=y_i)>0(i=1,2,\cdots)$，X 的可能值是 $x_1,x_2,\cdots$（有限个或可列无穷个），且 $E(X)$ 存在，则

$$E(X)=\sum_i E(X|Y=y_i)P(Y=y_i).$$

证明： 由于 $P(X=x_k,Y=y_i)=P(X=x_k|Y=y_i)P(Y=y_i)$，知

$$\begin{aligned}E(X)&=\sum_k x_kP(X=x_k)=\sum_k x_k\sum_i P(X=x_k,Y=y_i)\\&=\sum_k\sum_i x_kP(X=x_k|Y=y_i)P(Y=y_i)\\&=\sum_i E(X|Y=y_i)P(Y=y_i).\end{aligned}$$

□

例： 设 (X,Y) 的联合密度函数为

$$p(x,y)=\begin{cases}\frac{e^{-x/y}e^{-y}}{y}, & x,y\in(0,+\infty),\\ 0, & \text{其他}.\end{cases}$$

求 $E(X|Y=y)$。

解： 对给定的 $y\in(0,+\infty)$，在 $Y=y$ 条件下 X 的条件密度函数为

$$p(x|y)=\begin{cases}\frac{p(x,y)}{p_Y(y)}=\frac{\frac{1}{y}e^{-x/y}e^{-y}}{\int_0^{+\infty}\frac{1}{y}e^{-x/y}e^{-y}dx}=\frac{e^{-x/y}}{y} & x\in(0,+\infty),\\ 0, & x\notin(0,+\infty),\end{cases}$$

因此，X 在给定 $Y=y$ 条件下的条件分布恰好是参数为 $\frac{1}{y}$ 的指数分布。从而

$$E(X|Y=y)=\int_0^{+\infty}\frac{xe^{-x/y}}{y}dx=y.$$

例：（对应郑书例 7.7）一矿工在有三个门的矿井中迷了路，第 1 个门通到一个通道，走 2 个小时可到达地面；第 2 个门通到另一个通道，走 3 个小时又回到原处；第 3 个门通到第 3 个通道，沿它走 5 个小时也回到原处，假定该矿工总是等可能从 3 个门选择任意一个进入通道，试问，该矿工到达地面平均需要多长时间。

解： 设矿工到达地面所需时间为 X，选择门的编号为 Y，则 $P(Y=1)=P(Y=2)=P(Y=3)=\frac{1}{3}$，于是

$$E(X)=\sum_{i=1}^{3}P(Y=i)E(X|Y=i)=\frac{1}{3}\sum_{i=1}^{3}E(X|Y=i).$$

易知，$E(X|Y=1)=2$，$E(X|Y=2)=E(X)+3$，$E(X|Y=3)=E(X)+5$，于是

$$E(X)=\frac{1}{3}(2+E(X)+3+E(X)+5)$$

推知 $E(X)=10$，即矿工到达地面平均要 10 小时。

7.1　n 维随机向量

> **n 维随机向量及其联合分布函数：** 设 $\xi=(X_1,\cdots,X_n)$ 是 n 维向量, 称
>
> $$F\left(x_1,\cdots,x_n\right)=P\left(X_1\leqslant x_1,\cdots,X_n\leqslant x_n\right),\quad x_1,\cdots,x_n\in\mathbb{R}^n$$
>
> 为 ξ 的**联合分布函数**, 也记为 F_ξ 或 $F_{X_1,\cdots,X_n}$.
> **离散型 n 维随机向量：** 若 ξ 取有限个或可列个值 (n 维向量), 则称 ξ 为离散型.
> **连续型 n 维随机向量：** 若存在非负可积函数 $p\left(x_1,\cdots,x_n\right)$ 使得对任意 n 维矩形 D 都有
>
> $$P(\xi\in D)=\int\cdots\int_D p\left(x_1,\cdots,x_n\right)dx_1\cdots dx_n,$$
>
> 则称 ξ 为连续型随机向量, 称 $p\left(x_1,\cdots,x_n\right)$ 为 ξ 的**联合密度**, 也记为 $P_{X_1,\cdots,X_n}$.(注：上式对一般集合 D 都成立).

n 维随机向量的边缘分布： 设 $\xi=(X_1,\cdots,X_n)$ 是 n 维向量，对任意 $1\leqslant k<n, 1\leqslant i_1<\cdots<i_k\leqslant n$, 则称 $(X_{i_1},\cdots,X_{i_k})$ 为 ξ 的 (一个 k 维) 边缘, 其分布被称为 ξ 的**边缘分布**。

例： (多项分布) 设 $U_1,\cdots,U_n$ 是取值 $1,\cdots,t$ 的随机变量，且相互独立, 都服从如下分布:

$$P\left(U_i=k\right)=p_k,\quad k=1,\cdots,t,$$

其中 $t\geqslant 2, p_k>0,\forall k$ 且 $p_1+\cdots+p_t=1$.

记

$$X_k=|\{1\leqslant i\leqslant n: U_i=k\}|=\sum_{i=1}^n 1_{\{U_i=k\}}.$$

$\xi=(X_1,\cdots,X_t)$ 的联合分布列:

$$P\left(\xi=(i_1,\cdots,i_t)\right)=\frac{n!}{i_1!\cdots i_t!}p_1^{i_1}\cdots p_t^{i_t}.$$

因为 $X_t=n-\sum_{s=1}^{t-1}X_s$， $p_t=1-\sum_{s=1}^{t-1}p_s$, 所以 ξ 与 $(X_1,\cdots,X_{t-1})$ 等价.

本例的背景模型为: n 次独立重复试验 (投郑一枚 t 面股子).

例： 口袋中有 5 个白球，8 个黑球，从中不放回的依次取出 3 个，若第 i 次取出白球，则 $X_i=1$，否则令 $X_i=0$，$i=1,2,3$，求 (X_1,X_2,X_3) 的联合分布列。

解：

$$P(X_1=0,X_2=0,X_3=0)=\frac{8\times 7\times 6}{13\times 12\times 11}=0.1958$$

$$
\begin{aligned}
&P(X_1=1,X_2=0,X_3=0)=P(X_1=0,X_2=1,X_3=0)\\
&=P(X_1=0,X_2=0,X_3=1)=\frac{8\times 7\times 5}{13\times 12\times 11}=0.1632\\
&P(X_1=1,X_2=1,X_3=0)=P(X_1=0,X_2=1,X_3=1)\\
&=P(X_1=1,X_2=0,X_3=1)=\frac{5\times 4\times 8}{13\times 12\times 11}=0.0932\\
&P(X_1=1,X_2=1,X_3=1)=\frac{5\times 4\times 3}{13\times 12\times 11}=0.0.035
\end{aligned}
$$

独立性： 若对任意 $a_i<b_i, i=1,\cdots,n$ 都有

$$
\begin{aligned}
&P\left(a_1<X_1<b_1,\cdots,a_n<X_n<b_n\right)\\
=&P\left(a_1<X_1<b_1\right)\cdots P\left(a_n<X_n<b_n\right)
\end{aligned}
$$

则称 n 个随机变量 $X_1,\cdots,X_n$ 相互独立.

若 $X_1,\cdots,X_n$ 相互独立, 且 $F_{X_i}=F_{X_1}, i=2,\cdots,n$, 则称 $X_1,\cdots,X_n$ 独立同分布.

若相互独立, 则上式中的 $a_i<X_i<b_i$ 可以改为 $X_i\in B_i$，其中 $B_1,\cdots,B_n$ 为任意一维 Borel 集。

定理： 设 $X_1,\cdots,X_n(n\geqslant 2)$ 都是随机变量，分别有分布密度 $p_1\left(x_1\right),\cdots,p_n\left(x_n\right)$，则 $X_1,\cdots,X_n$ 相互独立的充分必要条件是 n 元函数

$$
p_{X_1,\cdots,X_n}\left(x_1,\cdots,x_n\right)=p_1\left(x_1\right)\cdots p_n\left(x_n\right).
$$

为 n 维随机向量 $\left(X_1,\cdots,X_n\right)$ 的联合密度。

对于离散型随机向量, 有类似的结论, 设 n 个随机变量的取值分别为 $X_1=x_1^{(1)},x_2^{(1)},\cdots;\cdots;X_n=x_1^{(n)},x_2^{(n},\cdots$，则 $X_1,\cdots,X_n$ 相互独立的充分必要条件是

$$
\begin{aligned}
&P\left(X_1=x_{i_1}^{(1)},\cdots,X_n=x_{i_n}^{(n)}\right)\\
=&P\left(X_1=x_{i_1}^{(1)}\right)\cdots P\left(X_n=x_{i_n}^{(n)}\right)=p_{i_1}^{(1)}\cdots p_{i_n}^{(n)}
\end{aligned}
$$

定义： 若 X_i 与 X_j 相互独立, $\forall i\neq j$, 则称 $X_1,\cdots,X_n$ 两两独立.

例： 甲、乙玩石头剪刀布. 甲出 X, 乙出 Y, 结局为 Z. 则 X,Y,Z 两两独立, 但不相互独立.

例： 设随机向量 (X,Y,Z) 在矩形区域 $a<x<b,c<y<d,e<z<f$ 内服从均匀分布，求 X,Y,Z 的分布密度函数，以及 X,Y,Z 是否相互独立。

解： 由均匀分布定义

$$
p(x,y,z)=\frac{1}{(b-a)(d-c)(f-e)}\quad a<x<b,c<y<d,e<z<f.
$$

当 x, y, z 所在边界矩形是独立的，且在矩形内时有：

$$p_X(x) = \int_e^f \int_c^d \frac{1}{(b-a)(d-c)(f-e)} dydz = \frac{1}{b-a}$$

$$p_Y(y) = \int_e^f \int_a^b \frac{1}{(b-a)(d-c)(f-e)} dxdz = \frac{1}{d-c}$$

$$p_Z(z) = \int_c^d \int_a^b \frac{1}{(b-a)(d-c)(f-e)} dxdy = \frac{1}{f-e}.$$

由于 $p(x,y,z) = p_X(x)p_Y(y)p_Z(z)$，因此 X, Y, Z 之间相互独立。

定义： 设 $\mathbf{X} = (X_1, \cdots, X_m)$ 和 $\mathbf{Y} = (Y_1, \cdots, Y_n)$ 分别是 m 维和 n 维随机向量，给定 $\mathbf{y} = (y_1, \cdots, y_n)$，若 $P(\mathbf{Y} = \mathbf{y}) > 0$，则 $x_1, \cdots, x_m$ 的函数

$$P(X_1 \leqslant x_1, \cdots, X_m \leqslant x_m | \mathbf{Y} = \mathbf{y})$$

称为在 $\mathbf{Y} = \mathbf{y}$ 条件下 $\mathbf{X}$ 的**条件分布函数**，记为 $F_{\mathbf{X}|\mathbf{Y}}(x_1, \cdots, x_m|\mathbf{y})$.

若 $\mathbf{X} = (X_1, \cdots, X_m)$ 和 $\mathbf{Y} = (Y_1, \cdots, Y_n)$ 有联合密度 $p(x_1, \cdots x_m, y_1, \cdots, y_n)$，则

$$F_{\mathbf{X}|\mathbf{Y}}(x_1, \cdots, x_m|y_1, \cdots, y_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_m} \frac{p(u_1, \cdots, u_m, y_1, \cdots, y_n)}{p_Y(y_1, \cdots, y_n)} du_1 \cdots du_m,$$

这里 $p_Y(y_1, \cdots, y_n)$ 是 $\mathbf{Y} = (Y_1, \cdots, Y_n)$ 的联合密度，称这里的被积函数为在 $\mathbf{Y} = (y_1, \cdots, y_n)$ 条件下 $\mathbf{X}$ 的**条件分布密度**。

例： 设 X_1, X_2, X_3 为独立同分布的连续型随机变量，求 $P(X_3 < X_1 | X_1 = \min\{X_1, X_2\})$.

解：

$$\begin{aligned}
P(X_3 < X_1 | X_1 = \min\{X_1, X_2\}) &= \frac{P(X_3 < X_1, X_1 = \min\{X_1, X_2\})}{P(X_1 = \min\{X_1, X_2\})} \\
&= \frac{\int_{-\infty}^{+\infty} \int_{x_3}^{+\infty} \int_{x_1}^{+\infty} p(x_2) dx_2 p(x_1) dx_1 p(x_3) dx_3}{\int_{-\infty}^{+\infty} \int_{x_1}^{+\infty} p(x_2) dx_2 p(x_1) dx_1} \\
&= \frac{\int_{-\infty}^{+\infty} \int_{x_3}^{+\infty} (1 - F(x_1)) dF(x_1) dF(x_3)}{\int_{-\infty}^{+\infty} (1 - F(x_1)) dF(x_1)} \\
&= \frac{\int_{-\infty}^{+\infty} \frac{1}{2} - F(x_3) + \frac{1}{2} F^2(x_3) dF(x_3)}{1/2} = \frac{1/6}{1/2} = \frac{1}{3}
\end{aligned}$$

7.1.1 n 维随机向量的数字特征

设 $\xi=(X_1,\cdots,X_n)$ 是 n 维随机向量，每个 X_i 都有期望和方差，易知协方差

$$\sigma_{X_iX_j}=E((X_i-E(X_i))(X_j-E(X_j)))\quad(i\neq j)$$

必然存在。

期望： 称 $(E(X_1),\cdots,E(X_n))$ 为 ξ 的**期望**, 记为 $E(\xi)$.

协方差阵： 记 $\sigma_{ij}=\operatorname{cov}(X_i,X_j),\rho_{ij}=\frac{\sigma_{ij}}{\sqrt{\sigma_{ii}\sigma_{jj}}}$. 称 $\mathbf{\Sigma}=(\sigma_{ij})_{n\times n}$ 为 ξ 的**协方差阵**，$\mathbf{R}=(\rho_{ij})_{n\times n}$ 为 ξ 的**相关系数阵**。

例： 设随机变量 X_1,X_2,X_3 满足

$$aX_1+bX_2+cX_3=0,$$

$$E(X_1)=E(X_2)=E(X_3)=d,$$

$$\operatorname{var}(X_1)=\operatorname{var}(X_2)=\operatorname{var}(X_3)=\sigma^2.$$

求相关系数 $\rho_{12},\rho_{23},\rho_{31}$.

解： 对等式 $aX_1+bX_2=-cX_3$ 两侧求方差得 $a^2\sigma^2+b^2\sigma^2+2ab\sigma^2\rho_{12}=c^2\sigma^2$，由此解得

$$\rho_{12}=\frac{c^2-a^2-b^2}{2ab},$$

同理，对等式 $aX_1+cX_3=-bX_2$ 两侧求方差得

$$\rho_{13}=\frac{b^2-a^2-c^2}{2ac},$$

同理，对等式 $bX_2+cX_3=-aX_1$ 两侧求方差得

$$\rho_{23}=\frac{a^2-b^2-c^2}{2bc}.$$

特别的，当 $d\neq 0$ 时，有 $(a+b+c)d=0$，因此 $a+b+c=0$，由此可得

$$c^2=a^2+b^2+2ab,\quad b^2=a^2+c^2+2ac,\quad a^2=b^2+c^2+2bc,$$

代入 $\rho_{12},\rho_{23},\rho_{31}$ 表达式得 $\rho_{12}=\rho_{23}=\rho_{31}=1$。

7.1.2 n 个随机变量的函数

定理： 设 $Y=f(X_1,\cdots X_n)$ 的分布函数是 $F(y)$，令

$$A(y)=\{(x_1,\cdots,x_n):f(x_1,\cdots,x_n)\leqslant y\}$$

其中 y 是任意实数，则

$$F_Y(y)=P(f(\xi)\leqslant y)=\int\cdots\int_{A(y)}p(x_1,\cdots,x_n)\,dx_1\cdots dx_n$$

定理：（均值公式）设 $Y=f(X_1,\cdots X_n)$，n 维随机向量 $(X_1,\cdots,X_n)$ 有联合密度 $p(x_1,\cdots,x_n)$，则

$$EY=\int\cdots\int f(x_1,\cdots,x_n)\,p(x_1,\cdots,x_n)\,dx_1\cdots dx_n.$$

例: (χ^2 分布) 假设 $X_1,\cdots,X_n$ 独立同分布, 都服从 $N(0,1)$. 于是, $Y_n:=X_1^2+\cdots+X_n^2\sim\Gamma\left(\frac{n}{2},\frac{1}{2}\right)$, 密度为

$$p_n(x)=\frac{1}{2^{n/2}\Gamma\left(\frac{n}{2}\right)}x^{n/2-1}e^{-x/2},\quad x>0.$$

其中

$$\Gamma(\alpha)=\int_0^{+\infty}x^{\alpha-1}e^{-x}dx$$

证明： 利用数学归纳法，已经证明（郑书例 5.2）$Y_1=X_1^2$ 的分布密度是

$$p_1(x)=\frac{1}{\sqrt{2\pi}}x^{-1/2}e^{-x/2},\quad x>0.$$

设 $n=k$ 时结论成立，考虑 $n=k+1$ 的情形，由于 $Y_{k+1}=Y_k+X_{k+1}^2$，Y_k 与 X_{k+1}^2 相互独立，则 Y_{k+1} 的分布密度为

$$\begin{aligned}
p_{k+1}(x)&=\int_{-\infty}^{+\infty}p_k(u)p_1(x-u)du\\
&=\int_0^x\frac{1}{2^{k/2}\Gamma\left(\frac{k}{2}\right)}u^{k/2-1}e^{-u/2}\frac{1}{\sqrt{2\pi}}(x-u)^{-1/2}e^{-(x-u)/2}du\\
&=\int_0^x\frac{e^{-x/2}}{2^{(k+1)/2}\Gamma\left(\frac{k}{2}\right)\sqrt{\pi}}u^{k/2-1}(x-u)^{-1/2}du\\
&=\frac{x^{(k+1)/2-1}e^{-x/2}}{2^{(k+1)/2}\Gamma\left(\frac{k}{2}\right)\sqrt{\pi}}\int_0^1 v^{k/2-1}(1-v)^{-1/2}dv\quad(\text{做变量替换}u=xv)\\
&=Cx^{(k+1)/2-1}e^{-x/2}\quad(C\text{是与}x\text{无关的常数}).
\end{aligned}$$

由归一性

$$1=\int_0^{+\infty}Cx^{(k+1)/2-1}e^{-x/2}dx=C2^{(k+1)/2}\int_0^{+\infty}t^{(k+1)/2-1}e^{-t}dt$$

故

$$C=\frac{1}{2^{(k+1)/2}\Gamma\left(\frac{k+1}{2}\right)}.$$

因此 $n=k+1$ 时结论成立。对一切 $n\geqslant 1$，Y_n 均服从 $\Gamma\left(\frac{n}{2},\frac{1}{2}\right)$。称 Y_n 服从 n 个自由度的 χ^2 **（卡方）分布**。 □

例： 假设 $X_1,\cdots,X_n$ 独立同分布, 都服从参数为 λ 的指数分布，则 $Y_n:=\sum_{i=1}^n X_i \quad (n\geqslant 1)$ 的分布密度是

$$p_n(x)=\frac{\lambda^n}{(n-1)!}x^{n-1}e^{-\lambda x},\quad (x>0).$$

证明： 利用数学归纳法，当 $n=1$ 时，结论显然成立。设 $n=k$ 时结论成立，考虑 $n=k+1$ 的情形，由于 $Y_{k+1}=Y_k+X_{k+1}$，Y_k 与 X_{k+1} 相互独立，则 Y_{k+1} 的分布密度为

$$\begin{aligned}p_{k+1}(x)&=\int_{-\infty}^{+\infty}p_k(u)p_1(x-u)du\\&=\int_0^x\frac{\lambda^k}{(k-1)!}u^{k-1}e^{-\lambda u}\lambda e^{-\lambda(x-u)}du\\&=\frac{\lambda^{k+1}}{(k-1)!}e^{-\lambda x}\int_0^x u^{k-1}du=\frac{\lambda^{k+1}}{k!}x^ke^{-\lambda x}.\end{aligned}$$

因此 $n=k+1$ 时结论成立。对一切 $n\geqslant 1$，Y_n 的概率密度均为 $p_n(x)=\frac{\lambda^n}{(n-1)!}x^{n-1}e^{-\lambda x},\quad (x>0)$。并且随机变量 $Z_n=2\lambda Y_n$ 服从 $2n$ 个自由度的 χ^2 分布。 □

例： N 件产品中有 D 件次品. 随机抽取 n 件, 设包含 X 件次品. 可以利用期望的性质，求 $E(X)$ 与 $\mathrm{var}(X)$. (其中, $N\geqslant n\geqslant 2$).

解： 随机数目的分解: $X=X_1+\cdots+X_n$, 其中

$$X_i=\begin{cases}1,\ \text{若第}i\text{ 件是次品;}\\0,\ \text{若第}i\text{ 件是合格品.}\end{cases}$$

由期望的线性、伯努利分布的期望,

$$E(X)=\sum_{i=1}^n E(X_i)=\sum_{i=1}^n P(\text{ 第}i\text{ 件是次品})=n\frac{D}{N}.$$

由于 $\mathrm{var}(X)=EX^2-(EX)^2$. 根据对称性,

$$E(X^2)=\sum_{i=1}^n E(X_i^2)+\sum_{i\neq j}E(X_iX_j)=nE(X_1^2)+n(n-1)E(X_1X_2)$$

由乘法公式,

$$E(X_1X_2)=P(\text{ 前两件都是次品})=\frac{D}{N}\cdot\frac{D-1}{N-1}.$$

因此,

$$\begin{aligned}\operatorname{var}(X)&=n\frac{D}{N}+n(n-1)\frac{D}{N}\cdot\frac{D-1}{N-1}-\left(n\frac{D}{N}\right)^2\\&=\frac{n(N-n)D(N-D)}{N^2(N-1)}\quad(N>1)\end{aligned}$$

例: 随机向量 $\mathbf{X}=(X_i)_{n\times 1}$, $E(\mathbf{X})=\mu$, $\operatorname{var}(\mathbf{X})=\mathbf{\Sigma}$, 矩阵 $\mathbf{A}_{n\times n}$, 证明: $E(\mathbf{X}^\top\mathbf{A}\mathbf{X})=\operatorname{tr}(\mathbf{A}\mathbf{\Sigma})+\mu^\top\mathbf{A}\mu$.

证明:

$$\begin{aligned}E(\mathbf{X}^\top\mathbf{A}\mathbf{X})&=E(\operatorname{tr}(\mathbf{X}^\top\mathbf{A}\mathbf{X}))=E(\operatorname{tr}(\mathbf{A}\mathbf{X}\mathbf{X}^\top))\\&=\operatorname{tr}(E(\mathbf{A}\mathbf{X}\mathbf{X}^\top))=\operatorname{tr}(\mathbf{A}E(\mathbf{X}\mathbf{X}^\top))\\&=\operatorname{tr}(\mathbf{A}(\operatorname{var}(\mathbf{X})+\mu\mu^\top))=\operatorname{tr}(\mathbf{A}\mathbf{\Sigma})+\operatorname{tr}(\mathbf{A}\mu\mu^\top)\\&=\operatorname{tr}(\mathbf{A}\mathbf{\Sigma})+\mu^\top\mathbf{A}\mu.\end{aligned}$$

□

7.1.3 n 个随机变量的多个函数

定理: 设 $\xi=(X_1,\cdots,X_n)$ 为连续型随机向量，且 $\mathbb{R}^n$ 中的区域 A 满足 $P(\xi\in A)=1$，函数 $f_1(x_1,\cdots,x_n),\cdots,f_n(x_1,\cdots,x_n)$ 满足下列条件:

(1) 对任何实数 $u_1,\cdots,u_n$，方程组

$$f_k(x_1,\cdots,x_n)=u_k,\quad(k=1,\cdots,n)$$

在 A 中至多有一个解 $x_i=x_i(u_1,\cdots,u_n),\quad i=1,\cdots,n;$

(2) 对一切 $k=1,\cdots,n$，f_k 在 A 中有连续偏导数;

(3) 雅可比行列式

$$J=\frac{\partial(y_1,\cdots,y_n)}{\partial(x_1,\cdots,x_n)}\neq 0.$$

设 $Y_k=f_k(X_1,\cdots,X_n)(k=1,\cdots,n)$，$G=\{(u_1,\cdots,u_n):\text{方程组}f_k(x_1,\cdots,x_n)=u_k,(k=1,\cdots,n)\text{在}A\text{中有解}\}$，则 $\eta=(Y_1,\cdots,Y_n)$ 是连续型, 且联合密度

$$p_\eta(y_1,\cdots,y_n)=p_\xi(x_1,\cdots,x_n)\left|J^{-1}\right|,(y_1,\cdots,y_n)\in G.$$

定理： 设 $\xi=(X_1,\cdots,X_n)$ 的协方差阵为 $\mathbf{\Sigma}$, 且

$$Y_i=\sum_{j=1}^{n}a_{ij}X_j, j=1,\cdots,m.$$

记 $\mathbf{A}=(a_{ij})_{m\times n}$，$\eta=(Y_1,\cdots,Y_m)$，则

$$(E(\eta))^\top=\mathbf{A}(E(\xi))^\top,$$

$$\operatorname{cov}(\eta,\eta)=\mathbf{A\Sigma A}^\top.$$

证明: 由于 $E(Y_i)=\sum_{j=1}^n a_{ij}E(X_j)$, 故 $(E(\eta))^\top=\mathbf{A}(E(\xi))^\top$ 成立, 又由于 $Y_i-E(Y_i)=\sum_{j=1}^n a_{ij}(X_j-E(X_j))$，知

$$(Y_i-E(Y_i))(Y_k-E(Y_k))=\sum_{j=1}^{n}\sum_{l=1}^{n}a_{ij}a_{kl}(X_j-E(X_j))(X_l-E(X_l)).$$

于是

$$\begin{aligned}\operatorname{cov}(Y_i,Y_k)&=\sum_{j=1}^{n}\sum_{l=1}^{n}a_{ij}a_{kl}E(X_j-E(X_j))(X_l-E(X_l))\\&=\sum_{j=1}^{n}\sum_{l=1}^{n}a_{ij}a_{kl}\sigma_{jl},\end{aligned}$$

这里 $\sigma_{jl}=\operatorname{cov}(X_j,X_l)$.

由于 $\mathbf{\Sigma}=(\sigma_{jl})_{n\times n}$，知 $\operatorname{cov}(\eta,\eta)=\mathbf{A\Sigma A}^\top$ 成立。 $\square$

次序统计量： 设 n 个随机变量 $X_1,\cdots,X_n$ ，将它们从小到大排列:

$$X_{(1)}\leqslant X_{(2)}\leqslant\cdots\leqslant X_{(n)},$$

称 $X_{(k)}$ 为第 k 个次序统计量.

例： 设 $X_1,\cdots,X_n$ 独立同分布, 都服从 $U(0,1)$. 已知对于 $\forall 0<x<1$,

$$P\left(X_{(k)}\leqslant x\right)=\sum_{i=k}^{n}\frac{n!}{i!(n-i)!}x^i(1-x)^{n-i}.$$

求 $E(X_{(k)})$ 与 $\operatorname{var}\left(X_{(k)}\right)$.

解： 由于对于 $\forall 0<x<1$,

$$P\left(X_{(k)}\leqslant x\right)=\sum_{i=k}^{n}\frac{n!}{i!(n-i)!}x^i(1-x)^{n-i}.$$

$k \leqslant i \leqslant n-1$, 上式单项的导数是

$$
\begin{aligned}
&\frac{n!}{i!(n-i)!}\left(ix^{i-1}(1-x)^{n-i}-x^{i}(n-i)(1-x)^{n-i-1}\right)\\
&=\frac{n!}{(i-1)!(n-i)!}x^{i-1}(1-x)^{n-i}-\frac{n!}{i!(n-i-1)!}x^{i}(1-x)^{n-i-}\\
&=a_{i-1}-a_{i},
\end{aligned}
$$

$i=n$ 时, $(x^n)'=a_{n-1}$, 于是, $\forall 0<x<1$,

$$
p_{X_{(k)}}(x)=\sum_{i=k}^{n-1}(a_{i-1}-a_i)+a_{n-1}=a_{k-1}.
$$

已有 $q_k(x):=p_{X_{(k)}}(x)=\frac{n!}{(k-1)!(n-k)!}x^{k-1}(1-x)^{n-k}$，且对于 $\forall \ell, m \geqslant 1$，由分部积分

$$
\begin{aligned}
\int_0^1 x^{\ell}(1-x)^m dx &= \frac{m}{\ell+1}\int_0^1 x^{\ell+1}(1-x)^{m-1}dx\\
=\cdots &= \frac{m!}{(\ell+1)\cdots(\ell+m)}\int_0^1 x^{\ell+m}dx=\frac{\ell!m!}{(\ell+m+1)!}
\end{aligned}
$$

期望: 取 $\ell=k, m=n-k$, 知

$$
\begin{aligned}
EX_{(k)}&=\int_0^1 xq_k(x)dx=\frac{n!}{(k-1)!(n-k)!}\int_0^1 x^k(1-x)^{n-k}dx\\
&=\frac{n!}{(k-1)!(n-k)!}\cdot\frac{k!(n-k)!}{(n+1)!}=\frac{k}{n+1}.
\end{aligned}
$$

二阶矩：取 $\ell=k+1, m=n-k$,

$$
\begin{aligned}
EX_{(k)}^2&=\int_0^1 x^2q_k(x)dx=\frac{n!}{(k-1)!(n-k)!}\int_0^1 x^{k+1}(1-x)^{n-k}dx\\
&=\frac{n!}{(k-1)!(n-k)!}\cdot\frac{(k+1)!(n-k)!}{(n+2)!}=\frac{k(k+1)}{(n+1)(n+2)}.
\end{aligned}
$$

方差:

$$
\begin{aligned}
\operatorname{var}\left(X_{(k)}\right)&=EX_{(k)}^2-\left(EX_{(k)}\right)^2=\frac{k(k+1)}{(n+1)(n+2)}-\frac{k^2}{(n+1)^2}\\
&=\frac{k^2(n+1)+k(n+1)-k^2(n+2)}{(n+1)^2(n+2)}=\frac{k(n+1-k)}{(n+1)^2(n+2)}.
\end{aligned}
$$

7.1.4 n 维正态分布

我们已经定义过 n 维正态分布。

n **维正态分布：** 假设 n 维随机向量 ξ 有如下的联合密度, 则称 ξ 服从 n 维正态分布, 记为 $\xi \sim N(\mu, \mathbf{\Sigma})$.

$$p(\mathbf{x}) = \frac{1}{\sqrt{2\pi}^n \sqrt{|\mathbf{\Sigma}|}} \exp\left\{-\frac{1}{2}(\mathbf{x}-\mu)^\top \mathbf{\Sigma}^{-1}(\mathbf{x}-\mu)\right\}.$$

定理 8.1： 设 $(X_1, \cdots, X_n)^\top \sim N(\mu, \mathbf{\Sigma})$，$\mathbf{A} = (a_{ij})_{n\times n}$，$|\mathbf{A}| \neq 0$，$Y_i = \sum_{j=1}^n a_{ij}X_j (i = 1, \cdots, n)$，则

$$(Y_1, \cdots, Y_n)^\top \sim N(\mathbf{A}\mu, \mathbf{A\Sigma A}^\top). \tag{7.1.1}$$

证明： 设 $\mathbf{y} = (y_1, \cdots, y_n)^\top$，$\mathbf{x} = (x_1, \cdots, x_n)^\top$，对于任意 n 维矩形 D，记

$$D^* = \{\mathbf{x} = (x_1, \cdots, x_n)^\top : \mathbf{Ax} \in D\},$$

则

$$P((Y_1, \cdots, Y_n)^\top \in D) = P((X_1, \cdots, X_n)^\top \in D^*) = \iint_{D^*} \frac{1}{\sqrt{2\pi}^n \sqrt{|\mathbf{\Sigma}|}} \exp\left\{-\frac{1}{2}(\mathbf{x}-\mu)^\top \mathbf{\Sigma}^{-1}(\mathbf{x}-\mu)\right\} d\mathbf{x}$$

做变量替换 $\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}$，雅可比行列式为

$$\frac{\partial(x_1, \cdots, x_n)}{\partial(y_1, \cdots, y_n)} = |A^{-1}| = |A|^{-1}.$$

于是

$$\begin{aligned} P((Y_1, \cdots, Y_n)^\top \in D) &= \int \cdots \int_D \frac{1}{\sqrt{2\pi}^n \sqrt{|\mathbf{\Sigma}|}} \exp\left\{-\frac{1}{2}(\mathbf{A}^{-1}\mathbf{y}-\mu)^\top \mathbf{\Sigma}^{-1}(\mathbf{A}^{-1}\mathbf{y}-\mu)\right\} ||A||^{-1} d\mathbf{y} \\ &= \int \cdots \int_D \frac{1}{\sqrt{2\pi}^n \sqrt{|\mathbf{A\Sigma A}^\top|}} \exp\left\{-\frac{1}{2}(\mathbf{y}-\mathbf{A}\mu)^\top (\mathbf{A\Sigma A}^\top)^{-1}(\mathbf{y}-\mathbf{A}\mu)\right\} d\mathbf{y}. \end{aligned}$$

这表明 $(Y_1, \cdots, Y_n)^\top \sim N(\mathbf{A}\mu, \mathbf{A\Sigma A}^\top)$. □

推论： 若 ξ 服从 n 元正态分布 $N(\mu, \mathbf{\Sigma})$，则存在一个正交变换 $\mathbf{U}$，使得 $\eta = \mathbf{U}\xi$ 是一个具有独立正态分布分量的随机向量，它的数学期望为 $\mathbf{U}\mu$，方差分量是 $\mathbf{\Sigma}$ 的特征值。

证明： 对实对称矩阵 $\mathbf{\Sigma}$，存在正交矩阵 $\mathbf{U}$，使得 $\mathbf{U\Sigma U}^\top = \mathbf{D}$，其中 $\mathbf{D}$ 为对角矩阵，对角元是 $\mathbf{\Sigma}$ 的特征值，若 $\mathbf{\Sigma}$ 的秩为 r，则有 r 个特征值不为零。

将这里的 $\mathbf{U}$ 作为定理 8.1 的变换矩阵，则可得推论结果。 □

推论： 正交变换下，多维标准正态变量保持其独立性，同方差性不变。

证明： 设 $\mathbf{X} = (X_1, \cdots, X_n)^\top$ 服从 n 元正态分布，且 X_i 相互独立有相同的方差 σ^2，则协方差矩阵 $D(\mathbf{X}) = \sigma^2\mathbf{I}$, 若 $\mathbf{U}$ 是正交阵，$\mathbf{Y} = \mathbf{UX}$，由定理 8.1 知 $\mathbf{Y}$ 服从正态分布，协方差为

$$\mathbf{U}\sigma^2\mathbf{I}\mathbf{U}^\top = \sigma^2\mathbf{I}$$

因此 η 仍然是相互独立且具有相同方差。 $\square$

推论： 若 $\xi \sim N(\mu, \mathbf{\Sigma})$，其中 $\mathbf{\Sigma}$ 是 n 阶正定阵，则

$$(\xi-\mu)^\top \mathbf{\Sigma}^{-1}(\xi-\mu) \sim \chi_n^2$$

证明： 设正定阵 $\mathbf{\Sigma} = \mathbf{L}\mathbf{L}^\top$，则

$$(\xi-\mu)^\top \mathbf{\Sigma}^{-1}(\xi-\mu) = (\xi-\mu)^\top (\mathbf{L}\mathbf{L}^\top)^{-1}(\xi-\mu)$$

$$= [\mathbf{L}^{-1}(\xi-\mu)]^\top[\mathbf{L}^{-1}(\xi-\mu)] = \eta^\top\eta$$

其中 $\eta = \mathbf{L}^{-1}(\xi-\mu)$，由定理 8.1 知它是均值为 $\mathbf{0}$ 的 n 维正态变量，协方差矩阵为

$$\mathbf{L}^{-1}\mathbf{\Sigma}(\mathbf{L}^{-1})^\top = \mathbf{I}$$

从而 η 的各个分量是相互独立的标准状态变量，因此

$$\eta^\top\eta = \chi_1^2 + \cdots + \chi_1^2 \sim \chi_n^2.$$

$\square$

定理 8.2： 设 $(X_1, \cdots, X_m, X_{m+1}, \cdots, X_n)^\top \sim N(\mu, \mathbf{\Sigma})(1 \leqslant m < n)$，且

$$\mu = \begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \end{bmatrix}, \quad \mathbf{\Sigma} = \begin{bmatrix} \mathbf{\Sigma}^{(1)} & \mathbf{0} \\ \mathbf{0} & \mathbf{\Sigma}^{(2)} \end{bmatrix},$$

其中 $\mu^{(1)}$ 是 m 维列向量，$\mu^{(2)}$ 是 $n-m$ 维列向量，$\mathbf{\Sigma}^{(1)}$ 是 m 阶矩阵，$\mathbf{\Sigma}^{(2)}$ 是 $n-m$ 阶矩阵，则

$$\mathbf{X}^{(1)} = (X_1, \cdots, X_m)^\top \sim N(\mu^{(1)}, \mathbf{\Sigma}^{(1)}), \quad \mathbf{X}^{(2)} = (X_{m+1}, \cdots, X_n)^\top \sim N(\mu^{(2)}, \mathbf{\Sigma}^{(2)}).$$

证明： 记 $\mathbf{x}^{(1)} = (x_1, \cdots, x_m)^\top$，$\mathbf{x}^{(2)} = (x_{m+1}, \cdots, x_n)^\top$，易知 $(X_1, \cdots, X_m, X_{m+1}, \cdots, X_n)^\top$ 的联合密度为

$$p(x_1, \cdots, x_m, x_{m+1}, \cdots, x_n) = \frac{1}{\sqrt{2\pi}^n\sqrt{|\mathbf{\Sigma}^{(1)}|}} \exp\left\{-\frac{1}{2}(\mathbf{x}^{(1)}-\mu^{(1)})^\top(\mathbf{\Sigma}^{(1)})^{-1}(\mathbf{x}^{(1)}-\mu^{(1)})\right\}$$

$$\cdot\frac{1}{\sqrt{2\pi}^n\sqrt{|\mathbf{\Sigma}^{(2)}|}} \exp\left\{-\frac{1}{2}(\mathbf{x}^{(2)}-\mu^{(2)})^\top(\mathbf{\Sigma}^{(2)})^{-1}(\mathbf{x}^{(2)}-\mu^{(2)})\right\}.$$

于是

$$P((X_1, \cdots, X_m)^\top \in D) = \int\cdots\int_D \frac{1}{\sqrt{2\pi}^n\sqrt{|\mathbf{\Sigma}^{(1)}|}} \exp\left\{-\frac{1}{2}(\mathbf{x}^{(1)}-\mu^{(1)})^\top(\mathbf{\Sigma}^{(1)})^{-1}(\mathbf{x}^{(1)}-\mu^{(1)})\right\} d\mathbf{x}^{(1)}$$

$$\cdot \int \cdots \int_{\mathscr{R}^{n-m}} \frac{1}{\sqrt{2\pi}^n \sqrt{|\mathbf{\Sigma}^{(2)}|}} \exp\left\{-\frac{1}{2}(\mathbf{x}^{(2)} - \mu^{(2)})^\top (\mathbf{\Sigma}^{(2)})^{-1} (\mathbf{x}^{(2)} - \mu^{(2)})\right\} d\mathbf{x}^{(2)}$$

$$= \int \cdots \int_{D} \frac{1}{\sqrt{2\pi}^n \sqrt{|\mathbf{\Sigma}^{(1)}|}} \exp\left\{-\frac{1}{2}(\mathbf{x}^{(1)} - \mu^{(1)})^\top (\mathbf{\Sigma}^{(1)})^{-1} (\mathbf{x}^{(1)} - \mu^{(1)})\right\} d\mathbf{x}^{(1)}.$$

这表明 $(X_1, \cdots, X_m)^\top \sim N(\mu^{(1)}, \mathbf{\Sigma}^{(1)})$，同理知 $(X_{m+1}, \cdots, X_n)^\top \sim N(\mu^{(2)}, \mathbf{\Sigma}^{(2)})$。 □

在上述定理的假设条件下，$(X_1, \cdots, X_m)^\top$ 与 $(X_{m+1}, \cdots, X_n)^\top$ 相互独立。进而推知多元正态分布 $(X_1, \cdots, X_n)$ 两两独立的充分必要条件是两两不相关。

定理 8.3： $(X_1, \cdots, X_m, \cdots, X_n)^\top \sim N(\mu, \mathbf{\Sigma})(1 \leqslant m < n)$，则

$$(X_1, \cdots, X_m) \sim N(\mu^{(1)}, \mathbf{\Sigma}_{11})$$

其中

$$\mathbf{\Sigma} = \begin{bmatrix} \mathbf{\Sigma}_{11} & \mathbf{\Sigma}_{12} \\ \mathbf{\Sigma}_{21} & \mathbf{\Sigma}_{22} \end{bmatrix}, \quad \mu = \begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \end{bmatrix}.$$

证明： 令

$$\begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} = \begin{bmatrix} \mathbf{I}_m & \mathbf{0} \\ -\mathbf{\Sigma}_{21}\mathbf{\Sigma}_{11}^{-1} & \mathbf{I}_{n-m} \end{bmatrix} \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} = \mathbf{B} \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix}$$

则由式7.1.1知

$$(Y_1, \cdots, Y_n)^\top \sim N(\mathbf{B}\mu, \mathbf{B\Sigma B}^\top).$$

易知

$$\mathbf{B}\mu = \mathbf{B} \begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \end{bmatrix}, \quad \mathbf{B\Sigma B}^\top = \begin{bmatrix} \mathbf{\Sigma}_{11} & \mathbf{0} \\ \mathbf{0} & \mathbf{\Sigma}_{22} - \mathbf{\Sigma}_{21}\mathbf{\Sigma}_{11}^{-1}\mathbf{\Sigma}_{12} \end{bmatrix}.$$

根据定理知

$$(X_1, \cdots, X_m) \sim N(\mu^{(1)}, \mathbf{\Sigma}_{11}).$$

□

定理 8.4： 设 $(X_1, \cdots, X_n)^\top \sim N(\mu, \mathbf{\Sigma})$，$\mathbf{A}$ 是 $m \times n$ 的矩阵且 $\mathbf{A}$ 的秩等于 m，$(Y_1, \cdots, Y_m)^\top = \mathbf{A}(X_1, \cdots, X_m)^\top$，则

$$(Y_1, \cdots, Y_m)^\top \sim N(\mathbf{A}\mu, \mathbf{A\Sigma A}^\top).$$

证明： 若 $m = n$，则结论与式7.1.1相同；若 $m < n$，则在 $\mathbf{A}$ 下方添加 $n - m$ 行使得到的矩阵

$$\mathbf{B} = \begin{bmatrix} \mathbf{A} \\ \mathbf{C} \end{bmatrix}$$

非奇异，令

$$(Z_1, \cdots Z_n)^\top = \mathbf{B}(X_1, \cdots, X_n)^\top.$$

由式7.1.1知

$$(Z_1, \cdots Z_n)^\top \sim N(\mathbf{B}\mu, \mathbf{B\Sigma B}^\top).$$

注意到

$$\mathbf{B}\mu = \begin{bmatrix} \mathbf{A}\mu \\ \mathbf{C}\mu \end{bmatrix}, \quad \mathbf{B\Sigma B}^\top = \begin{bmatrix} \mathbf{A\Sigma A}^\top & \mathbf{A\Sigma C}^\top \\ \mathbf{C\Sigma A}^\top & \mathbf{C\Sigma C}^\top \end{bmatrix},$$

$$(Z_1, \cdots Z_m)^\top = (Y_1, \cdots Y_m)^\top.$$

由定理 8.3 知定理成立。 □

定理 8.5： 设 $(X_1, \cdots, X_n)^\top \sim N(\mu, \mathbf{\Sigma})$，则有

（1）$E(\mathbf{X}) \triangleq (E(X_1), \cdots, E(X_n))^\top = \mu$；

（2）$\mathrm{cov}(\mathbf{X}, \mathbf{X}) = \mathbf{\Sigma}$.

证明： 先考虑 $\mathbf{\Sigma} = \mathbf{I}$ 的情形，此时 $X_1, \cdots, X_n$ 独立同分布，且 $X_i \sim N(\mu_i, 1)$，于是

$$(E(X_1), \cdots, E(X_n))^\top = \mu, \quad \mathrm{cov}(\mathbf{X}, \mathbf{X}) = \mathbf{I},$$

故 $\mathbf{\Sigma} = \mathbf{I}$ 时定理成立。

现考虑一般情形，设 $\mathbf{\Sigma}$ 是任何 n 阶正定矩阵，存在方阵 $\mathbf{A}$，使得 $\mathbf{A\Sigma A} = \mathbf{I}$，令 $\mathbf{Y} = \mathbf{AX}$，由定理 8.1 知 $\mathbf{Y} \sim N(\mathbf{A}\mu, \mathbf{A\Sigma A})$，即

$$Y \sim N(\mathbf{A}\mu, \mathbf{I}),$$

因此

$$E(\mathbf{Y}) = \mathbf{A}\mu, \quad \mathrm{cov}(\mathbf{Y}, \mathbf{Y}) = \mathbf{I}.$$

由于 $\mathbf{X} = \mathbf{A}^{-1}\mathbf{Y}$，利用期望的线性性质得到

$$E(\mathbf{X}) = \mathbf{A}^{-1}E(\mathbf{Y}) = \mu,$$

$$\mathrm{cov}(\mathbf{X}, \mathbf{X}) = \mathbf{A}^{-1}\mathrm{cov}(\mathbf{Y}, \mathbf{Y})(\mathbf{A}^{-1})^\top = \mathbf{\Sigma}.$$

□

例： 若 $\xi \sim N(0, I_d)$，试证明 $\frac{\xi}{||\xi||}(\xi \neq 0)$ 为 $||x||_2 = 1$ 上的均匀分布。

证明： 只需说明 $\forall ||x||_2 = 1$，$R^\top R = I_d$，有 $p_{\frac{\xi}{||\xi||}}(x) = p_{\frac{\xi}{||\xi||}}(Rx)$.

由于概率密度函数 $p_{\frac{\xi}{||\xi||}}(Rx)$ 等价于 $\frac{\xi}{||\xi||}$ 经过线性变换 $R^\top$ 后，得到的变量 $Z=\frac{R^\top\xi}{||\xi||}$ 的概率密度函数，

$$p_{\frac{\xi}{||\xi||}}(Rx)=p_{\frac{R^\top\xi}{||\xi||}}(x),$$

注意到 $||R^\top\xi||=||\xi||$，故

$$p_{\frac{\xi}{||\xi||}}(Rx)=p_{\frac{R^\top\xi}{||R^\top\xi||}}(x)$$

由定理 8.1 有 $R^\top\xi\sim N(0,I_d)$, 因此

$$p_{\frac{\xi}{||\xi||}}(Rx)=p_{\frac{R^\top\xi}{||R^\top\xi||}}(x)=p_{\frac{\xi}{||\xi||}}(x).$$

例： 若 ξ_1，ξ_2 是相互独立的随机变量，均服从标准正态分布，而

$$\eta_1=a\xi_1+b\xi_2,\quad \eta_2=c\xi_1+d\xi_2,$$

则由于

$$E(\eta_1)=0,\quad D(\eta_1)=a^2D(\xi_1)+b^2D(\xi_2)=a^2+b^2$$
$$E(\eta_2)=0,\quad D(\eta_2)=c^2D(\xi_1)+d^2D(\xi_2)=c^2+d^2$$
$$\mathrm{cov}(\eta_1,\eta_2)=ac+bd,\quad \rho_{\eta_1,\eta_2}=\frac{ac+bd}{\sqrt{a^2+b^2}\sqrt{c^2+d^2}}$$

因此 $\eta_1\sim N(0,a^2+b^2)$，$\eta_2\sim N(0,c^2+d^2)$，且

$$(\eta_1,\eta_2)\sim N(0,0,a^2+b^2,c^2+d^2,\frac{ac+bd}{\sqrt{a^2+b^2}\sqrt{c^2+d^2}})$$

当 $ac+bd=0$ 时，$\rho_{\eta_1,\eta_2}=0$，η_1 与 η_2 独立。

当 $\rho_{\eta_1,\eta_2}=\pm1$，即 $(ac+bd)^2=(a^2+b^2)(c^2+d^2)$ 时，$(\eta_1,\eta_2)(\eta_1,\eta_2)$ 退化为一个点。退化为一维分布，而当 $a=b=c=d=0$ 时，(η_1,η_2) 退化为一个点。

条件分布：若 $\xi=\begin{pmatrix}\xi_1\\ \xi_2\end{pmatrix}$ 服从 n 元正态分布 $N(\mu,\mathbf{\Sigma})$, $E(\xi_1)=\mu_1$, $E(\xi_2)=\mu_2$, $\mathbf{\Sigma}=\begin{bmatrix}\mathbf{\Sigma}_{11} & \mathbf{\Sigma}_{12}\\ \mathbf{\Sigma}_{21} & \mathbf{\Sigma}_{22}\end{bmatrix}$, 则在给定 $\xi_1=x_1$ 下，ξ_2 的分布仍然为正态分布，条件数学期望

$$\mu_{2|1}=E(\xi_2|\xi_1=x_1)=\mu_2+\mathbf{\Sigma}_{21}\mathbf{\Sigma}_{11}^{-1}(x_1-\mu_1)$$

条件方差

$$\mathbf{\Sigma}_{22|1}=\mathbf{\Sigma}_{22}-\mathbf{\Sigma}_{21}\mathbf{\Sigma}_{11}^{-1}\mathbf{\Sigma}_{12}$$

这里 $E(\xi_2|\xi_1=x_1)$ 称为 ξ_2 关于 ξ_1 的回归，注意到它是 x_1 的线性函数。又有条件方差与 x_1 无关。

证明： 考虑

$$\begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \begin{bmatrix} \boldsymbol{A}_{11} & \boldsymbol{A}_{12} \\ \boldsymbol{A}_{21} & \boldsymbol{A}_{22} \end{bmatrix} = \boldsymbol{I}.$$

其中，$\boldsymbol{\Sigma}_{12} = \boldsymbol{\Sigma}_{21}^\top$ 和 $\boldsymbol{A}_{12} = \boldsymbol{A}_{21}^\top$。则有

$$\boldsymbol{\Sigma}_{11}\boldsymbol{A}_{12} + \boldsymbol{\Sigma}_{12}\boldsymbol{A}_{22} = \boldsymbol{0}.$$

则 $\boldsymbol{A}_{22}^{-1}\boldsymbol{A}_{12}^\top = -\boldsymbol{\Sigma}_{12}^\top\boldsymbol{\Sigma}_{11}^{-1}$. 所以 $\boldsymbol{A}_{22}^{-1}\boldsymbol{A}_{21} = -\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}$. 另外有

$$\boldsymbol{\Sigma}_{12}\boldsymbol{A}_{12} + \boldsymbol{\Sigma}_{22}\boldsymbol{A}_{22} = \boldsymbol{I}.$$

则有

$$(\boldsymbol{\Sigma}_{22} - \boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12})\boldsymbol{A}_{22} = \boldsymbol{I}.$$

而配方有

$$\begin{aligned} &(x_2-\mu_2)^\top \boldsymbol{A}_{22}(x_2-\mu_2)^\top + 2(x_2-\mu_2)^\top \boldsymbol{A}_{21}(x_1-\mu_1) \\ =& \left[x_2-\mu_2+\boldsymbol{A}_{22}^{-1}\boldsymbol{A}_{21}(x_1-\mu_1)\right]^\top \boldsymbol{A}_{22}\left[x_2-\mu_2+\boldsymbol{A}_{22}^{-1}\boldsymbol{A}_{21}(x_1-\mu_1)\right] \\ &+ f(x_1). \end{aligned}$$

得到证明。

例： 二元场合，若 $(\xi_1, \xi_2)^\top$ 服从正态分布 $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$，则

$$\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \quad \boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}.$$

在给定 $\xi_1 = x_1$ 条件下，ξ_2 的条件分布还是正态分布而且其条件期望由定理可以推知

$$E(\xi_2|\xi_1 = x_1) = \mu_2\rho\frac{\sigma_2}{\sigma_1}(x_1-\mu_1)$$

条件方差可以推知为

$$\sigma_2^2 - \frac{(\rho\sigma_1\sigma_2)^2}{\sigma_1^2} = \sigma_2^2(1-\rho^2).$$

8.1 随机序列的收敛性

设随机变量 $\eta=\eta(\omega),\xi_1=\xi_1(\omega),\xi_2=\xi_2(\omega),\cdots$ 都是概率空间 $(\Omega,\mathscr{F},P)$ 上的实值函数，我们在表述上常常省去 ω。

定义： 称随机变量 $\xi_1,\xi_2,\cdots$ **依概率收敛**于 η，若对任何 $\varepsilon>0$，有

$$\lim_{n\to\infty}P(\{\omega:|\xi_n(\omega)-\eta(\omega)|\geqslant\varepsilon\})=0.$$

此时记作 $\xi_n\xrightarrow{P}\eta$.

定义： 称随机变量 $\xi_1,\xi_2,\cdots$ **概率为** 1 **（或几乎必然）的收敛**于 η，若

$$P(\{\omega:\lim_{n\to\infty}\xi_n(\omega)=\eta(\omega)\})=1.$$

此时记作 $\xi_n\xrightarrow{a.s.}\eta.$，其中 a.s. 是 almost surely 的缩写。

定义： 称随机变量 $\xi_1,\xi_2,\cdots$ **弱收敛**于 η，若对于 η 的分布函数 $F(x)$ 的任何连续点 x，下式皆成立：

$$\lim_{n\to\infty}P(\{\omega:\xi_n(\omega)\leqslant x\})=P(\{\omega:\eta(\omega)\leqslant x\}).$$

此时记作 $\xi_n\xrightarrow{\omega}\eta$。弱收敛也称为依分布收敛。

定理： 设 $\xi_n\xrightarrow{a.s.}\eta$，则 $\xi_n\xrightarrow{P}\eta$。

证明（不做要求）： 研究集合 $A=\{\omega:\xi_(\omega),\xi_2(\omega),\cdots\text{不收敛于}\eta(\omega)\}$，假设 $\xi_n\xrightarrow{a.s.}\eta$，知 $P(A)=0$，对任何 $\varepsilon>0$，令

$$B=\{\omega:\text{有无穷多个}n,\text{使得}|\xi_n(\omega)-\eta(\omega)|\geqslant\varepsilon\},$$

$$B_m=\{\omega:\text{有}n\geqslant m,\text{使得}|\xi_n(\omega)-\eta(\omega)|\geqslant\varepsilon\},$$

则 $B_m\supset B_{m+1}$，$B=\cap_{m=1}^{\infty}B_m$，于是

$$\lim_{m\to\infty}P(B_m)=P(B)\leqslant P(A)=0,$$

因为 $P(|\xi_n-\eta|\geqslant\varepsilon)\leqslant P(B_m)$，所以

$$\lim_{m\to\infty}P(|\xi_n-\eta|\geqslant\varepsilon)=0.$$

表明 $\xi_n\xrightarrow{P}\eta$。 □

注意，逆定理不成立：

例（不做要求）： 设 $\Omega=(0,1)$，$\mathscr{F}$ 由 $(0,1)$ 中所有 Borel 子集组成，P 是这样的概率测度：对任何区间 $(a,b)(0\leqslant a<b\leqslant 1)$，$P((a,b))=b-a$，在概率空间 $(\Omega,\mathscr{F},P)$ 上考虑下列随机变量序列：

对任何正整数 k 及 $j=1,\cdots,2^k$，令

$$X_{k1}=\begin{cases}1, & 0<\omega<\frac{1}{2^k},\\ 0, & \text{其他};\end{cases}\quad,\quad X_{kj}=\begin{cases}1, & \frac{j-1}{2^k}<\omega<\frac{j}{2^k},\\ 0, & \text{其他};\end{cases}\quad (j>1).$$

这些 $X_{kj}: k\geqslant 1, j=1,\cdots,2^k\}$ 可排成一个序列：$X_{11},X_{12},X_{21},X_{22},X_{23},X_{24},\cdots$（按照字典排列法，将第一个足标从小到大排，若相同则按第二个足标从小到大排），将该序列记为 $\xi_1,\xi_2,\cdots$，其中 $\xi_n=X_{k_nj_n}$，则对任何 $\varepsilon\in(0,1)$ 有：

$$P(|\xi_n|\geqslant\varepsilon)=P(\xi_n=1)=\frac{1}{2_n^k}$$

在 $n\to\infty$ 时 $k_n\to\infty$，故有 $\lim_{n\to\infty}P(|\xi_n|\geqslant\varepsilon)=0$，这表明 $\xi_n\xrightarrow{P}0$.

而对于任何 $\omega\in(0,1)$, $\lim_{n\to\infty}\xi_n(\omega)$ 不存在。实际上对任何 ω 和 k, 存在唯一的 j_k 使得 $X_{kj_k}(\omega)=1$，而 $j\neq j_k$ 时 $X_{kj}(\omega)=0$，由此可见，$\lim_{n\to\infty}\xi_n(\omega)$ 不存在。即 $\xi_n\xrightarrow{a.s}\eta$ 不成立。

定理（不做要求）： 设 $\xi_n\xrightarrow{P}\eta$，则 $\xi_n\xrightarrow{\omega}\eta$.

证明： 设 x_0 是 η 的分布函数 $F(x)$ 的连续点，记

$$F_n(x)=P(\xi_n\leqslant x)\quad(n=1,2,\cdots).$$

易知，对任何 $\varepsilon>0$，有

$$\{\xi_n\leqslant x_0\}\subset\{\xi_n-\eta\leqslant-\varepsilon\}\cup\{\eta\leqslant x_0+\varepsilon\},$$

于是 $P(\xi_n\leqslant x_0)\leqslant P(\xi_n-\eta\leqslant-\varepsilon)+P(\eta\leqslant x_0+\varepsilon)$.

故

$$F_n(x_0)-F(x_0)\leqslant P(|\xi_n-\eta|\geqslant\varepsilon)+F(x_0+\varepsilon)-F(x_0).$$

类似地，有

$$\{\xi_n\leqslant x_0\}\supset\{\xi_n-\eta\leqslant\varepsilon,\eta\leqslant x_0-\varepsilon\},$$

于是

$$P(\xi_n\leqslant x_0)\geqslant P(\xi_n-\eta\leqslant\varepsilon,\eta\leqslant x_0-\varepsilon)\geqslant P(\eta\leqslant x_0-\varepsilon)-P(\xi_n-\eta>\varepsilon)$$

故

$$F_n(x_0)-F(x_0)\geqslant F(x_0-\varepsilon)-F(x_0)-P(|\xi_n-\eta|\geqslant\varepsilon).$$

因此

$$|F_n(x_0)-F(x_0)|\leqslant F(x_0+\varepsilon)-F(x_0-\varepsilon)+P(|\xi_n-\eta|\geqslant\varepsilon).$$

由于 x_0 是 $F(x)$ 的连续点，因此对任何 $\delta>0$，有 $\varepsilon>0$，满足

$$F(x_0+\varepsilon)-F(x_0-\varepsilon)<\frac{\delta}{2}.$$

取 n_0，当 $n\geqslant n_0$ 时，

$$P(|\xi_n-\eta|\geqslant\varepsilon)<\frac{\delta}{2}.$$

于是对一切 $n\geqslant n_0$，有

$$|F_n(x_0)-F(x_0)|<\delta.$$

这表明 $F_n(x_0)\to F(x_0)(n\to\infty)$，故 $\xi_n\xrightarrow{\omega}\eta$. □

注意，逆定理不真：

例： 设随机变量 $X\sim N(0,1)$，令

$$\xi_{2n-1}=X,\quad \xi_{2n}=-X\quad (n=1,2,\cdots).$$

易知所有的 ξ_n 有相同的分布函数 $\phi(x)$，为标准正态分布函数，显然 $\xi_n\xrightarrow{\omega}\eta$. 但是对 $\varepsilon>0$，有

$$P(|\xi_n-X|\geqslant\varepsilon)=\begin{cases}0, & n\text{是奇数},\\ P(|X|\geqslant\frac{\varepsilon}{2}), & n\text{是偶数}.\end{cases}$$

可见 $\xi_1,\xi_2,\cdots$ 并不依概率收敛于 X。

设 $X_1,X_2,\cdots$ 是随机变量序列，令

$$S_n=X_1+\cdots+X_n.$$

定义： 若 $E(X_n),n=1,2,\cdots$ 都存在, 且

$$\frac{1}{n}\left(S_n-E(S_n)\right)\xrightarrow{P}0$$

则称 $X_1,X_2,\cdots$ 服从 (弱) 大数律 (Weak Law of Large Numbers, WLLN)。

定义： 若 $E(X_n),n=1,2,\cdots$ 都存在, 且

$$\frac{1}{n}\left(S_n-E(S_n)\right)\xrightarrow{\text{a.s.}}0,$$

则称 $X_1,X_2,\cdots$ 服从强大数律 (SLLN)。

定义： 若对任意 $n\geqslant 2$ 都有 $X_1,\cdots,X_n$ 相互独立, 则称 $X_1,X_2,\cdots$ 是相互独立的随机变量序列。

若 $X_1, X_2, \cdots$ 相互独立, 且 $X_n \stackrel{d}{=} X_1, \forall n \geqslant 2$, 则称 $X_1, X_2, \cdots$ 独立同分布, 记为 i.i.d. (independent and identically distributed).

例: 设随机变量序列 $\{X_n\}$ 独立同分布，其密度函数为

$$p(x) = \begin{cases} \frac{1}{\beta}, & 0 < x < \beta, \\ 0, & \text{其他}. \end{cases}$$

其中常数 $\beta > 0$，令 $Y_n = \max\{X_1, X_2, \cdots, X_n\}$，证明 $Y_n \xrightarrow{P} \beta$.

证明: 因为当 $x < 0$ 时，有 $P(Y_n \leqslant x) = 0$，当 $x \geqslant \beta$ 时，有 $P(Y_n \leqslant x) = 1$，当 $0 \leqslant x < \beta$ 时，有

$$P(Y_n \leqslant x) = \prod_{i=1}^{n} P(X_i \leqslant x) = \prod_{i=1}^{n} \int_0^x \frac{1}{\beta} dx = \left(\frac{x}{\beta}\right)^n,$$

所以对任意的 $\varepsilon > 0 (\varepsilon < \beta)$，当 $n \to \infty$ 时，有

$$P(|Y_n - \beta| \geqslant \varepsilon) = P(Y_n \leqslant \beta - \varepsilon) = \left(\frac{\beta - \varepsilon}{\beta}\right)^n \to 0,$$

所以有 $Y_n \xrightarrow{P} \beta$. □

8.2 大数定律

切比雪夫大数定律: 假设 $X_1, X_2, \cdots$ 相互独立, 且存在 M 使得 $\operatorname{var}(X_i) \leqslant M, \forall i$. 设 $S_n = X_1 + \cdots + X_n$.，那么,

$$\frac{1}{n}(S_n - ES_n) \xrightarrow{P} 0 \quad (n \to \infty).$$

证明: 令 $A_n = \left\{\left|\frac{1}{n}(S_n - ES_n)\right| \geqslant \varepsilon\right\}$. 需验证 $P(A_n) \to 0$.

由切比雪夫不等式,

$$P(A_n) = P(|S_n - ES_n| \geqslant n\varepsilon) \leqslant \frac{1}{(n\varepsilon)^2} \operatorname{var}(S_n)$$

由于 $X_1, X_2, \cdots$ 两两不相关，所以 $\operatorname{var}(S_n) = \sum_{i=1}^n \operatorname{var}(X_i) \leqslant nM$，于是

$$P(A_n) \leqslant \frac{nM}{n^2\varepsilon^2} = \frac{M}{\varepsilon^2} \cdot \frac{1}{n} \to 0.$$

由此知定律成立。

其中定律里的条件“相互独立”可减弱为“两两不相关”. □

推论: 设 $X_1, X_2, \cdots$ 独立同分布, $\operatorname{var}(X_1) < \infty$, 则当 $n \to \infty$ 时,

$$\frac{S_n}{n} \xrightarrow{P} E(X_1).$$

推论：（伯努利大数律）单次试验中 A 发生的概率为 p, 设在 n 次试验中事件 A 发生了 ν_n 次，则当 $n \to \infty$ 时，

$$\frac{\nu_n}{n} \xrightarrow{P} p.$$

证明： 令

$$X_i = \begin{cases} 1, & \text{第}i\text{次试验中}A\text{发生}, \\ 0, & \text{第}i\text{次试验中}A\text{不发生}, \end{cases} \quad (i = 1, 2, \cdots),$$

则 $\frac{\nu_n}{n} = \frac{1}{n}\sum_{i=1}^{n} X_i$ 由于 $X_1, X_2, \cdots$ 是独立同分布的随机变量序列，$E(X_i) = p$，$\mathrm{var}(X_i) = p(1-p)(i = 1, 2, \cdots)$，故由上一推论知本推论成立。 □

如果不假定 $E(X_i)$ 存在，上述推论是否成立?

例： 设 $X_1, X_2, \cdots$ 独立同分布, 密度为 $p(x) = \frac{1}{\pi(x^2+1)}$. 可以证明，$\frac{S_n}{n}$ 与 X_1 有相同的密度. 于是，对任何 a 和 $\varepsilon > 0$，有

$$P\left(\left|\frac{S_n}{n} - a\right| > \varepsilon\right) = P\left(|X_1 - a| > \varepsilon\right) \text{ 不趋于}0.$$

故 $\frac{S_n}{n}$ 不能以概率收敛于 a。

定理：（Cantelli 强大数定律）假设 $X_1, X_2, \cdots$ 相互独立, $E(X_i)$ 存在, 且 $E\left(X_i - E(X_i)\right)^4 \leqslant M$, $\forall i$. 那么

$$\frac{1}{n}\left(S_n - ES_n\right) \xrightarrow{a.s.} 0.$$

推论： 设 $X_1, X_2, \cdots$ 独立同分布, $E(X_1^4)$ 存在, 则 $\frac{S_n}{n} \xrightarrow{\text{a.s.}} E(X_1)$.

本推论可以由 Cantelli 强大数定律直接推出。

推论：（Borel 强大数律）单次小试验中事件 A 发生的概率为 p. 在独立重复试验中, 前 n 次试验中 A 发生的次数为 ν_n，则

$$\frac{\nu_n}{n} \xrightarrow{\text{a.s.}} p.$$

定理 2.4. (Kolmogorov's SLLN). 假设 $X_1, X_2, \cdots$ 独立同分布, 期望存在, 则 $\frac{1}{n}S_n \xrightarrow{\text{a.s.}} EX_1$.

例： 设 $X_1, X_2, \cdots$ 是相互独立的随机变量序列，$X_1 \equiv 0$，对一切 $n \geqslant 2$，X_n 只取三个可能值 $n, -n, 0$，且

$$P(X_n) = n = P(X_n = -n) = \frac{1}{2n\ln n}, \quad P(X_n = 0) = 1 - \frac{1}{n\ln n}.$$

证明 $X_1, X_2, \cdots$ 服从切比雪夫大数定律。

证明： 易知

$$E(X_n) = 0, \quad \mathrm{var}(X_1) = 0, \quad \mathrm{var}(X_n) = \frac{n}{\ln n}(n = 2, 3, \cdots).$$

令 $S_n=\sum_{i=1}^n X_i$，则 $\operatorname{var}(S_n)=\sum_{i=1}^n \operatorname{var}(X_i)=\sum_{i=2}^n \frac{i}{\ln i}$. 由于 $x\geqslant 3$ 时 $\frac{x}{\ln x}$ 是 x 的增函数，故 $\operatorname{var}(S_n)\leqslant \frac{2}{\ln 2}+\frac{n^2}{\ln n}$，利用切比雪夫不等式，有

$$P\left(\left|\frac{S_n-E(S_n)}{n}\right|\geqslant\varepsilon\right)\leqslant\frac{1}{n^2\varepsilon}\operatorname{var}(S_n)\to 0\quad(\varepsilon>0,n\to\infty).$$

这表明 $X_1,X_2,\cdots$ 服从切比雪夫大数定律。

大数定律和强大数定律有广泛的应用：

(1)：统计方法的理论依据. 假设采集到数据数据: $X_1,\cdots,X_n$ 为 X 的 n 次独立观测值, 它们独立同分布.

常用 $\frac{1}{n}\left(X_1+\cdots+X_n\right)$ 估计期望:

$$\bar{X}:=\frac{1}{n}\left(X_1+\cdots+X_n\right)\stackrel{\text{a.s.}}{\to}E(X).$$

常用 $\frac{1}{n}\sum_{i=1}^n\left(X_i-\bar{X}\right)^2$ 估计方差:

$$\frac{1}{n}\sum_{i=1}^n\left(X_i-\bar{X}\right)^2=\frac{1}{n}\sum_{i=1}^n X_i^2-(\bar{X})^2\stackrel{\text{a.s.}}{\to}E(X^2)-(E(X))^2=\operatorname{var}(X).$$

(2): 用于计算机模拟期望、概率.

例： 设有 m 枚炮弹同时射击, 第 i 枚炮弹落点为 (x_i,y_i),

$$\varphi\left(x_1,y_1;\cdots;x_m,y_m\right)=\begin{cases}1, & \text{若落点造成有效毁伤;}\\ 0, & \text{否则.}\end{cases}$$

设第 i 枚炮弹的瞄准点为 (a_i,b_i), 实际落点 (X_i,Y_i). 模型假设: $X_1,\cdots,X_n;Y_1,\cdots,Y_n$ 相互独立, 且

$$X_i\sim N\left(a_i,\sigma_1^2\right),\quad Y_i\sim N\left(b_i,\sigma_2^2\right).$$

根据 SLLN:

$$\begin{aligned}&P\left(\varphi\left(X_1,Y_1;\cdots;X_m,Y_m\right)=1\right)\\ \approx&\frac{1}{n}\sum_{k=1}^n\varphi\left(X_1^{(k)},Y_1^{(k)};\cdots;X_m^{(k)},Y_m^{(k)}\right).\end{aligned}$$

利用数据 $X_1^{(k)},Y_1^{(k)};\cdots;X_m^{(k)}$ 即可用计算机计算概率的估计值。

(3)：估计积分 $I=\int_a^b f(x)dx$.

利用变量替换 $x=a+(b-a)u$ 得，$I=\int_0^1 f(a+(b-a)u)(b-a)du$, 因此不妨假设 $a=0,b=1$.

得到 $I=\int_0^1 f(x)\cdot 1dx = E(f(U))$. 其中 U 为服从区间 $(0,1)$ 上均匀分布的随机变量。

根据 SLLN:

$$I \approx \frac{1}{n}\sum_{i=1}^{n}\left(f\left(U_1\right)+\cdots+f\left(U_n\right)\right)$$

因此只需得到服从区间 $(0,1)$ 上均匀分布的随机数 $u_1,\cdots,u_n$，即可得到积分的近似值。该方法还可以推广到高维的数值积分。

8.3 中心极限定理

中心极限定理: 设 $X_1,X_2,\cdots$ 为随机变量序列，若 $E(X_n),\operatorname{var}(X_n),n=1,2,\cdots$ 都存在, $\operatorname{var}(X_n)$ 不全为 0 , 令 $S_n=\sum_{i=1}^n X_i$，且

$$S_n^*=\frac{S_n-E(S_n)}{\sqrt{\operatorname{var}(S_n)}}\xrightarrow{\omega} Z\sim N(0,1),$$

则称 $X_1,X_2,\cdots$ 服从中心极限定理 (Central Limit Theorem, CLT)(或适合中心极限定理)。

定理: (Linderberg-Levy 中心极限定理) 假设 $X_1,X_2,\cdots$ 独立同分布, $E(X_1)$ 存在且 $0<\operatorname{var}(X_1)<\infty$. 那么,

$$S_n^*\xrightarrow{\omega} Z\sim N(0,1).$$

例: 加法器同时收到 20 个噪声电压 $V_k,k=1,\cdots,20$, 它们独立同分布, $V_1\sim U(0,10)$. 记 $V=\sum_{k=1}^{20}V_k$, 求 $P(V>105)$.

解: 易知 $E(V_1)=5,\operatorname{var}(V_1)=\frac{10^2}{12}$.

设

$$V^*=\frac{V-20\times 5}{\sqrt{20\times\frac{100}{12}}}$$

根据中心极限定理,

$$P(V>105)=P\left(V^*>\frac{105-20\times 5}{\sqrt{20\times\frac{100}{12}}}\right)\approx 1-\Phi(0.387)$$

查表得 $\Phi(x^*)=0.652$, 从而所求的 $p=1-0.652=0.348$.

例: 旅馆有 500 间客房, 每间有一台 2 千瓦的空调. 入住率为 80%. 问: 需多少千瓦的电力能有 99% 的把握保证电力足够?

解: 假设提供 x 千瓦.

设事件 $A_i=$ “第 i 间房开空调”, $P\left(A_i\right)=80\%, X_i=2\times 1_{A_i}$.

则易知 $E(X_1)=1.6, \operatorname{var}\left(X_1\right)=4\times 0.8-1.6^2=0.64$.

要求 x 满足: $P\left(S_n\leqslant x\right)\geqslant 99\%$. 设

$$S_n^*=\frac{S_n-500\times 1.6}{\sqrt{500\times 0.64}}$$

根据根据中心极限定理, 要求

$$P\left(S_n\leqslant x\right)=P\left(S_n^*\leqslant x^*\right)\approx\Phi\left(x^*\right)\geqslant 0.99$$

其中

$$x^*=\frac{x-500*1.6}{\sqrt{500*0.64}}.$$

查表得 $\Phi(2.33)=0.99$. 即, 要求 $x^*\geqslant 2.33$.

即, 要求 $x\geqslant 800+2.33*\sqrt{320}=841.68$, 从而需 842 千瓦.

9.1 统计学若干基本概念

定义： 所考察的对象的总和称为**总体**，在统计学中可以归结为随机变量或其他形式的随机量。

例如，考察电子产品的使用寿命，于是将所有电子产品的使用寿命作为总体。所谓总体特性，就是使用寿命的特性，或者是刻画使用寿命的随机变量 X 的特性，该随机变量的分布称为**总体分布**。可以假定 X 的分布为指数分布，其分布密度有下列形式：

$$p(x,\theta)=\frac{1}{\theta}\exp\left\{-\frac{x}{\theta}\right\}\quad(x>0,\theta>0),$$

式中 θ 是分布的**参数**。

设用 $F(x,\theta)$ 表示随机变量 X 分布密度相应的分布函数，用 F_θ 表示相应的分布。为获取分布 F_θ 的信息，我们假定 F_θ 属于一个**分布族**，用 $\mathscr{F}=\{F_\theta,\theta\in\Theta\}$ 表示这个分布族。在分布族 $\mathscr{F}$ 的表达式中 θ 称为参数，Θ 称为**参数空间**。在统计学中，随机变量 X 称为总体，它的分布 F_θ 称为**总体分布**。这样，$X\sim F_\theta\in\mathscr{F}$ 形成了这个统计问题的**模型**，称为总体模型。

例如，电子产品的使用寿命 X 的分布 F_θ 由分布密度确定，其中参数 $\theta\in(0,+\infty)$。当 θ 确定后，我们获得了电子产品使用寿命的全部信息。

总体模型只涉及 X 这个随机变量,而没有涉及数据。观察数据 $\mathbf{x}=(x_1,\cdots,x_n)$ 是 $\mathbf{X}=(X_1,\cdots,X_n)$ 的观察值。其中 $X_1,\cdots,X_n$ 是独立同分布的, 这由样本的产生所确定, 其共同的分布为 F_θ。在统计学中，我们称 $\mathbf{X}=(X_1,\cdots,X_n)$ 为**样本**，称 n 为**样本量**，称 $\mathbf{X}$ 的取值 $\mathbf{x}=(x_1,\cdots,x_n)$ 为**样本值**。称 $\mathbf{X}$ 的所有可能取值的集合为样本空间 $\mathscr{X}$，在样本空间上的分布为 P_θ，我们称 $\mathbf{X}\sim P_\theta(\theta\in\Theta)$ 为**统计模型**。

模型的参数 θ 可以是常数向量或者其他的量，主要特征是：一旦参数的值确定后，统计模型中的分布就完全确定了。在某些统计问题中，我们需要了解与参数有关的量，即 θ 的函数 $g(\theta)$，为了简便，将 $g(\theta)$ 也称为参数。

例:（测量问题）对某待估量 a 重复独立测量 n 次, 得到测量值 $x_1,\cdots,x_n$.

测量值带有误差，总体分布 $X=a+e$, 其中 $e\sim N\left(0,\sigma^2\right)$. 即, $X\sim N\left(a,\sigma^2\right)$. 相应的参数空间为 $\Theta=\{\theta=(a,\sigma^2):a\in\mathbb{R},\sigma^2>0\}$。

参数 $\theta=\left(a,\sigma^2\right)$. 其中, σ^2 不是所关心的, 称为讨厌参数。

$P_\theta: \vec{X}$ 的联合密度为

$$f_\theta(x)=\prod_{i=1}^{n}\frac{1}{\sqrt{2\pi}\sigma}\exp\left\{-\frac{(x_i-a)^2}{2\sigma^2}\right\}.$$

这样，$\mathbf{X}\sim P_\theta$，$\theta=(a,\sigma^2)\in\Theta$ 形成了统计模型。

研究对象 θ 或 $g(\theta)$. 例, $g\left(a,\sigma^2\right)=a$.

定义： 设 $\mathbf{X}\sim P_\theta(\theta\in\Theta)$ 是一个统计模型，则定义在样本空间 $\mathcal{X}$ 上的任何函数 $T(\mathbf{x})(\mathbf{x}\in\mathcal{X})$ 都称为**统计量**。

在统计学中统计量通常是指具体的函数，不能泛指，尤其不能含有未知参数。从数学上，统计量是一个只依赖数据的函数，当 $(x_1,\cdots,x_n)$ 的值给定后根据函数关系可以算出 $T(\mathbf{x})$ 的值。

然而，如果将统计量看成样本 $\mathbf{X}$ 的函数，$T(\mathbf{X})$ 还是一个随机变量，具有分布，且在不同参数值下具有不同的分布。严格意义下，统计量具有分布族。

例如在测量问题中，最常见的统计量为样本均值 $T=\frac{1}{n}(X_1+\cdots+X_n)$，当观察值为 $x_1,\cdots,x_n$ 时，$T=\frac{1}{n}(x_1+\cdots+x_n)$ 为一个数值。当 $\mathbf{X}=(X_1,\cdots,X_n)$ 时，统计量是样本的函数，为随机变量。我们可以计算 T 的分布，$T\sim N\left(a,\frac{\sigma^2}{n}\right)$。注意统计量的分布含有未知参数 (a,σ^2)。

9.2 若干统计问题

估计问题： 依赖于样本的统计量就可以作为参数 a 的估计，在估计问题中，估计参数的统计量也称为估计量。

例：（测量问题续）测量问题中待测量 a 的一个估计为 $T_1=\frac{1}{n}\sum_{i=1}^{n}x_i$。当 $(X_1,\cdots,X_n)$ 服从多元正态分布时，其常系数线性组合的分布也是正态分布，利用 $X_i(i=1,\cdots,n)$ 独立同分布的特性，计算 T_1 的期望和方差，可得

$$E(T_1)=\frac{1}{n}\left[\sum_{i=1}^{n}E(X_i)\right]=a,$$

$$\operatorname{var}(T_1)=\frac{1}{n^2}\left[\sum_{i=1}^{n}\operatorname{var}(X_i)\right]=\frac{\sigma^2}{n},$$

这样我们得到 $T_1\sim N\left(a,\frac{\sigma^2}{n}\right)$。

假设检验： 对假设 H_0 回答“是”或“否”。

例如, 规定不合格率不能超过 3%. 现有 200 件产品, 从中任意抽取 10 件, 发现 2 件不合格. 问：是否可以出厂?

线性回归： 研究变量 Y 对 x 的线性依赖关系，

$$Y = b_0 + b_1 x + e, \quad e \sim N\left(0, \sigma^2\right).$$